

哈爾濱工業大學

模式识别与机器学习实验报告

实验 四

题	目	多层感知机实验
学	院	计算学部
专	业	工科试验班(AI 先进技术领军班)
学	号	2024113212
学	生	张泽晰
任	课 教 师	刘扬

哈尔滨工业大学计算机科学与技术学院

2021 年春季

1 实验内容

本实验面向人工构造的二维非线性四分类数据集，自行实现线性 Softmax 分类器与带一个隐藏层的多层感知机（MLP），并比较二者在同一数据集上的分类效果。实验进一步改变训练数据量、隐藏层神经元数和学习率，观察模型容量、样本规模与优化参数对分类性能的影响。

实验要求包括：构造超过 3 类的二维平面数据；自行实现 MLP 分类器；自行实现线性分类器作为对比；使用不同数据量与不同超参数比较实验效果，并分析产生差异的原因。

2 实验环境

表 1 实验环境与主要设置

项目	配置
编程语言	Python 3
主要依赖	NumPy、Matplotlib
随机种子	<code>np.random.seed(42)</code>
数据划分	对 800 个样本按 60%、20%、20% 划分训练集、验证集和测试集
训练方式	批量梯度下降，手写前向传播、反向传播与参数更新

3 实验原理与方法

3.1 数据构造

实验使用四类二维螺旋数据。每一类从不同的起始角度出发，半径随参数 t 线性增大，角度随 t 旋转，从而形成明显的非线性类别边界。该数据集无法被单个线性判别面充分分开，因此适合检验 MLP 的非线性表示能力。

$$x_1 = r \cos \theta + \varepsilon_1, \quad x_2 = r \sin \theta + \varepsilon_2 \quad (1)$$

$$r = 0.5 + t, \quad \theta = \theta_c + \pi t \quad (2)$$

其中， θ_c 表示第 c 类样本的起始角度， $\varepsilon_1, \varepsilon_2$ 表示加入到二维坐标上的高斯噪声。

3.2 线性分类器

线性分类器直接对二维输入进行仿射变换并接 Softmax，等价于多类 Softmax 回归。设输入矩阵为 X ，参数矩阵为 W ，偏置为 b ，则输出 logits 为

$$Z = XW + b. \quad (3)$$

第 k 类的预测概率为

$$p_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}. \quad (4)$$

由于该模型只包含线性变换，其决策边界主要由线性区域组合而成，难以拟合螺旋数据的弯曲边界。

3.3 多层感知机

MLP 在输入层和输出层之间加入隐藏层，先将二维输入映射到高维隐空间，再进行线性分类。本文实现的一隐层 MLP 使用 ReLU 作为隐藏层激活函数，输出层使用 Softmax：

$$H = \text{ReLU}(XW_1 + b_1), \quad (5)$$

$$\hat{Y} = \text{Softmax}(HW_2 + b_2). \quad (6)$$

训练时使用交叉熵损失函数：

$$L = -\frac{1}{m} \sum_{i=1}^m \log p_{i,y_i}. \quad (7)$$

其中 m 为样本数， y_i 为第 i 个样本的真实类别， p_{i,y_i} 为模型分配给真实类别的概率。

Listing 1 MLP 前向传播与反向传播关键代码

```
1 def forward(self, X):
2     self.X = X
3     self.z1 = X @ self.W1 + self.b1
4     self.a1 = self._activate(self.z1)
5     self.z2 = self.a1 @ self.W2 + self.b2
```

```

6     self.probs = softmax(self.z2)
7     return self.probs
8
9 def backward(self, y_true_onehot):
10     m = self.X.shape[0]
11     dZ2 = self.probs - y_true_onehot
12     dW2 = (self.a1.T @ dZ2) / m
13     db2 = np.mean(dZ2, axis=0, keepdims=True)
14     dA1 = dZ2 @ self.W2.T
15     dZ1 = dA1 * self._derivative_activate(self.a1)
16     dW1 = (self.X.T @ dZ1) / m
17     db1 = np.mean(dZ1, axis=0, keepdims=True)
18     return dW1, db1, dW2, db2

```

4 实验结果及分析

本节所有准确率均来自 代码完整输出.txt 中记录的程序输出。

4.1 线性分类器与 MLP 对比

表 2 线性分类器与 MLP 测试准确率对比

模型	主要设置	测试准确率
线性分类器	lr=0.05, epochs=500	0.4375
MLP	hidden=20, ReLU, lr=0.1, epochs=5000	0.9187




图 1 线性分类器与 MLP 的决策边界对比

由图 1 可见，线性分类器只能形成较简单的线性分割区域，在螺旋数据的弯曲类别边界附近出现大量误分，测试准确率仅为 0.4375。MLP 的决策区域能够沿数据分布弯曲变化，说明隐藏层非线性映射提升了模型表达能力，测试准确率提高到 0.9187。

4.2 不同数据量的影响

表 3 不同数据量下 MLP 的测试准确率

样本总量	测试准确率	现象
50	0.8750	样本较少，决策边界估计不稳定 性能有所提升 样本覆盖更充分，泛化效果最好
100	0.9000	
300	1.0000	




图 2 数据量对 MLP 分类准确率的影响

随着数据量由 50 增加到 300，MLP 的测试准确率整体上升。较大的训练集提供了更充分的空间分布信息，使网络能够学习到更稳定的螺旋边界；样本过少时，模型容易只记住局部模式，边界估计受随机采样影响更明显。

4.3 隐藏层规模的影响

表 4 不同隐藏层神经元数下 MLP 的测试准确率

隐藏层神经元数	测试准确率	分析
5	0.9688	已有较强拟合能力，但局部边界仍受容量限制 表达能力提升，准确率提高 继续增大容量收益趋于饱和
20	0.9812	
30	0.9812	




图 3 隐藏层神经元数对 MLP 分类准确率的影响

隐藏层神经元数从 5 增加到 20 后准确率提高，说明适当增加模型容量可以更好地刻画非线性决策边界；从 20 增加到 30 后准确率基本不再提升，表明在当前数据规模和任务难度下，20 个隐藏单元已经足以提供主要表达能力。

4.4 学习率的影响

表 5 不同学习率下 MLP 的测试准确率

学习率	测试准确率	分析
0.001	0.2000	更新过小，有限轮数内几乎未有效收敛
0.01	0.2000	收敛仍然较慢
0.1	0.4625	能够学习部分结构，但训练轮数不足以达到最优
1.0	0.9625	收敛速度明显提高，效果最好




图 4 学习率对 MLP 分类准确率的影响




图 5 MLP 训练损失曲线

学习率直接影响梯度下降的更新幅度。在本实验的 500 轮学习率对比中，0.001 和 0.01 更新幅度过小，模型尚未充分收敛；0.1 有一定改善；1.0 能够更快降低损失并获得最高准确率。损失曲线显示，在主要 MLP 训练过程中交叉熵损失持续下降，说明反向传播和参数更新能够有效优化模型。

5 结论

本实验自行实现了四分类二维螺旋数据上的线性分类器和一隐层 MLP。实验结果表明，线性分类器由于表达能力受限，难以拟合非线性螺旋边界；MLP 通过隐藏层和 ReLU 激活获得非线性表示能力，测试准确率显著提升。进一步实验说明，增加训练数据量通常有助于提高泛化性能；隐藏层规模需要与任务复杂度匹配，过小会欠拟合，过大时收益逐渐饱和；学习率过小会导致收敛缓慢，合适的较大学习率能显著改善训练效果。