

模式识别与机器学习 (2-3)

贝叶斯决策理论

左旺孟


哈尔滨工业大学计算机学院
机器学习研究中心
综合楼712

cswmzuo@gmail.com

13134506692



模式识别（分类）系统组成



问题的引出

- 两类问题
- 训练数据 $\{(\mathbf{x}_i, y_i) | i = 1, 2, \dots, N_{\text{train}}\}$
- 测试数据 $\{(\mathbf{x}_j, y_j) | j = 1, 2, \dots, N_{\text{test}}\}$
- 分类器 $y = f(\mathbf{x}; \Theta)$
- 如何学习 Θ

$$\Theta = \arg \min \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \{y_i \neq f(\mathbf{x}_i; \Theta)\}$$

- 问题：
 - 1. 无法求导 $\rightarrow$ proxy loss（代理损失）
 - 2. 过拟合 $\rightarrow$ 正则化（如：f应尽可能简单）

如何从训练数据中学习一个分类器

学习内容： 贝叶斯决策理论

- 1. 贝叶斯定理
- 2. 贝叶斯决策
 - 最小错误率判别
 - 最小风险判别
 - 聂曼-皮尔逊准则

1. 贝叶斯定理

- 概率论基础知识
- 贝叶斯定理
- 模式识别的贝叶斯观点

概率论知识回顾

• 概率 P

- 设随机试验的所有可能试验结果组成的样本空间为 Ω ，对于 Ω 的任一子集 A (对应于一个事件)，定义一个函数，记为 $P(A)$ 。若函数 $P(A)$ 满足如下三个条件：

- (i) 对于任一随机事件 A ，有 $0 \leq P(A) \leq 1$ ；
- (ii) $P(\Omega)=1$ ， $P(\phi)=0$ ，其中 ϕ 为不可能事件；
- (iii) 对于两两互不相容事件 $A_1, A_2, \dots, A_n, \dots$ 有

则称 $P(A)$ 为事件 A 的概率：
$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

- 概率： (Ω, A, P)

• 条件概率

- 条件概率公式：
$$P(A|B) = \frac{P(AB)}{P(B)}$$

- 联合概率： $P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2 | A_1) \cdots P(A_n | A_1 A_2 \cdots A_{n-1})$
- 独立性： $P(AB) = P(A)P(B) \Rightarrow P(A|B) = P(A)$

两个重要概率计算公式

- 加法公式

$$p(X) = \sum_Y p(X, Y)$$

- 乘法公式

$$p(X, Y) = p(Y|X)p(X)$$

贝叶斯定理 (1) – 全概率公式

- 设 $A_1, A_2, \dots, A_n$ 是一组完备事件组，即满足
 1. $A_1, A_2, \dots, A_n$ 两两互不相容
 2. $A_1 \cup A_2 \cup \dots \cup A_n = \Omega$
 3. $P(A_i) > 0$

则对任一事件 B ，有

$$P(B) = \sum_{i=1}^n P(B | A_i) P(A_i)$$

贝叶斯定理 (2)

- 贝叶斯定理
$$P(A_i | B) = \frac{P(A_i)P(B | A_i)}{\sum_j P(A_j)P(B | A_j)}$$

- 先验概率 $P(A_i)$
- 条件概率（似然函数）
- 后验概率

- 简单说明

$$\begin{aligned} P(A_i, B) &= P(A_i)P(B | A_i) = P(B)P(A_i | B) \\ \Rightarrow P(A_i | B) &= \frac{P(A_i)P(B | A_i)}{P(B)} \\ \Rightarrow P(A_i | B) &= \frac{P(A_i)P(B | A_i)}{\sum_j P(A_j)P(B | A_j)} \left(P(B) = \sum_{i=1}^n P(B | A_i)P(A_i) \right) \end{aligned}$$

解释

$$\text{后验概率} = \frac{\text{先验概率} \cdot \text{似然}}{\text{归一化项}}$$

$$\text{结论} = \frac{\text{先验} \cdot \text{观测}}{\text{归一化项}}$$

$$P(x | y) = \frac{P(x)P(y | x)}{\sum_x P(x)P(y | x)}$$

贝叶斯分析：历史

- 历史
 - 贝叶斯：先验分布为均匀分布
 - 拉普拉斯：一般形式
 - E.T. Janes：一般推导方法
 - Pearl：因果推断
- 解释
 - 概率
 - 不确定性
 - 样本
 - 模型




推荐读物

- Dimitri P. Bertsekas, and John N. Tsitsiklis
， 概率导论， 人民邮电出版社
- E.T. Janes, Probability Theory: The Logic of Science（概率论沉思录）， 人民邮电出版社， 2024（中文版）

模式识别问题

- 监督学习
 - 模式分类
 - 回归分析



- 无监督学习
 - 聚类分析
- 其它

模式识别问题：模式分类

• 问题描述

给定一个训练样本的特征矢量集合：


$$D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \mathbf{x}_i \in \mathbb{R}^d$$

分别属于 c 个类别：

$$\omega_1, \omega_2, \dots, \omega_c$$

设计出一个分类器，能够对未知类别样本 $\mathbf{x}$ 进行分类

$$y = g(\mathbf{x}), \mathbb{R}^d \rightarrow \{1, \dots, c\}$$



决策函数

模式识别问题：回归分析

• 问题描述

给定一个训练样本的特征矢量集合：

$$D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \mathbf{x}_i \in \mathbb{R}^d$$

其对应的输出 $\{y_1, y_2, \dots, y_n\}$ 是连续变量：

$$y_i \in \mathbb{R}, 1 \leq i \leq n$$

设计出一个函数，能够对未知类别样本 $\mathbf{x}$ 进行回归分析


$$y = g(\mathbf{x}), \mathbb{R}^d \rightarrow \mathbb{R}$$




决策函数





模式识别的贝叶斯观点 (1)

- 基于贝叶斯准则来训练决策函数




- 决策函数的概率解释





模式识别的贝叶斯观点 (2)

- 基于贝叶斯准则来分析输出结果



- 输出结果的概率解释

模式识别的贝叶斯观点 (2)

- 基于贝叶斯准则进行决策和预测
- 以模式分类问题为例
 - 先验概率: $P(\omega_i)$
 - 后验概率: $P(\omega_i | \mathbf{x})$
 - 类条件概率: $P(\mathbf{x} | \omega_i)$
 - 贝叶斯公式:
$$P(\omega_i | \mathbf{x}) = \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})}$$

学习内容： 贝叶斯决策理论

- 1. 贝叶斯定理
- 2. 贝叶斯决策
 - 最小错误率判别
 - 最小风险判别
 - 聂曼-皮尔逊准则

2. 贝叶斯决策


贝叶斯决策准则：

- 最小错误率判别
- 最小风险判别
- 聂曼-皮尔逊准则
-

起点

- 从 n 个数 $\{x_1, \dots, x_n\}$ 中选出尽可能多的数，使得他们的和最大
- 使他们的和最小
- 假设有 m 个正数，选 $d \leq m$ 个数，使得他们的和最大

2.1 最小错误率准则（以两类问题为例）



两类问题的错误率

- 观察到特征 $\mathbf{x}$ 时作出判别的**错误率**:

$$P(error|\mathbf{x}) = \begin{cases} P(\omega_1|\mathbf{x}), & \text{判定 } \omega_2 \\ P(\omega_2|\mathbf{x}), & \text{判定 } \omega_1 \end{cases}$$

- 两类问题**最小错误率判别准则**:

$$\begin{cases} \text{如果 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_2 \end{cases}$$

多类问题最小错误率

- 判别 $\mathbf{x}$ 属于 ω_i 的**错误率**:

$$P(error|\mathbf{x}) = \sum_{j \neq i} P(\omega_j|\mathbf{x}) = 1 - P(\omega_i|\mathbf{x})$$

- **判别准则**为:

$$i = \arg \max_{1 \leq j \leq c} P(\omega_j|\mathbf{x}), \quad \text{则: } \mathbf{x} \in \omega_i$$

贝叶斯最小错误率准则


$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{p(\mathbf{x})}$$

$$g_j(\mathbf{x}) = p(\mathbf{x} | \omega_j) P(\omega_j)$$

Bayes判别准则:

$$i = \arg \max_{1 \leq j \leq c} g_j(\mathbf{x}) , \quad \text{则 } \mathbf{x} \in \omega_i$$

贝叶斯分类器的错误率估计



$$\begin{aligned} p(\text{mistake}) &= p(\mathbf{x} \in \mathcal{R}_1, C_2) + p(\mathbf{x} \in \mathcal{R}_2, C_1) \\ &= \int_{\mathcal{R}_1} p(\mathbf{x}, C_2) d\mathbf{x} + \int_{\mathcal{R}_2} p(\mathbf{x}, C_1) d\mathbf{x}. \end{aligned}$$

例2.1

- 对一大批人进行癌症普查，设 ω_1 类代表患癌症， ω_2 类代表正常人。已知先验概率：

$$P(\omega_1) = 0.005, P(\omega_2) = 0.995$$

以一个化验结果作为特征 x : {阳性, 阴性}, 患癌症的人和正常人化验结果为阳性的概率分别为:

$$P(x = \text{阳性} | \omega_1) = 0.95, P(x = \text{阳性} | \omega_2) = 0.01$$

现有一人化验结果为阳性，问此人是否患癌症？

2.2 最小平均风险准则贝叶斯分类器

- 问题的提出

有 c 个类别 $\omega_1, \omega_2, \dots, \omega_c$, 将 ω_i 类的样本判别为 ω_j 类的**代价 (Cost)** 为 λ_{ij} 。

- 将未知模式 $\mathbf{x}$ 判别为 ω_j 类的**平均风险**为:

$$\gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\omega_i | \mathbf{x})$$

最小平均风险判别准则

- 利用Bayes公式，构造判别函数：

$$g_j(\mathbf{x}) = -\gamma_j(\mathbf{x})$$

$$\gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\mathbf{x}|\omega_i) P(\omega_i)$$

- 判别准则：

$$i = \arg \min_{1 \leq j \leq c} \gamma_j(\mathbf{x}), \quad \text{则: } \mathbf{x} \in \omega_i$$

与最小错误率准则的联系

- 定义0-1代价函数

$$\lambda_{ij} = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases}$$

- 使用上面的代价函数，最小错误率准则与最小平均风险判别准则等价。

例2.2

- 对一大批人进行癌症普查，设 ω_1 类代表患癌症， ω_2 类代表正常人。已知先验概率：

$$P(\omega_1) = 0.005, P(\omega_2) = 0.995$$

以一个化验结果作为特征 $\mathbf{x}$: {阳性, 阴性}, 患癌症的人和正常人化验结果为阳性的概率分别为:

$$P(x = \text{阳性} | \omega_1) = 0.95, P(x = \text{阳性} | \omega_2) = 0.01$$

判别代价: $\lambda_{11} = 0, \lambda_{22} = 0, \lambda_{12} = 10, \lambda_{21} = 1$

现有一人化验结果为阳性，问此人是否患癌症？

有 c 个类别 $\omega_1, \omega_2, \dots, \omega_c$, 将 ω_i 类的样本判别为 ω_j 类的代价 (Cost) 为 λ_{ij} 。

- 将未知模式 $\mathbf{x}$ 判别为 ω_j 类的平均风险为:

$$\gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\omega_i | \mathbf{x})$$

Neyman-Pearson准则的引入

- 假设检验
 - 第一类错误（Type-I，假阳性），错误地拒绝了实际上成立的原假设；
 - 第二类错误（Type-II，假阴性），错误地接受了实际上不成立的原假设
- 实际应用
 - 生物特征识别：误识率/误拒率
 - 信息检索：查全率/查准率
- 针对不同应用场合
 - 在限定一类错误率条件下使另一类错误率为最小
 - 调整


2.3 Neyman-Pearson准则

- 原则：在限定一类错误率条件下使另一类错误率为最小。
- 两类问题
- 实际问题：如身份鉴别、物体检测



Neyman-Pearson准则

在两类情况，设 $p(x|\omega_1)$ 和 $p(x|\omega_2)$ 已知，其分布如图所示：



ω_1 类的样本被错分到 ω_2 的错误率为：

$$\varepsilon_1 = \int_{a_2} p(x | \omega_1) dx \quad (16)$$

ω_2 类的样本被错分到 ω_1 的错误率为：

$$\varepsilon_2 = \int_{a_1} p(x | \omega_2) dx \quad (17)$$

聂曼-皮尔逊准则是在取 ε_2 为常数条件下，使 ε_1 为最小，以此来确定判别准则（阈值 t ）。

决策准则

- 以两类问题为例

$$\frac{p(x | \omega_1)}{p(x | \omega_2)} > \mu \quad \rightarrow \quad x \in \begin{matrix} \omega_1 \\ \omega_2 \end{matrix}$$

- 重点：给定 ε_2 ，如何确定对应的 μ ？
- 优化问题的等价性（选择适当的 μ ）：

$$\arg \min_{a_1} = \varepsilon_1(a_1), \quad s.t. \quad \varepsilon_2(a_2) \leq C \quad \varepsilon_2 = C$$

$$\Leftrightarrow \arg \min_{a_1} = \varepsilon_1(a_1) + \mu \varepsilon_2(a_2)$$

构造如下等式：

$$Q = \varepsilon_1 + \mu(\varepsilon_2 - C) \quad (18)$$

其中， μ 为待定常数。

由于 $\mu\varepsilon_2$ 是常数， ε_1 最小等价于 Q 最小。

将式(16) 和 (17) 代入式 (18)：

$$\begin{aligned} Q &= \varepsilon_1 + \mu(\varepsilon_2 - C) \\ &= \int_{a_2} p(x | \omega_1) dx + \mu \int_{a_1} p(x | \omega_2) dx - \mu C \\ &= 1 - \mu C - \int_{a_1} p(x | \omega_1) dx + \mu \int_{a_1} p(x | \omega_2) dx \\ &= 1 - \mu C + \int_{a_1} [\mu p(x | \omega_2) - p(x | \omega_1)] dx \end{aligned} \quad (19)$$

上式中，只有 a_1 是变量。为使 Q 最小，我们把使得被积分项为负的所有样本组成区域 a_1 （即 ω_1 类）：

$$\mu p(x | \omega_2) - p(x | \omega_1) < 0$$

即

$$\frac{p(x | \omega_1)}{p(x | \omega_2)} > \mu \quad \rightarrow \quad x \in \omega_1$$

同理：

$$\begin{aligned} Q &= \varepsilon_1 + \mu \varepsilon_2 - \mu C \\ &= \int_{a_2} p(x | \omega_1) dx + \mu \int_{a_1} p(x | \omega_2) dx - \mu C \\ &= \int_{a_2} p(x | \omega_1) dx + \mu (1 - \int_{a_2} p(x | \omega_2) dx) - \mu C \\ &= \mu(1 - C) + \int_{a_2} [p(x | \omega_1) - \mu p(x | \omega_2)] dx \end{aligned} \quad (20)$$

即确定区域 a_2 的准则为

$$\frac{p(x | \omega_1)}{p(x | \omega_2)} < \mu \quad \rightarrow \quad x \in \omega_2$$

综合起来,

$$\frac{p(x | \omega_1)}{p(x | \omega_2)} > \mu \quad \rightarrow \quad x \in \omega_1$$

聂曼-皮尔逊判别准则就是要找**阈值** μ 。

μ 值可以通过求解如下方程组得到:

$$\left\{ \begin{array}{l} \mu = \frac{p(x | \omega_1)}{p(x | \omega_2)} \end{array} \right. \quad (*)$$

$$\left\{ \begin{array}{l} \varepsilon_2 = \int_{\frac{p(x|\omega_1)}{p(x|\omega_2)} > \mu} p(x | \omega_2) dx \end{array} \right. \quad (**)$$


先由式(*)得到 x 的 μ 的表达式,并代入 (**)就得到 μ 和 ε_2 的表达式, 确定了 ε_2 后, 就能找到 μ 。

例2.3

例：一两类问题，模式分布为二维正态，其分布参数为：

$$m_1 = (-1 \ 0)^t, \quad m_2 = (1 \ 0)^t$$

它们的协方差矩阵等于单位矩阵，即 $\mathbf{C}_1 = \mathbf{C}_2 = \mathbf{I}$ ，其分布如图所示。设确定 $\varepsilon_2 = 0.04$ ，求聂曼-皮尔逊判别阈值。



解：

$$p(x | \omega_1) = \frac{1}{2\pi} \exp[-((x_1 + 1)^2 + x_2^2) / 2]$$

$$p(x | \omega_2) = \frac{1}{2\pi} \exp[-((x_1 - 1)^2 + x_2^2) / 2]$$

所以，

$$\mu \leq \frac{p(x | \omega_1)}{p(x | \omega_2)} = \exp(-2x_1)$$

两边取对数，得

$$x_1 \leq -\frac{1}{2} \ln \mu$$

所以

$$\varepsilon_2 = \int_{-\infty}^{-\frac{1}{2}\ln\mu} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x_1-1)^2}{2}\right] dx_1$$

化为标准正态，令

$$x_1 - 1 = y, \quad x_1 = -\frac{1}{2}\ln\mu$$

则

$$y = -\frac{1}{2}\ln\mu - 1$$

所以

$$\varepsilon_2 = \int_{-\infty}^{-\frac{1}{2}\ln\mu-1} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right) dy$$

查有关的数学用表可计算得下表：

μ	4	2	1	1/2	1/4
y	-1.693	-1.347	-1	-0.653	-0.307
x_1	-0.693	-0.347	0	0.347	0.693
ε_2	0.046	0.089	0.0159	0.258	0.378

2.4 贝叶斯分类器的其它版本

- 先验概率 $P(\omega_i)$ 未知：极小化极大准则；
 - 博弈论：使最大风险最小化
- 某些特征缺失的决策；
- 顺序出现的特征之间统计相关的决策：序贯决策

贝叶斯决策：小结

- 最小错误率

$$\frac{p(x | w_1)}{p(x | w_2)} > 1 \quad \rightarrow \quad x \in \begin{matrix} w_1 \\ w_2 \end{matrix}$$


- 最小代价

$$i = \arg \min_{1 \leq j \leq c} \gamma_j(\mathbf{x}), \text{ 则: } \mathbf{x} \in \omega_i \quad \gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\omega_i | \mathbf{x})$$

- Neyman-Pearson准则

$$\frac{p(x | w_1)}{p(x | w_2)} > \mu \quad \rightarrow \quad x \in \begin{matrix} w_1 \\ w_2 \end{matrix}$$

贝叶斯分类器




分类器、判别函数和决策面

- 判别函数: $g_i(\mathbf{x})$
 - 如 $g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$
 - 或 $g_i(\mathbf{x}) = \ln[P(\omega_i|\mathbf{x})]$
- 判别准则
 - 最小错误率
 - 最小平均风险
 - Neyman-Pearson
- 分类器 (判别函数+判别准则): 对未知样本进行分类
- 决策面: 类与类的分界面

简单应用：正态分布的贝叶斯分类器


- 单变量正态分布密度函数（高斯分布）：




$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

多元正态分布函数


$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_i|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \right]$$



正态分布（高斯分布）



$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$






$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$



正态（高斯）分布

- 中心极限定理：如果一个随机变量是若干独立随机变量的总和，当被加数的个数趋于无穷时，它的概率密度函数近似高斯函数。
- 许多实际数据往往近似服从正态分布。
- 任何分布都可以近似表示为若干（甚至无穷多）个高斯分布的混合模型
- 数学上的简单性



正态分布的判别函数

- 贝叶斯判别函数可以写成对数形式:

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

- 类条件概率密度函数为正态分布时:

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

情况一： $\Sigma_i = \sigma^2 \mathbf{I}, P(\omega_i) = \frac{1}{c}$

- 判别函数可以写成：

$$g_i(\mathbf{x}) = -(\mathbf{x} - \boldsymbol{\mu}_i)^t (\mathbf{x} - \boldsymbol{\mu}_i) = -\|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

- 此分类器称为**距离分类器**，判别函数可以用**待识模式 $\mathbf{x}$ 与类别均值 $\boldsymbol{\mu}_i$ 之间的距离**表示：

$$g_i(\mathbf{x}) = -d(\mathbf{x}, \boldsymbol{\mu}_i)$$

情况二： $\Sigma_i = \Sigma$

- 判别函数可以写成：

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$


- 可以简化为：

$$g_i(\mathbf{x}) = \boldsymbol{\mu}_i^t \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i + \ln P(\omega_i) = \mathbf{w}_i^t \mathbf{x} + w_{i0}$$

称为线性分类器



线性分类器

- 两类问题，1维特征，先验概率相同时：




线性分类器

- 两类问题，高维特征，先验概率相同时





线性分类器

- 两类问题，1维特征，先验概率不同时：



线性分类器

- 两类问题，高维特征，先验概率不同时：







情况三： 任意 Σ_i

- 判别函数可以写成：





$$g_i(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^t \Sigma_i^{-1} \mathbf{x} + \boldsymbol{\mu}_i^t \Sigma_i^{-1} \mathbf{x} + \left(-\frac{1}{2} \boldsymbol{\mu}_i^t \Sigma_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \right)$$

- 分类界面为2次曲线（面）

二次分类曲线




二次分类曲面



Note（假设可以错误 + 推导必须严格）

- 应用概率模型来分析不确定现象时，一般会分为两个阶段：
 - 在一个适当的样本空间中给出概率律，建立满足概率公理的概率模型。选择的模型应当**准确**、**简单**又要兼顾**可操作性**。有时，人们宁愿使用“错误”的模型，其理由是“错误”的模型比“正确”的模型简单且易于处理。
 - 在**严格**的概率模型下进行推导，形成一个**准确**或**合理**的答案。
- Dimitri P. Bertsekas, and John N. Tsitsiklis, [Introduction to Probability](#), Second edition, 人民邮电出版社, 2009.

- 作为扩展逻辑的概率论，概率论的数学规则不仅仅是计算“随机变量”频率的规则，也是进行任何形式推断（即合情推理）的唯一一致性规则。



Edwin Thompson Jaynes, 概率论沉思录, 人民邮电出版社, 2024.

分类器

$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^2 P(\mathbf{x}|\omega_j)P(\omega_j)}$$

3. 贝叶斯学习：根据训练样本对类别先验概率和类条件概率进行建模，并进一步构建分类器

$$\begin{cases} \text{如果 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_2 \end{cases}$$

$$F(\mathbf{x}) = \log \left(\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} \right) \begin{cases} \geq 0, & \mathbf{x} \in \omega_1 \\ < 0, & \mathbf{x} \in \omega_2 \end{cases}$$

2. 判别学习：根据训练样本对类别后验概率进行建模判别函数：


$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$$


1. 判别函数：根据训练样本学习直接学习函数 $F(\mathbf{x})$

判别函数： $g(\mathbf{x}) = F(\mathbf{x})$

模式识别的贝叶斯观点

- 基于贝叶斯准则来训练决策函数





END

复习

- 基于最小错误率判别准则，

$$P(\omega_{\max} | \mathbf{x}) = \max_{1 \leq j \leq c} P(\omega_j | \mathbf{x}), \text{ 则: } \mathbf{x} \in \omega_i$$

进行分类时，试证明或分析下述问题：

- 证明

$$P(\omega_{\max} | \mathbf{x}) \geq 1/c$$

- 证明误判概率

$$P(error) \leq (c-1)/c$$

- 分析在什么情况下，有

$$P(error) = (c-1)/c$$

复习

- 考虑二维两类问题，其中

$$P(\mathbf{x}|\omega_1) \sim N(\mathbf{0}, \mathbf{I}), \quad P(\mathbf{x}|\omega_2) \sim N\left(\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{I}\right)$$

且 $P(\omega_1) = P(\omega_2) = 0.5$

- 根据最小错误率准则，计算贝叶斯决策面；
- 分析计算误判概率 $P(error)$ 的上界
- 如果 $P(\omega_1) = 0.6, P(\omega_2) = 0.4$
 - 计算此时的贝叶斯决策面

复习

- 在图像识别中，假定有灌木丛和坦克两种类型，他们的先验概率分别是0.7和0.3，损失函数如表所示。现在做了四次试验，获得的四个样本的类概率密度如下：

$$P(\mathbf{x}|\omega_1) = 0.1, 0.15, 0.3, 0.6$$

$$P(\mathbf{x}|\omega_2) \sim 0.8, 0.7, 0.55, 0.3$$

- 使用贝叶斯最小风险准则判决四个样本的类别。
- 使用贝叶斯最小错误率准则判决四个样本的类别

各种判决情况下的风险

判决 \ 类型	ω_1	ω_2
	ω_1	ω_2
ω_1	0	2
ω_2	5	0

分类器讨论

$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^2 P(\mathbf{x}|\omega_j)P(\omega_j)}$$

3. 贝叶斯学习：根据训练样本对类别先验概率和类条件概率进行建模，并进一步构建分类器

$\begin{cases} \text{如果 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_2 \end{cases}$

$$F(\mathbf{x}) = \log \left(\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} \right) \begin{cases} \geq 0, & \mathbf{x} \in \omega_1 \\ < 0, & \mathbf{x} \in \omega_2 \end{cases}$$

2. 判别学习：根据训练样本对类别后验概率进行建模

判别函数： $g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$

1. 判别函数：根据训练样本学习直接学习函数 $F(\mathbf{x})$

判别函数： $g(\mathbf{x}) = F(\mathbf{x})$