



模式识别与机器学习 (4)

线性分类器

左旺孟

哈尔滨工业大学计算机学院
机器学习研究中心
综合楼712

cswmzuo@gmail.com

13134506692

复习

- 基于最小错误率判别准则,

$$P(\omega_{\max} | \mathbf{x}) = \max_{1 \leq j \leq c} P(\omega_j | \mathbf{x}), \text{ 则: } \mathbf{x} \in \omega_i$$

进行分类时, 试证明或分析下述问题:

- 证明

$$P(\omega_{\max} | \mathbf{x}) \geq 1/c$$

- 证明误判概率

$$P(error) \leq (c-1)/c$$

- 分析在什么情况下, 有

$$P(error) = (c-1)/c$$

分类器讨论

$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^2 P(\mathbf{x}|\omega_j)P(\omega_j)}$$

3. 贝叶斯学习：根据训练样本对
类别先验概率和**类条件概率**进行
建模，并进一步构建分类器

$$\begin{cases} \text{如果 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_2 \end{cases}$$

$$F(\mathbf{x}) = \log \left(\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} \right) \begin{cases} \geq 0, & \mathbf{x} \in \omega_1 \\ < 0, & \mathbf{x} \in \omega_2 \end{cases}$$

2. 判别学习：根据训练样本对
类别后验概率进行建模

判别函数： $g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$

1. 判别函数：根据训练样本学
习直接学习**函数** $F(\mathbf{x})$

判别函数： $g(\mathbf{x}) = F(\mathbf{x})$

判别分类器

- 线性判别分类器
 - 判别函数：感知器、线性支持向量机
 - 判别学习：Logistic回归
- 非线性判别分类器
 - 判别学习：kNN
 - 判别函数：神经网络
 - 核方法
 - 推广能力
- 两类问题和多类问题

1. 线性判别函数

- 问题

- 基本概念：线性判别函数、线性判别分类器
- 两类问题
- 多类问题


- 训练方法

- Logistic回归方法
- 感知器准则
- 线性支持向量机

线性判别分类器、判别函数、决策平面



线性判别分类器

- 决策面是平面或超平面
- 判别函数是一个线性函数



线性判别分类器

- 判别函数是一个线性函数




两类问题的线性判别函数

$$g(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_nx_n + w_0 = \mathbf{w}^t\mathbf{x} + w_0$$

- $\mathbf{x} = (x_1, x_2, \dots, x_n)^t$ 为待识别模式的特征向量;
- $\mathbf{w} = (w_1, w_2, \dots, w_n)^t$ 称为权向量。

分类界面（决策面）与权值



线性判别函数的增广形式

$$g(\mathbf{x}) = \mathbf{w}^t \mathbf{x}$$

- $\mathbf{x} = (x_1, x_2, \dots, x_n, 1)^t$ 称为增广的特征向量(齐次);
- $\mathbf{w} = (w_1, w_2, \dots, w_n, w_0)^t$ 称为增广的权向量。

两类问题线性判别准则

——线性判别分类器


$$g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} \begin{cases} > 0, & \mathbf{x} \in \omega_1 \\ < 0, & \mathbf{x} \in \omega_2 \\ = 0, & \text{拒识} \end{cases}$$

从两类到多类

多类问题（情况一）：一对多

- 每一类模式可以用一个超平面与其它类别分开；
- 这种情况可以把C个类别的多类问题分解为C个两类问题解决；

多类问题（情况一）



多类问题（情况一）判别规则

- 判别规则1



- 若存在 i ，使得 $g_i(x) > 0$ ， $g_j(x) < 0$ ， $j \neq i$ ，则判别 x 属于 ω_i 类；
- 其它情况，拒识。

- 判别规则2

- $i = \arg \max g_j(x)$ ，如果 $g_i(x)$ 大于某一预先设定的值 T ，则判别 x 属于 ω_i 类；
- 如果 $g_i(x)$ 小于等于某一预先设定的值 T ，拒识

多类问题（判别准则2）

- 不存在拒识区域。



多类问题（判别准则2）判别函数

- C个类别需要C个线性函数：

$$g_i(\mathbf{x}) = \mathbf{w}_i^t \mathbf{x} = w_{i1}x_1 + w_{i2}x_2 + \cdots + w_{in}x_n + w_{i0}$$

∨ 判别准则：


$$g_i(\mathbf{x}) = \max_{1 \leq j \leq C} \{g_j(\mathbf{x})\} \quad \mathbf{x} \in \omega_i$$

多类问题（情况二）：一对一

- 每两类之间可以用一个超平面分开，但是不能用来把其余类别分开；
- 需要将C个类别的多类问题转化为 $C(C-1)/2$ 个两类问题。
- 第i类与第j类之间的判别函数的为：

$$g_{ij}(\mathbf{x}) = \mathbf{w}_{ij}^t \mathbf{x} \quad i \neq j$$

多类问题（情况二）



多类问题（情况二）判别准则

- 判别准则1

- 如果对任意 $j \neq i$ ，有 $g_{ij}(\mathbf{x}) \geq 0$ ，则决策 $\mathbf{x}$ 属于 ω_i 。
- 其它情况，则拒识。

- 判别准则2

- $i = \arg \max_j \sum_{k=1, k \neq j}^C \text{sgn}(g_{jk}(\mathbf{x}))$
- 如果 $\sum_{k=1, k \neq j}^C \text{sgn}(g_{jk}(\mathbf{x}))$ 大于某一阈值 T ，则决策 $\mathbf{x}$ 属于 ω_i 。
- 其它情况，则拒识。

课外阅读：

- Ryan Rifkin, Aldebaro Klautau. In Defense of One-Vs-All Classification, JMLR, 2004.
 - A simple “one-vs-all” scheme is **as accurate as** any other approach, assuming that the underlying binary classifiers are well-tuned regularized classifiers.
- 情况一判别准则2

启示

- 基本问题：两类问题
- 多类问题
 - 可以转化为若干个两类问题
 - Reduction（约简）
 - 模式识别和机器学习中的一个重要概念
 - 针对某种学习算法，我们可能只会结合两类问题加以介绍，大家可以在实际应用中方便地推广到多类问题和复杂应用。
 - <http://hunch.net/~jl/projects/reductions/reductions.html>




两类线性判别函数的学习

- 判别分类器
 - 感知器算法
 - 支持向量机
- 判别学习
 - Logistic回归

Logistic回归

- 两类问题
 - 基本原理
 - 学习算法
- 多类问题
 - 自己解决



线性判别学习

- 以两类问题为例
- 判别学习的目标：后验概率

$$P(y = i | \mathbf{x}), i = 0, 1$$

- 分类器：

$$F(\mathbf{x}) = \log \left(\frac{P(y = 1 | \mathbf{x})}{P(y = 0 | \mathbf{x})} \right) \begin{cases} \geq 0, & \mathbf{x} \in \omega_1 \\ < 0, & \mathbf{x} \in \omega_0 \end{cases}$$

- 决策面： $F(\mathbf{x}) = 0$
- 线性判别学习（约束）
 - 决策面是一个（超）平面
 - 即：判别函数 $F(\mathbf{x})$ 是一个线性函数

$$F(\mathbf{x}) = \mathbf{w}^t \mathbf{x}$$

Logistic回归：两类问题

- 数据采用齐次（增广）表示形式
- 假设样本的后验概率为



$$P(y=1|\mathbf{x}) = \frac{\exp(\mathbf{w}^t \mathbf{x})}{1 + \exp(\mathbf{w}^t \mathbf{x})}$$

$$P(y=0|\mathbf{x}) = \frac{1}{1 + \exp(\mathbf{w}^t \mathbf{x})}$$

- 则判别函数


$$F(\mathbf{x}) = \log \left(\frac{P(y=1|\mathbf{x})}{P(y=0|\mathbf{x})} \right) = \mathbf{w}^t \mathbf{x}$$

Logistic 回归



$$Pr(w|\phi, \mathbf{x}) = \text{Bern}_w \left[\frac{1}{1 + \exp[-\phi^T \mathbf{x}]} \right]$$

Logistic函数图示



目标函数

- 最大似然法 (ML)

- 训练样本

$$X : \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_i, \dots, \mathbf{x}_N\}$$

$$Y : \{y_1, y_2, \dots, y_i, \dots, y_N\}, \text{ } y_i \in \{0, 1\}$$

- 似然函数

$$L(\mathbf{w}) = \prod_{i=1}^N P(y_i \mid \mathbf{x}_i, \mathbf{w})$$

目标函数

- 最大似然估计
- 对数似然函数

$$\begin{aligned}\log(L(\mathbf{w})) &= \sum_{i=1}^N \log(P(y_i | \mathbf{x}_i, \mathbf{w})) \\ &= \sum_{i=1}^N \left\{ y_i \mathbf{w}^t \mathbf{x}_i - \log[1 + \exp(\mathbf{w}^t \mathbf{x}_i)] \right\}\end{aligned}$$

- 学习问题

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} \log(L(\mathbf{w}))$$

矩阵和向量导数

$$\frac{\partial(\mathbf{b}^T \mathbf{a})}{\partial \mathbf{a}} = \mathbf{b}$$

$$\frac{\partial(\mathbf{a}^T \mathbf{A} \mathbf{a})}{\partial \mathbf{a}} = (\mathbf{A} + \mathbf{A}^T) \mathbf{a}$$

$$\frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{B} \mathbf{A}) = \mathbf{B}^T$$

$$\frac{\partial}{\partial \mathbf{A}} \log |\mathbf{A}| = \mathbf{A}^{-T} \triangleq (\mathbf{A}^{-1})^T$$

$$\text{tr}(\mathbf{A} \mathbf{B} \mathbf{C}) = \text{tr}(\mathbf{C} \mathbf{A} \mathbf{B}) = \text{tr}(\mathbf{B} \mathbf{C} \mathbf{A})$$

- <https://www.math.uwaterloo.ca/~hwolkowi/matrixcookbook.pdf>

学习算法

- 最优化条件

$$\begin{aligned}\frac{\partial \log(L(\mathbf{w}))}{\partial \mathbf{w}} &= \sum_{i=1}^N \mathbf{x}_i \left\{ y_i - \frac{\exp(\mathbf{w}^t \mathbf{x}_i)}{1 + \exp(\mathbf{w}^t \mathbf{x}_i)} \right\} \\ &= \sum_{i=1}^N \mathbf{x}_i \{ y_i - P(y = 1 | \mathbf{x}_i) \} = 0\end{aligned}$$

- 无法直接求解上述方程

学习算法：Newton–Raphson算法

- 一阶导数： $p_i = P(y = 1 | \mathbf{x}_i)$

$$\frac{\partial \log(L(\mathbf{w}))}{\partial \mathbf{w}} = \sum_{i=1}^N \mathbf{x}_i \{y_i - P(y = 1 | \mathbf{x}_i)\} = \sum_{i=1}^N \mathbf{x}_i (y_i - p_i),$$

- 二阶导数

$$\frac{\partial^2 \log(L(\mathbf{w}))}{\partial \mathbf{w} \partial \mathbf{w}^t} = - \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^t p_i (1 - p_i)$$

- 更新规则

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(k)} + \left(\frac{\partial^2 \log(L(\mathbf{w}))}{\partial \mathbf{w} \partial \mathbf{w}^t} \right)^{-1} \frac{\partial \log(L(\mathbf{w}))}{\partial \mathbf{w}}$$

Newton–Raphson算法：矩表示

- 一阶导数： $\mathbf{X}$ ($N * (d+1)$ 矩阵), $\mathbf{p}$ ($N*1$ 向量)

$$\frac{\partial \log(L(\mathbf{w}))}{\partial \mathbf{w}} = \mathbf{X}^t (\mathbf{y} - \mathbf{p})$$

- 二阶导数： $\mathbf{W}$ (对角矩阵, $\mathbf{W}_{ii} = \mathbf{p}_i(1-\mathbf{p}_i)$)

$$\frac{\partial^2 \log(L(\mathbf{w}))}{\partial \mathbf{w} \partial \mathbf{w}^t} = -\mathbf{X}^t \mathbf{W} \mathbf{X}$$

- 更新规则

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(k)} + \left(\mathbf{X}^t \mathbf{W} \mathbf{X} \right)^{-1} \mathbf{X}^t (\mathbf{y} - \mathbf{p})$$

注释/思考

- 矩阵的上界？

$$-\frac{\partial^2 \log(L(\mathbf{w}))}{\partial \mathbf{w} \partial \mathbf{w}^t} = \mathbf{X}^t \mathbf{W} \mathbf{X}$$

- 意义何在？
 - 收敛速度
 - 实际计算复杂度

多类问题

$$P(y = 1|\mathbf{x}) = \frac{\exp(\mathbf{w}_1^t \mathbf{x})}{1 + \sum_{i=1}^{C-1} \exp(\mathbf{w}_i^t \mathbf{x})}$$

$$P(y = 2|\mathbf{x}) = \frac{\exp(\mathbf{w}_1^t \mathbf{x})}{1 + \sum_{i=1}^{C-1} \exp(\mathbf{w}_i^t \mathbf{x})}$$

•
•
•

$$P(y = C|\mathbf{x}) = \frac{1}{1 + \sum_{i=1}^{C-1} \exp(\mathbf{w}_i^t \mathbf{x})}$$

多类问题

$$\log \frac{P(y=1|\mathbf{x})}{P(y=C|\mathbf{x})} = \mathbf{w}_1^t \mathbf{x}$$

$$\log \frac{P(y=2|\mathbf{x})}{P(y=C|\mathbf{x})} = \mathbf{w}_2^t \mathbf{x}$$

•
•
•

$$\log \frac{P(y=C-1|\mathbf{x})}{P(y=C|\mathbf{x})} = \mathbf{w}_{C-1}^t \mathbf{x}$$

作业

- 请推导并给出多类logistic回归的学习算法。
- 如果有什么问题，可以参考以下材料：
 - C. Bishop, Pattern Recognition and Machine Learning, Springer, 2008. (pp. 209 - 210)

进一步阅读

- Trevor Hastie, Robert Tibshirani, Jerome Friedman, 《统计学习基础——数据挖掘、推理和预测》，电子工业出版社，2004
- 阅读pp. **67-71**

应用：鸢尾属(Iris)植物分类

- (Anderson 1935)

150种鸢尾属植物 (每类50种):

u 类别(Species): setosa, versicolor, virginica;

特征:

u 萼片(sepals)的长度和宽度 (cm);

u 花瓣(petals)的长度和宽度 (cm);



iris setosa



iris versicolor




iris virginica


数据

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.10	3.50	1.40	0.20	setosa
2	4.90	3.00	1.40	0.20	setosa
3	4.70	3.20	1.30	0.20	setosa
4	4.60	3.10	1.50	0.20	setosa
5	5.00	3.60	1.40	0.20	setosa
:	:	:	:	:	
51	7.00	3.20	4.70	1.40	versicolor
52	6.40	3.20	4.50	1.50	versicolor
53	6.90	3.10	4.90	1.50	versicolor
54	5.50	2.30	4.00	1.30	versicolor
:	:	:	:	:	
101	6.30	3.30	6.00	2.50	virginica
102	5.80	2.70	5.10	1.90	virginica
103	7.10	3.00	5.90	2.10	virginica
104	6.30	2.90	5.60	1.80	virginica
105	6.50	3.00	5.80	2.20	virginica
:	:	:	:	:	
150	5.90	3.00	5.10	1.80	virginica


数据的可视化



分类结果




分类结果




模式识别的贝叶斯观点 (1)

- 基于贝叶斯准则来训练决策函数



- 决策函数的概率解释




最大似然估计

- Logistic回归
 - 重点：参数 $\mathbf{w}$ 的估计
- 最大似然估计

$$\begin{aligned}\hat{\mathbf{w}} &= \arg \max_{\mathbf{w}} \log(L(\mathbf{w})) = \sum_{i=1}^N \log(P(y_i | \mathbf{x}_i, \mathbf{w})) \\ &= \sum_{i=1}^N \left\{ y_i \mathbf{w}^t \mathbf{x} - \log[1 + \exp(\mathbf{w}^t \mathbf{x})] \right\}\end{aligned}$$

The Important of Prior

- Logistic regression (ML估计) fails on linear separable problems



贝叶斯(最大后验概率估计)

- 假设参数 $\mathbf{w}$ 的先验服从正态分布

$$P(\mathbf{w}) = \left(\frac{\sqrt{\lambda}}{2\pi} \right)^n \exp \left(-\frac{\lambda \mathbf{w}^t \mathbf{w}}{2} \right)$$

- 则有

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^N \left\{ \log[1 + \exp(\mathbf{w}^t \mathbf{x})] - y_i \mathbf{w}^t \mathbf{x} \right\} + \frac{\lambda}{2} \mathbf{w}^t \mathbf{w}$$

Newton–Raphson算法：矩表示

- 一阶导数： $\mathbf{X}$ ($N * (d+1)$ 矩阵)， $\mathbf{p}$ ($N*1$ 向量)


$$\frac{\partial \log(L(\mathbf{w}))}{\partial \mathbf{w}} = -\mathbf{X}^t (\mathbf{y} - \mathbf{p}) + \lambda \mathbf{w}$$

- 二阶导数： $\mathbf{W}$ (对角矩阵, $\mathbf{W}_{ii} = p_i(1-p_i)$)

$$\frac{\partial^2 \log(L(\mathbf{w}))}{\partial \mathbf{w} \partial \mathbf{w}^t} = \mathbf{X}^t (\mathbf{W}) \mathbf{X} + \lambda \mathbf{I}$$

- 更新规则

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(k)} + \left(\mathbf{X}^t (\mathbf{W}) \mathbf{X} + \lambda \mathbf{I} \right)^{-1} \left[\mathbf{X}^t (\mathbf{y} - \mathbf{p}) - \lambda \mathbf{w} \right]$$



END