

模式识别与机器学习 (5)

贝叶斯学习基础

左旺孟

哈尔滨工业大学计算机学院
机器学习研究中心
综合楼712


cswmzuo@gmail.com

13134506692




模式识别的贝叶斯观点 (1)

- 基于贝叶斯准则来训练决策函数



- 决策函数的概率解释



分类器

$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^2 P(\mathbf{x}|\omega_j)P(\omega_j)}$$

3. 贝叶斯学习：根据训练样本对类别先验概率和类条件概率进行建模，并进一步构建分类器

$$\begin{cases} \text{如果 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_2 \end{cases}$$

$$F(\mathbf{x}) = \log \left(\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} \right) \begin{cases} \geq 0, & \mathbf{x} \in \omega_1 \\ < 0, & \mathbf{x} \in \omega_2 \end{cases}$$

2. 判别学习：根据训练样本对类别后验概率进行建模判别函数：

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$$

1. 判别函数：根据训练样本学习直接学习函数 $F(\mathbf{x})$

判别函数： $g(\mathbf{x}) = F(\mathbf{x})$

Logistic回归：两类问题

- 数据采用齐次（增广）表示形式
- 假设样本的后验概率为

$$P(y=1|\mathbf{x}) = \frac{\exp(\mathbf{w}^t \mathbf{x})}{1 + \exp(\mathbf{w}^t \mathbf{x})}$$

$$P(y=0|\mathbf{x}) = \frac{1}{1 + \exp(\mathbf{w}^t \mathbf{x})}$$

- 则判别函数

$$F(\mathbf{x}) = \log \left(\frac{P(y=1|\mathbf{x})}{P(y=0|\mathbf{x})} \right) = \mathbf{w}^t \mathbf{x}$$

目标函数

- 最大似然法 (ML)

- 训练样本

$$X : \{\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_i, \cdots, \mathbf{x}_N\}$$

$$Y : \{y_1, y_2, \cdots, y_i, \cdots, y_N\}, \quad y_i \in \{0, 1\}$$

- 似然函数


$$L(\mathbf{w}) = \prod_{i=1}^N P(y_i \mid \mathbf{x}_i, \mathbf{w})$$

学习内容：贝叶斯学习基础


- 1. 参数估计
 - 最大似然估计 (ML)
 - 最大化后验估计 (贝叶斯估计)
 - 完全贝叶斯估计
- 2. 非参数估计
- 3. 朴素贝叶斯分类器
- 4. 隐马尔可夫模型
- ...

} 应用

参数估计



非参数估计



1. 参数估计

- 问题的提出

$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^2 P(\mathbf{x}|\omega_j)P(\omega_j)}$$

- 最大似然估计
- 最大化后验概率估计
- 完全贝叶斯估计

1.1 最大似然估计

- 样本集 $\mathbf{D}$ 中包含 n 个样本： $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ ，样本都是独立同分布的随机变量(i.i.d, independent identically distributed)。
- 对类条件概率密度函数的函数形式作出假设，参数可以表示为参数矢量 θ ：

$$p(\mathbf{x}|\omega_i; \theta_i)$$

似然函数

- 由独立同分布假设，样本集 $\mathbf{D}$ 出现的概率为：

$$p(D|\boldsymbol{\theta}) = p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n | \boldsymbol{\theta}) = \prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta})$$

- 定义对数似然函数：

$$l(\boldsymbol{\theta}) = \ln p(D|\boldsymbol{\theta}) = \sum_{i=1}^n \ln p(\mathbf{x}_i | \boldsymbol{\theta})$$

最大似然估计

- 最大似然估计就是要寻找到一个最优向量 $\hat{\theta}$ ，使得（对数）似然函数 $l(\theta)$ 最大。

$$\hat{\theta} = \arg \max_{\theta} l(\theta)$$

最大似然估计

- 已知： X 的概率密度函数 $f(x; \theta)$ 和一组样本观测值 $x_1, x_2, \dots, x_n$ ，其中 θ 为未知参数
- 问题：估计参数 θ
- 定义似然函数 $L(\theta) \equiv L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$
- 最大似然估计 $\hat{\theta} = \arg \max [\ln L(\theta)]$
- 求解方法：优化问题，如果满足特定优化条件的话，可以考虑

$$\frac{\partial}{\partial \theta} \ln L(\theta) = 0$$

例1

- 假设手写数字样本满足正态分布，使用最小错误率贝叶斯分类器进行识别，采用降维后的样本；
- 正态分布最大似然估计结果为：

$$\hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\boldsymbol{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^t$$

最大似然估计：例子

- 给定样本观测值 $x_1, x_2, \dots, x_n$ ，如果服从的正态分布 $N(\theta, 1)$ ，使用最大似然法估计 θ 。
- 定义似然函数

$$L(\theta) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}} e^{-(1/2)(x_i - \theta)^2} = \frac{1}{(2\pi)^{n/2}} e^{-(1/2) \sum_{i=1}^n (x_i - \theta)^2}$$

- 估计 θ

$$\frac{\partial}{\partial \theta} \ln L(\theta) = \sum_{i=1}^n (x_i - \theta) = 0$$

$$\Rightarrow \hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i$$

思考

- 请证明正态分布中协方差的最大似然估计结果为

$$\mathbf{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^t$$

以及上述解是全局最优解。

(可以假设均值已知。)

最大似然估计：讨论

- 具有良好的理论支持
- 当似然函数较复杂时，会存在局部最优问题
- 在某些情况下，尤其是样本容量较小的情况下，参数估计结果不稳定
- 最大化后验概率估计：如果估计参数服从一定的先验分布

1.2 最大后验概率估计（贝叶斯估计）

- 已有独立同分布训练样本集 D ;
- 已知类条件概率密度函数 $p(\mathbf{x} | \theta)$ 的形式, 但参数 θ 未知;
- 已知参数 θ 的先验概率密度函数 $p(\theta)$;
- 参数估计 $\hat{\theta} = \arg \max [\ln (p(\theta | D))]$

$$p(\theta | D) = \frac{p(D | \theta)p(\theta)}{p(D)}$$

单变量正态分布的贝叶斯估计

- 已知概率密度函数满足正态分布，其中方差 σ^2 已知，均值 μ 未知，假设 μ 的先验概率满足正态分布，即：

$$p(x|\mu) \sim N(\mu, \sigma^2)$$

$$p(\mu) \sim N(\mu_0, \sigma_0^2)$$

均值的后验概率

经推导可得，在已知训练样本集合**D**的条件下，参数 μ 的分布：

$$\begin{aligned} p(\mu|D) &= \frac{p(D|\mu)p(\mu)}{\int p(D|\mu)p(\mu)d\mu} = \alpha \prod_{i=1}^n p(x_i|\mu)p(\mu) \\ &= \alpha'' \exp \left[-\frac{1}{2} \left[\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \mu^2 - 2 \left(\frac{1}{\sigma^2} \sum_{i=1}^n x_i + \frac{\mu_0}{\sigma_0^2} \right) \mu \right] \right] \\ &= \frac{1}{\sqrt{2\pi}\sigma_n} \exp \left[-\frac{1}{2} \left(\frac{\mu - \mu_n}{\sigma_n} \right)^2 \right] \end{aligned}$$

均值的最大化后验概率估计

$$\hat{\theta} = \arg \max [\ln (L(\theta) p(\theta))]$$


均值的后验概率仍满足正态分布，其中：

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\mu_n = \left(\frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \right) \hat{\mu}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0$$

$$\sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2}$$

均值分布的变化



应用：图像复原

- 很多应用中，往往存在样本数目不足的情形


- 噪声图像

$$\mathbf{y} = \mathbf{x} + n$$

- 退化图像

$$\mathbf{y} = \mathbf{A}\mathbf{x} + n$$

- 图像复原问题中，待估计的参数往往和样本数相同或更多。



最大似然估计

- 条件概率

$$P(\mathbf{y} | \mathbf{x}) = (2\pi\sigma)^{-mn/2} \exp\left(-\frac{\|\mathbf{Ax} - \mathbf{y}\|^2}{2\sigma^2}\right)$$

- 最大似然估计


$$-\ln P(\mathbf{y} | \mathbf{x}) = \frac{\|\mathbf{Ax} - \mathbf{y}\|^2}{2\sigma^2} + C$$

- 如果 $\mathbf{A}$ 不可逆，最大似然估计有无穷多解
- 对于去噪问题， $\mathbf{A} = \mathbf{I}$ ，ML只能得到平凡解 $\mathbf{x} = \mathbf{y}$ ，不能去除噪声

最大后验概率估计

- 先验概率

$$p(\nabla x) = \frac{\gamma \lambda^{(\frac{1}{\gamma})}}{2\Gamma(\frac{1}{\gamma})} \exp(-\lambda \|\nabla x\|^\gamma)$$



最大后验概率估计

$$P(\mathbf{x} | \mathbf{y}) \propto P(\mathbf{y} | \mathbf{x})P(\nabla \mathbf{x})$$

$$= (2\pi\sigma)^{-mn/2} \exp\left(-\frac{\|\mathbf{Ax} - \mathbf{y}\|^2}{2\sigma^2}\right) \times \frac{\gamma\lambda^{\frac{1}{\gamma}}}{2\Gamma\left(\frac{1}{\gamma}\right)} \exp\left(-\lambda\|\nabla \mathbf{x}\|^\gamma\right)$$


$$-\ln(P(\mathbf{y} | \mathbf{x})P(\nabla \mathbf{x})) = \frac{1}{2}\|\mathbf{Ax} - \mathbf{y}\|^2 + \mu\|\nabla \mathbf{x}\|^\gamma \quad \mu = \sigma^2\lambda$$

$$\arg \max_{\mathbf{x}} P(\mathbf{x} | \mathbf{y}) \Leftrightarrow \arg \min_{\mathbf{x}} (-\ln(P(\mathbf{y} | \mathbf{x})P(\nabla \mathbf{x})))$$

$$\Leftrightarrow \arg \min_{\mathbf{x}} \left(\frac{1}{2}\|\mathbf{Ax} - \mathbf{y}\|^2 + \mu\|\nabla \mathbf{x}\|^\gamma \right)$$

实验结果

Blurred
SNR=2.64



Ours $\alpha=2/3$
SNR=14.15
 $t=1.2$



1.3 完全贝叶斯估计

- 各种估计方法的一致性
 - 随着样本容量的增加
- MAP估计

$$\hat{\theta} = \arg \max [\ln(p(\theta | D))]$$

- 完全贝叶斯估计
 - 后验分布
 - 均值
 - 方差

$$\hat{\theta} = E[\theta | D] = \int_{\theta} \theta \frac{p(D | \theta) p(\theta)}{\int_{\theta'} p(D | \theta') p(\theta') d\theta'} d\theta$$

参数估计方法：实例

- 已知 $\mathbf{x}$ 服从概率分布 $p(\mathbf{x}|\boldsymbol{\theta})$
 - 给定样本 $D = \{x_1, x_2, \dots, x_N\}$, 估计参数 $\boldsymbol{\theta}$
 - 估计结果 $\boldsymbol{\theta}^*$
 - 优化参数
 - 参数的后验分布 $P(\boldsymbol{\theta} | D)$
- 二项分布和伯努利分布
- 高斯分布

二值变量 (1)

- 掷硬币: 正面=1, 反面=0

$$p(x = 1 | \mu) = \mu$$

- 泊努利分布 (**Bernoulli**)

$$\text{Bern}(x | \mu) = \mu^x (1 - \mu)^{1-x}$$

$$\mathbb{E}[x] = \mu$$

$$\text{var}[x] = \mu(1 - \mu)$$



二值变量 (2)

- (独立) 掷 N 次硬币:

$$p(m \text{ heads} | N, \mu)$$


- 二项分布 (**Binomial**)

$$\text{Bin}(m | N, \mu) = \binom{N}{m} \mu^m (1 - \mu)^{N-m}$$

$$\mathbb{E}[m] \equiv \sum_{m=0}^N m \text{Bin}(m | N, \mu) = N\mu$$

$$\text{var}[m] \equiv \sum_{m=0}^N (m - \mathbb{E}[m])^2 \text{Bin}(m | N, \mu) = N\mu(1 - \mu)$$

二项分布



最大似然估计: 二项分布(1)

- 给定样本观测值 $x_1, x_2, \dots, x_N$, 如果服从的泊努利分布 $B(\mu)$, 使用最大似然法估计 μ (假设共有 m 个1和 l 个0, $m+l=N$)。

- 定义似然函数
$$p(\mathcal{D}|\mu) = \prod_{n=1}^N p(x_n|\mu) = \prod_{n=1}^N \mu^{x_n} (1 - \mu)^{1-x_n}$$

$$\ln p(\mathcal{D}|\mu) = \sum_{n=1}^N \ln p(x_n|\mu) = \sum_{n=1}^N \{x_n \ln \mu + (1 - x_n) \ln(1 - \mu)\}$$

- 估计 μ
$$\frac{\partial}{\partial \mu} \ln L(\mu) = \sum_{n=1}^N (x_n / \mu + (1 - x_n) / (1 - \mu)) = 0$$
$$\Rightarrow \hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$$

最大似然估计: 二项分布(2)

- 假设有: $\mathcal{D} = \{1, 1, 1\} \rightarrow \mu_{\text{ML}} = \frac{3}{3} = 1$
- 即: 所有的硬币将都是正面
- 原因
 - 过拟合
 - 样本数量太小

贝叶斯估计：预备知识

- **Beta分布**
- 取值范围 $\mu \in [0, 1]$.

$$\text{Beta}(\mu|a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1}$$

$$\mathbb{E}[\mu] = \frac{a}{a+b}$$

$$\text{var}[\mu] = \frac{ab}{(a+b)^2(a+b+1)}$$

贝叶斯参数估计：伯努利





$$\begin{aligned} p(\mu|a_0, b_0, \mathcal{D}) &\propto p(\mathcal{D}|\mu)p(\mu|a_0, b_0) \\ &= \left(\prod_{n=1}^N \mu^{x_n} (1 - \mu)^{1-x_n} \right) \text{Beta}(\mu|a_0, b_0) \\ &\propto \mu^{m+a_0-1} (1 - \mu)^{(N-m)+b_0-1} \\ &\propto \text{Beta}(\mu|a_N, b_N) \end{aligned}$$

$$a_N = a_0 + m \quad b_N = b_0 + (N - m)$$




假设 μ 服从先验分布Beta分布.

➤ 增量学习

Beta分布



先验 · 似然 = 后验



后验概率分析

随着数据集大小 N 的增加,


$$a_N \rightarrow m$$

$$b_N \rightarrow N - m$$


$$\mathbb{E}[\mu] = \frac{a_N}{a_N + b_N} \rightarrow \frac{m}{N} = \mu_{\text{ML}}$$

$$\text{var}[\mu] = \frac{a_N b_N}{(a_N + b_N)^2 (a_N + b_N + 1)} \rightarrow 0$$

正态（高斯）分布



$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$



$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$


多变量高斯分布的几何表示

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

$$\boldsymbol{\Sigma}^{-1} = \sum_{i=1}^D \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T$$

$$\Delta^2 = \sum_{i=1}^D \frac{y_i^2}{\lambda_i}$$

$$y_i = \mathbf{u}_i^T (\mathbf{x} - \boldsymbol{\mu})$$



均值

$$\begin{aligned}\mathbb{E}[\mathbf{x}] &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \int \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\} \mathbf{x} d\mathbf{x} \\ &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \int \exp \left\{ -\frac{1}{2}\mathbf{z}^T \boldsymbol{\Sigma}^{-1}\mathbf{z} \right\} (\mathbf{z} + \boldsymbol{\mu}) d\mathbf{z}\end{aligned}$$




考虑到函数的对称性,

$$\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu}$$

方差

$$\mathbb{E}[\mathbf{x}\mathbf{x}^T] = \boldsymbol{\mu}\boldsymbol{\mu}^T + \boldsymbol{\Sigma}$$

$$\text{COV}[\mathbf{x}] = \mathbb{E} [(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^T] = \boldsymbol{\Sigma}$$



最大似然法：高斯分布

- 给定i.i.d. 数据 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)^T$, 其对数似然函数为:

$$\ln p(\mathbf{X}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu})$$

- 充分统计量

$$\sum_{n=1}^N \mathbf{x}_n$$

$$\sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^T$$

最大似然法：高斯分布

- 令其对数似然函数求导,

$$\frac{\partial}{\partial \boldsymbol{\mu}} \ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{n=1}^N \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}) = 0$$

- 求解上式

$$\boldsymbol{\mu}_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n.$$

- 类似有

$$\boldsymbol{\Sigma}_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})(\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})^{\text{T}}.$$

无偏估计

估计值

$$\begin{aligned}\mathbb{E}[\boldsymbol{\mu}_{\text{ML}}] &= \boldsymbol{\mu} \\ \mathbb{E}[\boldsymbol{\Sigma}_{\text{ML}}] &= \frac{N-1}{N} \boldsymbol{\Sigma}.\end{aligned}$$

无偏估计

$$\tilde{\boldsymbol{\Sigma}} = \frac{1}{N-1} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})(\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})^{\text{T}}.$$

增量解释

最后一个（第N个）样本 $\mathbf{x}_N$ ，的贡献：

$$\mu_{\text{ML}}^{(N)} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$

$$= \frac{1}{N} \mathbf{x}_N + \frac{1}{N} \sum_{n=1}^{N-1} \mathbf{x}_n$$

$$= \frac{1}{N} \mathbf{x}_N + \frac{N-1}{N} \mu_{\text{ML}}^{(N-1)}$$

$$= \underbrace{\mu_{\text{ML}}^{(N-1)}}_{\text{old estimate}} + \underbrace{\frac{1}{N} (\mathbf{x}_N - \mu_{\text{ML}}^{(N-1)})}_{\text{correction given } \mathbf{x}_N}$$

correction given $\mathbf{x}_N$

correction weight

old estimate

贝叶斯估计：一维情况

- 假设 方差 已知. 给定i.i.d. 数据 $\mathbf{x} = \{x_1, \dots, x_N\}$ 似然函数为,

$$p(\mathbf{x}|\mu) = \prod_{n=1}^N p(x_n|\mu) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 \right\}.$$

贝叶斯估计：一维情况

- 假设 μ 的先验服从正态分布

$$p(\mu) = \mathcal{N}(\mu | \mu_0, \sigma_0^2).$$

- 则后验为

$$p(\mu | \mathbf{x}) \propto p(\mathbf{x} | \mu) p(\mu).$$

- 代入可得

$$p(\mu | \mathbf{x}) = \mathcal{N}(\mu | \mu_N, \sigma_N^2)$$

贝叶斯估计：一维情况

- 接上页，其中

$$\mu_N = \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 + \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} \mu_{\text{ML}},$$

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n$$

$$\frac{1}{\sigma_N^2} = \frac{1}{\sigma_0^2} + \frac{N}{\sigma^2}.$$


- Note:**

	$N = 0$	$N \rightarrow \infty$
μ_N	μ_0	μ_{ML}
σ_N^2	σ_0^2	0

贝叶斯估计：例示

- 例子：N = 0, 1, 2 和 10时的后验分布

$$p(\mu|\mathbf{x}) = \mathcal{N}(\mu|\mu_N, \sigma_N^2)$$



贝叶斯估计：增量解释

$$\begin{aligned} p(\mu|\mathbf{x}) &\propto p(\mu)p(\mathbf{x}|\mu) \\ &= \left[p(\mu) \prod_{n=1}^{N-1} p(x_n|\mu) \right] p(x_N|\mu) \\ &\propto \underbrace{\mathcal{N}(\mu|\mu_{N-1}, \sigma_{N-1}^2)}_{\text{新的先验}} p(x_N|\mu) \end{aligned}$$

贝叶斯估计 (方差)

- 假设 μ 已知. 方差参数的似然函数如下:

$$p(\mathbf{x}|\lambda) = \prod_{n=1}^N \mathcal{N}(x_n|\mu, \lambda^{-1}) \propto \lambda^{N/2} \exp \left\{ -\frac{\lambda}{2} \sum_{n=1}^N (x_n - \mu)^2 \right\}.$$




- 为使用贝叶斯方法来估计方差参数, 我们需要一种新的先验: **Gamma先验**

贝叶斯估计 (方差)

- Gamma分布（共轭先验：**Conjugate Prior**）

$$\text{Gam}(\lambda|a, b) = \frac{1}{\Gamma(a)} b^a \lambda^{a-1} \exp(-b\lambda)$$

$$\mathbb{E}[\lambda] = \frac{a}{b} \quad \text{var}[\lambda] = \frac{a}{b^2}$$



贝叶斯估计 (方差)

- 结合**Gamma**先验 $\text{Gam}(\lambda|a_0, b_0)$ 和似然函数, 可以得到后验分布

$$p(\lambda|\mathbf{x}) \propto \lambda^{a_0-1} \lambda^{N/2} \exp \left\{ -b_0 \lambda - \frac{\lambda}{2} \sum_{n=1}^N (x_n - \mu)^2 \right\}$$

- 上式仍可以认为是一种**Gamma**分布 $\text{Gam}(\lambda|a_N, b_N)$

$$a_N = a_0 + \frac{N}{2}$$

$$b_N = b_0 + \frac{1}{2} \sum_{n=1}^N (x_n - \mu)^2 = b_0 + \frac{N}{2} \sigma_{\text{ML}}^2.$$

$$E(1/\sigma^2) = \frac{b_0 + \frac{\sigma_{\text{ML}}^2}{2}}{a_0 + \frac{N}{2}}$$

同时估计均值和方差

- 如果 μ 和 λ 都未知, 其联合似然函数为

$$p(\mathbf{x}|\mu, \lambda) = \prod_{n=1}^N \left(\frac{\lambda}{2\pi}\right)^{1/2} \exp\left\{-\frac{\lambda}{2}(x_n - \mu)^2\right\}$$
$$\propto \left[\lambda^{1/2} \exp\left(-\frac{\lambda\mu^2}{2}\right)\right]^N \exp\left\{\lambda\mu \sum_{n=1}^N x_n - \frac{\lambda}{2} \sum_{n=1}^N x_n^2\right\}.$$

- 我们需要引入新 μ 和 λ 的先验: ...

同时估计均值和方差

- **Gaussian-gamma 分布**

$$p(\mu, \lambda) = \mathcal{N}(\mu | \mu_0, (\beta\lambda)^{-1}) \text{Gam}(\lambda | a, b)$$
$$\propto \underbrace{\exp \left\{ -\frac{\beta\lambda}{2} (\mu - \mu_0)^2 \right\}}_{\text{• } \mu \text{ 的二次项.}} \underbrace{\lambda^{a-1} \exp \{ -b\lambda \}}_{\text{• } \lambda \text{ 的一次项.}}$$

- μ 的二次项.
- λ 的一次项.
- λ 服从 Gamma 分布.
- 和 μ 独立

贝叶斯估计与最大似然估计的差别

- 最大似然估计认为 θ 是一个确定的未知向量；
 - 频率学派
- 贝叶斯估计认为 θ 是一个随机变量，以一定的概率分布取所有可能的值。
 - 贝叶斯学派
 - 最大后验概率：求对应于最大概率的 θ
 - 求 θ 的均值
 - 求 θ 的分布

贝叶斯估计的一般理论

- 求在已有训练样本集 D 的条件下，类条件概率密度函数 $p(\mathbf{x}|D)$ 。
- 由于参数向量 θ 是一个随机变量，所以类条件概率可以用下式计算：

$$p(\mathbf{x}|D) = \int p(\mathbf{x}, \theta|D) d\theta = \int p(\mathbf{x}|\theta) p(\theta|D) d\theta$$

- 根据贝叶斯公式，有：

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{\int p(D|\theta)p(\theta)d\theta} = \frac{\prod_{i=1}^n p(\mathbf{x}_i|\theta)p(\theta)}{\int \prod_{i=1}^n p(\mathbf{x}_i|\theta)p(\theta)d\theta}$$

贝叶斯估计小结

- 贝叶斯 vs. 最大似然
 - 一致性
 - 增量解释
- 选择适当的先验分布
 - 真实性
 - 可计算性（共轭先验：**Conjugate Prior**）
- 其它参数估计方法：变分贝叶斯 ...

学习内容：贝叶斯学习基础


- 1. 参数估计
 - 最大似然估计 (ML)
 - 最大化后验估计 (贝叶斯估计)
 - 完全贝叶斯估计
- 2. 非参数估计
- 3. 朴素贝叶斯分类器
- 4. 隐马尔可夫模型
- ...

} 应用


2. 非参数估计

- 真实的概率分布往往十分复杂，真实的概率分布往往不符合简单的参数模型。
 - 更有弹性的概率分布描述方式：能够处理任意的概率分布；
 - 从局部到整体的思想

- 灰度直方图
 - 1D



非参数估计



基本思想

- 令 R 是包含样本点 $\mathbf{x}$ 的一个区域，其体积为 V ，设有 n 个训练样本，其中有 k 个落在区域 R 中的样本，则可对概率密度作出一个估计：

$$p(\mathbf{x}) \approx \frac{k/n}{V}$$

- 相当于用 R 区域内的平均性质来作为一点 $\mathbf{x}$ 的估计，是一种数据的平滑。

有效性

- 当 n 固定时， V 的大小对估计的效果影响很大，过大则平滑过多，不够精确；过小则可能导致在此区域内无样本点， $k = 0$ 。
- 此方法的有效性取决于样本数量的多少，以及区域体积选择的合适。

收敛性

- 构造一系列包含 $\mathbf{x}$ 的区域 $R_1, R_2, \dots$, 对应 $n=1, 2, \dots$, 则对 $p(\mathbf{x})$ 有一系列的估计:

$$p_n(\mathbf{x}) = \frac{k_n/n}{V_n}$$

- 当满足下列条件时, $p_n(\mathbf{x})$ 收敛于 $p(\mathbf{x})$:

$$\lim_{n \rightarrow \infty} V_n = 0$$

$$\lim_{n \rightarrow \infty} k_n \rightarrow \infty$$

$$\lim_{n \rightarrow \infty} \frac{k_n}{n} = 0$$

区域选定的两个途径


- Parzen窗法：区域体积 V 是样本数 n 的函数，如：

$$V_n = \frac{1}{\sqrt{n}}$$

- K-近邻法：落在区域内的样本数 k 是总样本数 n 的函数，如：

$$k_n = \sqrt{n}$$

Parzen窗法和K-近邻法



Parzen窗方法

- 定义窗函数


$$\varphi(\mathbf{u}) = \begin{cases} 1, & |u_j| \leq 1/2 \\ 0, & \text{其它} \end{cases}$$

- 多尺度形式:

$$\varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right) = \begin{cases} 1/V_n, & |x_j - x_{ij}| \leq h_n/2 \\ 0, & \text{其它} \end{cases}$$

$$V_n = h_n^d \quad j = 1, \dots, d$$

1维数据的窗函数



概率密度函数的估计

- 超立方体中的样本数：

$$k_n = \sum_{i=1}^n \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right)$$

- 概率密度估计：

$$p_n(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \frac{1}{V_n} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right)$$




窗函数的要求

- 上述过程是一个内插过程，样本 $\mathbf{x}_i$ 距离 $\mathbf{x}$ 越近，对概率密度估计的贡献越大，越远贡献越小。
- 只要满足如下条件，就可以作为窗函数：

$$\varphi(\mathbf{u}) \geq 0$$


$$\int \varphi(\mathbf{u}) d\mathbf{u} = 1$$

窗函数的形式




窗函数的宽度对估计的影响（Gaussian分布）

- h_n 称为窗的宽度




窗函数的宽度对估计的影响





k_n -近邻法

- K_n : 是一个 n 的函数, 随着 n 的增加而增加
 - 如 $k_n = \sqrt{n}$
 - 以 $\mathbf{x}$ 为中心, 让 V_n 扩张直至包括 k_n 个样本。
- 概率密度估计

$$p_n(\mathbf{x}) = \frac{k_n/n}{V_n}$$

k_n -近邻法

Curse of Dimensionality (维数灾难)



作业


- 证明

$$p_n(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \frac{1}{V_n} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right)$$

是一个概率密度函数。

证明思路： $p_n(\mathbf{x}) \geq 0$

$$\int p_n(\mathbf{x}) d\mathbf{x} = 1$$



END