

模式识别与机器学习 (8)

特征选择与特征提取


左旺孟

哈尔滨工业大学计算机学院
综合楼712

cswmzuo@gmail.com
13134506692




特征选择和特征提取



特征表示

- 类内变化
- 类间变化



人脸识别

主要内容


- 特征选择

- 单变量选择法
- 搜索法
- 嵌入式方法

- 特征提取

- 线性方法
 - 主成分分析（重点介绍）
 - 线性判别分析（重点介绍）
- 非线性方法
 - 流形学习
 - 核特征提取方法

A 为对角阵并且
 $A(i, i) = 0$ 或 1




$y = Ax$


$y = f(x)$

特征选择

- 去除冗余特征，提高识别性能
 - 过多冗余特征可能会导致模式识别性能恶化（维数灾难）
- 减少特征数目，提高识别速度
- 降低系统成本，模型可解释性




微阵列数据分析



- 发现相关致病基因

文本分类



Reuters: 21578 新闻报道, 114 个语义类.

20 newsgroups: 19997 篇文章, 20 类.

WebKB: 8282个网页, 7 类.

原始特征维数: >100000.

朴素贝叶斯分类器

某些类的前三个特征词:

- ❖ **Alt.atheism:** atheism, atheists, morality
- ❖ **Comp.graphics:** image, jpeg, graphics
- ❖ **Sci.space:** space, nasa, orbit
- ❖ **Soc.religion.christian:** god, church, sin
- ❖ **Talk.politics.mideast:** israel, armenian, turkish
- ❖ **Talk.religion.misc:** jesus, god, jehovah

*Bekkerman et al,
JMLR, 2003*

特征选择问题

设有 n 个可用作分类的特征，为了在**不降低（或者尽量不降低）分类精度**的前提下，减小特征空间的维数以减少计算量，需要从中**直接**选出 m 个作为分类特征。这就是特征选择。

目标函数：

- (1) 不降低分类精度
- (2) 特征个数越少越好

从 n 个特征中，选出 m 个特征，一共有

$$C_n^m = \frac{n!}{m!(n-m)!}$$

种可能的选法。如果对每一种选法进行测试计算其错误率，固然能得到最佳的特征组合，但是计算量太大。因此这种穷举的方法并不实用。

1.1 单变量选择法

1.2 搜索法

1.3 嵌入式方法

1.1 单变量选择法

单变量选择法就是把n维特征每个分量单独使用时的可分性准则函数值都算出来，然后按准则函数值按从大到小排序，如


$$G(x_1) > G(x_2) > \cdots > G(x_m) > \cdots > G(x_n)$$

然后，取使 G 较大的前m个特征作为选择结果。

如两类样本 w_i 和 w_j ， $G(x_k)$ 可定义为：

$$G(x_k) = \frac{(m_{ik} - m_{jk})^2}{\sigma_{ik}^2 + \sigma_{jk}^2}, \quad k = 1, 2, \cdots, n$$

该方法简单，但适用范围与模式特征的概率分布有关。
当类概率密度不能用正态分布近似时，不适用。



相关性评价

- 独立性

$$P(X, Y) = P(X) P(Y)$$

- 相关性：互信息

$$\begin{aligned} \text{MI}(X, Y) &= \int P(X, Y) \log \frac{P(X, Y)}{P(X)P(Y)} dX dY \\ &= \text{KL}(P(X, Y) \parallel P(X)P(Y)) \end{aligned}$$

Kullback-Leibler散度

- 熵
$$H(X) \equiv \sum_{x \in \mathcal{A}_X} P(x) \log \frac{1}{P(x)},$$

- 相互熵
$$H(X, Y) = \sum_{xy \in \mathcal{A}_X \mathcal{A}_Y} P(x, y) \log \frac{1}{P(x, y)}.$$

- KL散度
$$D_{\text{KL}}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}.$$

$$I(f_1, f_0) \neq I(f_0, f_1)$$

- Jenson-Shannon熵

$$I_J(f_1, f_0) = I(f_1, f_0) + I(f_0, f_1)$$

Kullback-Leibler散度性质

$$D_{\text{KL}}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}.$$


- 非负性
- KL散度为0 $\Rightarrow$ P和Q同分布
- 不对称性
- Jensen-Shannon熵

$$I_J(f_1, f_0) = I(f_1, f_0) + I(f_0, f_1)$$

KL散度不满足对称性

Kullback-Leibler散度

- 连续情形




Reshed, D., Y. Reshef, H. Finucane, S. Grossman, G. McVean, P. Turnbaugh, E. Lander, M. Mitzenmacher, and P. Sabeti (2011, December). Detecting novel associations in large data sets. *Science* 334, 1518–1524.

1.2 搜索法


❖ 前向搜索 $(n(n+1))/2$

❖ 后向搜索 $(n(n+1))/2$



❖ 其他

问题与不足



Guyon-Elisseff, JMLR 2004; Springer 2006

1.3 嵌入式方法

- 特征选择

A 为对角阵并且 $A(i, i) = 0$ 或1

$$\mathbf{y} = \mathbf{A}\mathbf{x}$$

- 拓展1

A 为对角阵并且 $A(i, i) = 0$ 或不等于0

- 拓展2

A


非0	
0	0

1.3 嵌入式方法

- 利用某些分类器、先验分布的性质，自适应地检测并去除冗余特征。
- 如：基于支持向量机

$$\{\vec{w}^*, b^*\} = \min_{\vec{w}, b, \varepsilon} \sum_{i=1}^d w_i^2 + c \sum_{j=1}^N \varepsilon_j$$

$$y_1 (\vec{w} \cdot \vec{x}_1 + b) \geq 1 - \varepsilon_1, \varepsilon_1 \geq 0$$




Recursive Feature Elimination (RFE) SVM. *Guyon-Weston, 2000. US patent 7,117,188*

基于稀疏先验分布

- 拉普拉斯分布

$$\min_{\mathbf{w}} \sum_{i=1}^N \log(1 + \exp(-\mathbf{w}^T \bar{\mathbf{z}}_i)) + \lambda \|\mathbf{w}\|_1,$$

$$p_L(w) = \left(\frac{\alpha}{2}\right) \exp(-\alpha|w|)$$



- 目标函数

$$\log(L(\mathbf{w})) = \sum_{i=1}^N \left\{ \mathbf{y}_i \mathbf{w}^t \mathbf{x}_i - \log[1 + \exp(\mathbf{w}^t \mathbf{x}_i)] \right\} - \alpha \|\mathbf{w}\|_1$$


Krishnapuram, B., Figueiredo, M., Carin, L., & Hartemink, A. (2005) “Sparse Multinomial Logistic Regression: Fast Algorithms and Generalization Bounds.” IEEE Trans. Pattern Analysis and Machine Intelligence, 27, 2005. pp. 957–968.

- 求解:

- $$\arg \min \frac{1}{2} (x - x_0)^2 + \lambda |x|$$

- 证明

- $$\|\mathbf{x}\|_1 \geq \|\mathbf{x}\|_2 \geq \dots \geq \|\mathbf{x}\|_\infty$$



MATLAB

fscnca


Feature selection using neighborhood component analysis for classification

R2025b

[collapse all in page](#)

Syntax

```
mdl = fscnca(Tbl,ResponseVarName)
mdl = fscnca(Tbl,formula)
mdl = fscnca(Tbl,Y)
mdl = fscnca(X,Y)
mdl = fscnca(X,Y,Name,Value)
```



Feature Selection Library

Version 7.0.2020.3 (723 KB) by Giorgio


Feature Selection Library (MATLAB Toolbox)

[⊕ Follow](#)

$$d_w(x_i, x_j) = \sum_{r=1}^p w_r^2 |x_{ir} - x_{jr}|,$$

$$p_{ij} = P(\text{Ref}(x_i) = x_j | S^{-i}) = \frac{k(d_w(x_i, x_j))}{\sum_{j=1, j \neq i}^n k(d_w(x_i, x_j))}.$$

$$\xi(\mathbf{w}) = \sum_i \sum_j y_{ij} p_{ij} - \lambda \sum_{l=1}^d w_l^2$$



[1] Yang, W., K. Wang, W. Zuo. "Neighborhood Component Feature Selection for High-Dimensional Data." Journal of Computers. Vol. 7, Number 1, January, 2012.

2. 特征提取

- 预备知识
 - 矩阵分析基础
- 线性方法
 - 主成分分析
 - 线性判别分析
- 非线性方法
 - 流形学习
 - 核特征提取方法

2.1 矩阵分析基础

- 矩阵 A
 - 基本操作：加法、乘法
 - 其它重要操作：转置、 $\text{inv}(A)$ 、 rank (秩)、 $\text{det}(A)$ 、迹 (trace)
- 特征值和特征向量
 - $(\lambda, \mathbf{v})$ 是一个特征值-特征向量对，如果满足

$$Ax = \lambda x$$

- λ ：特征值
- $\mathbf{v}$ ：特征向量


正交矩阵

❖ 矩阵 $U \in \mathfrak{R}^{m \times m}$ 是正交矩阵，当且仅当

$$U U^T = I_m \Rightarrow U^{-1} = U^T$$

❖ 矩阵 $V \in \mathfrak{R}^{m \times n}$ ($m > n$) 是列正交矩阵，当且仅当

$$V^T V = I$$



矩阵范数和迹 (Trace)

矩阵范数(norm):

2-norm: $\|A\|_2 = \sqrt{\lambda_{\max}(AA^T)}$ 的最大特征值的平方根.

F-norm: $\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2}$.

1-norm: $\|A\|_1 = \sum_{i,j} |A_{ij}|$.

$\text{trace}(A) = \sum_{i=1}^m A_{ii}$, A 为 $m \times m$ 的正方阵.

$\|A\|_F^2 = \text{trace}(AA^T) = \text{trace}(A^T A)$, $\text{trace}(AB) = \text{trace}(BA)$.

$\|QA\|_F = \|A\|_F$, 如果 Q 为列正交矩阵.

对称矩阵、正定矩阵

如果 $A = A^T$, 称 A 是对称的.

如果 对任意 $x \in \mathfrak{R}^m$, $x^T A x \geq 0$, $A \in \mathfrak{R}^{m \times m}$ 是对称半正定矩阵.




如果 对任意 非零 $x \in \mathfrak{R}^m$, $x^T A x > 0$, $A \in \mathfrak{R}^{m \times m}$ 是对称正定矩阵.

奇异值分解 (SVD)


奇异值分解 (SVD): $A = U\Sigma V^T$, 其中 $A \in \mathbb{R}^{m \times n}$, $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ 为正交矩阵, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$ 是对角矩阵并有 $\sigma_1 \geq \dots \geq \sigma_r$, $r = \min(m, n)$.

$AA^T = U\Sigma\Sigma^T U^T$: U 是矩阵 AA^T 的特征向量集合.


$A^T A = V\Sigma^T \Sigma V^T$: V 是矩阵 $A^T A$ 的特征向量集合.



正交



对角



正交

SVD性质

THEOREM 2.1. *Let the SVD of A be given by Equation (1) and*

$$\sigma_1 \geq \sigma_2 \cdots \geq \sigma_r > \sigma_{r+1} = \cdots = \sigma_n = 0$$

and let $R(A)$ and $N(A)$ denote the range and null space of A , respectively. Then,

- rank property: $\text{rank}(A) = r$, $N(A) \equiv \text{span}\{v_{r+1}, \dots, v_n\}$, and $R(A) \equiv \text{span}\{u_1, \dots, u_r\}$, where $U = [u_1 u_2 \cdots u_m]$ and $V = [v_1 v_2 \cdots v_n]$.*
- dyadic decomposition: $A = \sum_{i=1}^r u_i \cdot \sigma_i \cdot v_i^T$.*
- norms: $\|A\|_F^2 = \sigma_1^2 + \cdots + \sigma_r^2$, and $\|A\|_2 = \sigma_1$.*

SVD性质

THEOREM 2.2. [Eckart and Young] *Let the SVD of A be given by Equation (1) with $r = \text{rank}(A) \leq p = \min(m, n)$ and define*

$$(2) \quad A_k = \sum_{i=1}^k u_i \cdot \sigma_i \cdot v_i^T ,$$

then

$$\min_{\text{rank}(B)=k} \|A - B\|_F^2 = \|A - A_k\|_F^2 = \sigma_{k+1}^2 + \cdots + \sigma_p^2.$$

- A_k 是矩阵Frobenius范数下的k-秩最优逼近

问题的提出


- 一般来说，在建立识别系统时，抽取的原始特征往往比较多，特征的维数比较大，这会给识别器的训练带来很大的困难，因此希望能够采用某种方法降低特征的维数。这些方法可以称作**成分分析**的方法。
- 成分分析方法主要包括：
 1. **主成分分析**；
 2. 线性判别分析；

2.1 主成分分析


(PCA, Principal Component Analysis)

- PCA是一种最常用的**线性**成分分析方法;
- PCA的主要思想是寻找到数据的主轴方向, 由主轴构成一个新的坐标系 (维数可以比原维数低), 然后数据由原坐标系向新的坐标系投影。
- PCA的**其它名称**: 离散K-L变换, Hotelling变换;

PCA的思想



PCA的思想



目标（损失）

- 输入：训练样本集 $(\mathbf{x}_1, \dots, \mathbf{x}_N)$ ，其维数为 n
- 输出：样本的均值 $\mathbf{m}$ 和 d ($< n$) 个主成分方向 $(\mathbf{u}_1, \dots, \mathbf{u}_d)$ 。
- 损失函数

$$\min_{\mathbf{m}, \mathbf{u}_1, \dots, \mathbf{u}_d} \frac{1}{N} \sum_{i=1}^N \left\| \mathbf{x}_i - \mathbf{m} - \sum_{j=1}^d \mathbf{u}_j \mathbf{u}_j^T (\mathbf{x}_i - \mathbf{m}) \right\|^2$$
$$\text{s.t. } \mathbf{u}_i^T \mathbf{u}_j = \begin{cases} 1, & \text{if } i = j \\ 0, & \text{if } i \neq j \end{cases}$$

PCA算法

1. 利用训练样本集合计算样本的均值 $\mathbf{m}$ 和**协方差矩阵（散度矩阵）** $\mathbf{S}$;

$$\mathbf{m} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \quad \mathbf{S} = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^T$$

2. 计算 $\mathbf{S}$ 的特征值，并由大到小排序;
3. 选择前 d' 个特征值对应的特征向量作成**一个变换矩阵** $\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{d'}]$;
4. 训练和识别时，每一个输入的 d 维特征向量 $\mathbf{x}$ 可以转换为 d' 维的新特征向量 $\mathbf{y}$:

$$\mathbf{y} = \mathbf{E}^t(\mathbf{x}-\mathbf{m}) \text{（投影）}, \quad \mathbf{x}' = \mathbf{E}\mathbf{y}+\mathbf{m} \text{（重建）}$$

PCA算法：如何确定特征维度d'

自适应准则

$$\frac{\sum_{i=1}^K \lambda_i}{\sum_{i=1}^N \lambda_i} > Threshold \quad (\text{e.g., } 0.9 \text{ or } 0.95)$$


重建误差

$$e = \|x - \hat{x}\|$$

$$e = 1/2 \sum_{i=K+1}^N \lambda_i$$

PCA的讨论

- 由于 S 是实对称阵，因此特征向量是**正交**的；
- 将数据向新的坐标轴投影之后，特征之间是**不相关**的；
- 特征值描述了变换后各维特征的重要性，特征值为0的各维特征为冗余特征，可以去掉。



PCA性质

- 最大方差

$$\text{var}[z_1] = E((z_1 - \bar{z}_1)^2) = \frac{1}{n} \sum_{i=1}^n (a_1^T x_i - a_1^T \bar{x})^2$$

$$= \frac{1}{n} \sum_{i=1}^n a_1^T (x_i - \bar{x})(x_i - \bar{x})^T a_1 = a_1^T S a_1$$

- 最优重建

$$\min_{G \in \mathbb{R}^{p \times d}} \|X - G(G^T X)\|_F^2 \text{ subject to } G^T G = I_d$$

- 去共生（相关）

$$\text{cov}[z_2, z_1] = 0$$


例8.1

- 有两类问题的训练样本：

$$\omega_1 : (-5, -4)^t, (-4, -5)^t, (-5, -6)^t, (-6, -5)^t$$

$$\omega_2 : (5, 4)^t, (4, 5)^t, (5, 6)^t, (6, 5)^t$$

将特征由2维压缩为1维。






































人脸识别举例



特征人脸 (Eigenfaces)

 e_1 e_2 e_3 e_4 e_5 e_6 e_7 e_8 

PCA重构

原图像	$d'=1$	5	10	20	50	100	200
							
							
							
							
							

PCA: 高维小样本数据 ($d \gg N$)

1. 均值 $\mathbf{m}$ 和协方差矩阵（散度矩阵） $\mathbf{S}$;

$$\mathbf{m} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \quad \mathbf{X} = [(\mathbf{x}_1 - \mathbf{m}), \dots, (\mathbf{x}_N - \mathbf{m})]$$

$$\mathbf{S} = \frac{1}{N} \mathbf{X} \mathbf{X}^T \quad \hat{\mathbf{S}} = \frac{1}{N} \mathbf{X}^T \mathbf{X}$$

2. 特征值分解

$$\hat{\mathbf{S}} \hat{\mathbf{e}}_i = \lambda_i \hat{\mathbf{e}}_i$$

$$\mathbf{e}_i = \frac{1}{\sqrt{\lambda_i}} \mathbf{X} \hat{\mathbf{e}}_i$$

3. 选择前 d' 个特征值对应的特征向量作成变换矩阵 $\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{d'}]$;

4. 特征投影与重建:

$$\mathbf{y} = \mathbf{E}^t(\mathbf{x} - \mathbf{m}) \text{ (投影)}, \quad \mathbf{x}' = \mathbf{E} \mathbf{y} + \mathbf{m} \text{ (重建)}$$

PCA性质

- 最大方差 $\text{var}[z_1] = E((z_1 - \bar{z}_1)^2) = \frac{1}{n} \sum_{i=1}^n (a_1^T x_i - a_1^T \bar{x})^2$

$$= \frac{1}{n} \sum_{i=1}^n a_1^T (x_i - \bar{x})(x_i - \bar{x})^T a_1 = a_1^T S a_1$$

- 最优重建

$$\min_{G \in \mathbb{R}^{p \times d}} \|X - G(G^T X)\|_F^2 \text{ subject to } G^T G = I_d$$

- 去共生

$$\text{cov}[z_2, z_1] = 0$$



PCA -> LDA

- PCA将所有的样本作为一个整体对待，寻找一个均方误差最小意义下的最优线性映射，而没有考虑样本的类别属性，它所忽略的投影方向有可能恰恰包含了重要的可分性信息；
- LDA则是在可分性最大意义下的最优线性映射，充分保留了样本的类别可分性信息；
- LDA还被称为FDA(Fisher Discriminant Analysis) 。

线性判别分析(LDA)

- PCA



$$Y = w^T X$$



寻求变换 w , 使得 $w^T x$ 的分布最大限度的分散 (最大方差原则)

Linear Discriminant Analysis (LDA)

- LDA $Y_1 = w^T X_1$ $Y_2 = w^T X_2$




寻求变换 w , 最大限度地拉大 $w^T X_1$ 和 $w^T X_2$ 的距离, 同时使得类样本的类内分布的分散程度最小 (最大分离原则)

线性判别分析(LDA)

- 基本假设:
 - 各类的类内分布相同
 - 满足假设时理论最优
- 维数约简
- 尽可能的保持原始数据中的类别判别信息.
- 寻求使各类样本之间分离程度最大的投影方向.
- 同时考虑了类内散度分布和类间散度分布情况.

线性判别分析(LDA)

- 只考虑均值和类内方差的情况



线性判别分析(LDA)

- 两类情形: ω_1, ω_2
- 定义类内散度矩阵 (S_w) 和类间散度矩阵 (S_b) 如下

$$Y = w^T X$$

$$\mu_i = \frac{1}{N_i} \sum_{x \in \omega_i} x \quad \tilde{\mu}_i = \frac{1}{N_i} \sum_{y \in \omega_i} y$$

$$S_i = \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T$$

$$S_w = S_1 + S_2$$

线性判别分析(LDA)

$$\tilde{S}_i^2 = \sum_{y \in \omega_i} (y - \tilde{\mu}_i)^2 = \sum_{x \in \omega_i} (w^T x - w^T \mu_i)^2 = \sum_{x \in \omega_i} w^T (x - \mu_i)(x - \mu_i)^T w = w^T S_i w$$

$$\tilde{S}_1^2 + \tilde{S}_2^2 = w^T S_W w$$

$$(\tilde{\mu}_1 - \tilde{\mu}_2)^2 = (w^T \mu_1 - w^T \mu_2)^2 = w^T (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w = w^T S_B w$$

$$J(w) = \frac{w^T S_B w}{w^T S_W w}$$

Maximize S_B

Minimize S_W

线性判别分析(LDA)

$$J(w) = \frac{w^T S_B w}{w^T S_W w} \quad \text{如何求解?}$$

$$\text{minimize} \quad -\frac{1}{2} w^T S_B w \quad \text{s.t.} \quad w^T S_W w = 1$$

$$\Lambda(w, \lambda) = -\frac{1}{2} w^T S_B w + \frac{1}{2} \lambda (w^T S_W w - 1)$$

$$\frac{\partial \Lambda}{\partial w} = -S_B w + \lambda S_W w = 0$$

$$S_B w = \lambda S_W w \quad \text{广义特征值问题}$$

$$S_W^{-1} S_B w = \lambda w \quad \text{特征值问题}$$

LDA算法

1. 利用训练样本集合计算类内散度矩阵 S_w 和类间散度矩阵 S_B ;
2. 计算 S_w 和 S_B 的广义特征值;
3. 选择非0的 $c-1$ 个特征值对应的特征向量作成
一个变换矩阵 $W=[w_1, w_2, \dots, w_{c-1}]$;
4. 训练和识别时, 每一个输入的 d 维特征向量 x
可以转换为 $c-1$ 维的新特征向量 y :

$$y = W^t x。$$

例

• 数据

- $X_1 = \{(4,1), (2,4), (2,3), (3,6), (4,4)\}$
- $X_2 = \{(9,10), (6,8), (9,5), (8,7), (10,8)\}$

• 类统计数据

$$\mu_1 = [3.0 \quad 3.6], \quad \mu_2 = [8.4 \quad 7.6]$$


$$S_1 = \begin{bmatrix} .8 & -.4 \\ -.4 & 2.6 \end{bmatrix}, \quad S_2 = \begin{bmatrix} 1.84 & -.04 \\ -.04 & 2.64 \end{bmatrix}$$

• 类内和类间散度

$$S_B = \begin{bmatrix} 29.16 & 21.60 \\ 21.60 & 16.00 \end{bmatrix}, \quad S_W = \begin{bmatrix} 2.64 & -.44 \\ -.44 & 5.28 \end{bmatrix}$$

• 求解特征值问题


$$S_W^{-1} S_B w = \lambda w \quad \text{or directly } w = S_W^{-1} (\mu_1 - \mu_2)$$



线性判别分析(LDA)

- C类问题

$$J(w) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|w^T S_B w|}{|w^T S_W w|}$$



线性判别分析(LDA)

- **C类问题**

$$U = [X_1^1 \quad X_2^1 \quad X_1^2 \quad X_2^2 \quad \cdots \quad X_{n_c}^c]$$

$$S_w = \sum_{i=1}^c \sum_{j=1}^{n_c} (X_j^i - \mu_i)(X_j^i - \mu_i)^T$$

$$S_b = \sum_{i=1}^c (\mu_i - \mu)(\mu_i - \mu)^T$$

$$S_B w = \lambda S_W w$$




$$W = [V_1 \quad \cdots \quad V_k]$$

LDA的讨论

- 经FDA变换后，新的坐标系可能不是一个正交坐标系；
- 新的坐标维数最多为 $c-1$ ， c 为类别数；
- 只有当样本数足够多时，才能够保证类内散度矩阵 S_w 为非奇异矩阵（存在逆阵），而高维小样本情形下 S_w 可能是奇异矩阵。
 - 存在向量 w ， $w^T S_w w = 0$
 - 如何解决？（PCA+LDA、Null Space LDA、VCA（ICML 2013 Best Paper））


应用：咖啡豆分类

- 5种类型的咖啡豆
- 每类45个样本
- 60 维特征向量





2.3 流形学习： ISOMAP

- 问题: 高维数据的低维结构
- 有意义和可解释性的维度



直接利用PCA


- 不能有效发现数据的低维结构




❖ Why?

ISOMAP

- 标度分析
- 用流形上的距离代替欧氏距离



A Global Geometric Framework for Nonlinear Dimensionality Reduction, Science, Dec. 2000.






其它流形学习方法

- 局部线性嵌入 (LLE)
- 拉普拉斯特征图 (Laplacian EigenMap)
- Hessian LLE
- t-SNE
- ...


S.T. Roweis, and L.K. Saul, Nonlinear Dimensionality Reduction by Locally Linear Embedding, Science, Dec., 2000.

PCA & t-SNE



PCA

Learned Embeddings



- NOUN
- PROPN
- AUX
- VERB
- ADP
- DET
- ADJ
- PRON
- ADV
- SCONJ
- NUM

t-SNE

核特征提取方法：Kernel PCA

- 经典的PCA方法假设数据 $\mathbf{x}$ 服从多变量高斯分布
- 但实际应用中这一假设可能不成立
- 基于核方法，我们可以将数据从原始空间 $\mathbf{x}$ 转换为特征空间 $\phi(\mathbf{x})$ ，如果 $\phi(\mathbf{x})$ 服从高斯分布的话，我们可在特征空间下做PCA，即核PCA.
- 核PCA在高维甚至无穷维特征空间下进行主成分分析。庆幸的是，借助于核函数的性质， $\Phi(\mathbf{x})^t \Phi(\mathbf{y}) = K(\mathbf{x}, \mathbf{y})$ ，我们并不需要计算从原始空间到特征空间的显式映射。

KPCA: 基本思想




Fig. 1. Basic idea of kernel PCA: by using a nonlinear kernel function k instead of the standard dot product, we implicitly perform PCA in a possibly high-dimensional space F which is nonlinearly related to input space. The dotted lines are contour lines of constant feature value.

核PCA 问题表述

- 基础知识（先假设均值为0）：
- 令 $\mathbf{v}$ 为散度矩阵 $S = \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^T$ 的一个特征向量
- 则 $\mathbf{v}$ 应属于数据点 $\mathbf{x}_i$ $i=1, 2, \dots, N$ 所组成的空间
- 证明:

$$S\mathbf{v} = \lambda\mathbf{v} \Rightarrow \mathbf{v} = \frac{1}{\lambda} \sum_{i=1}^N \mathbf{x}_i (\mathbf{x}_i^T \mathbf{v}) = \sum_{i=1}^N \alpha_i \mathbf{x}_i$$

核PCA 问题表述（续）

- 令 C 表示经过过去中心化映射 $\phi(\mathbf{x})$ 后的特征空间下的散度矩阵：

$$C = \sum_{i=1}^N \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T$$

- 令 $\mathbf{w}$ 为 C 的一个特征向量, 则 $\mathbf{w}$ 也可以被写成线性组合形式:

$$\mathbf{w} = \sum_{k=1}^N \alpha_k \phi(\mathbf{x}_k)$$

- 同样, 有:

$$C\mathbf{w} = \lambda\mathbf{w}$$

- 综合上述, 可得:

$$\left(\sum_{i=1}^N \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T \right) \left(\sum_{k=1}^N \alpha_k \phi(\mathbf{x}_k) \right) = \lambda \sum_{k=1}^N \alpha_k \phi(\mathbf{x}_k)$$

核PCA 问题表述（续）

$$\left(\sum_{i=1}^N \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T\right) \left(\sum_{k=1}^N \alpha_k \phi(\mathbf{x}_k)\right) = \lambda \sum_{k=1}^N \alpha_k \phi(\mathbf{x}_k) \Rightarrow$$

$$\sum_{i=1}^N \sum_{k=1}^N \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_k) \alpha_k = \lambda \sum_{k=1}^N \alpha_k \phi(\mathbf{x}_k) \Rightarrow$$

$$\sum_{i=1}^N \sum_{k=1}^N \phi(\mathbf{x}_l)^T \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_k) \alpha_k = \lambda \sum_{k=1}^N \alpha_k \phi(\mathbf{x}_l)^T \phi(\mathbf{x}_k), l = 1, 2, \dots, N \Rightarrow$$

$$K^2 \boldsymbol{\alpha} = \lambda K \boldsymbol{\alpha} \Rightarrow$$

$$K \boldsymbol{\alpha} = \lambda \boldsymbol{\alpha}, \text{ 其中 } K_{ij} = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j).$$



核矩阵或 Gram 矩阵

Kernel PCA Formulation...

求解特征值问题 $K\mathbf{a} = \lambda\mathbf{a}$

然后将特征向量 $\mathbf{w}$ 归一化为单位向量, 可得:

$$\|\mathbf{w}\|^2 = \left(\sum_{i=1}^N \alpha_i \phi(\mathbf{x}_i)\right)^T \left(\sum_{i=1}^N \alpha_i \phi(\mathbf{x}_i)\right) = \mathbf{a}^T K \mathbf{a} = 1 \Rightarrow$$

$$\mathbf{a}^T \mathbf{a} = \frac{1}{\lambda}$$

KPCA 算法

Step 1: 计算 Gram 矩阵: $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j), i, j = 1, \dots, N$

Step 2: 计算矩阵 $\mathbf{K}$ 的 (特征值, 特征向量) 对: $(\boldsymbol{\alpha}^l, \lambda_l), l = 1, \dots, M$

Step 3: 特征向量归一化: $\boldsymbol{\alpha}^l \leftarrow \frac{\boldsymbol{\alpha}^l}{\lambda_l}$

因而, 矩阵 $\mathbf{C}$ 的一个特征向量 $\mathbf{w}^l$ 可被表示为: $\mathbf{w}^l = \sum_{k=1}^N \alpha_k^l \phi(\mathbf{x}_k)$

为投影测试特征向量 $\phi(\mathbf{x})$ 到 $\mathbf{w}^l$, 需要计算:

$$\phi(\mathbf{x})^T \mathbf{w}^l = \phi(\mathbf{x})^T \left(\sum_{k=1}^N \alpha_k^l \phi(\mathbf{x}_k) \right) = \sum_{k=1}^N \alpha_k^l k(\mathbf{x}_k, \mathbf{x})$$

不需要显式计算 ϕ !

特征映射中心化处理

到目前为止，我们假设特征向量 $\phi(\mathbf{x})$ 经过中心化处理，即 $\sum_{i=1}^N \phi(\mathbf{x}_i) = 0$

实际上，即使不满足上述假设，我们可以利用下述方式对Gram矩阵进行中心化处理

$$\tilde{K} = (I - \mathbf{1}\mathbf{1}^T / N) K (I - \mathbf{1}\mathbf{1}^T / N)$$

中心化处理后的核矩阵，即， $\sum_{i=1}^N \phi(\mathbf{x}_i) = 0$

$$\mathbf{m} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$
$$\mathbf{S} = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^T$$


我们可以使用类似的方式来处理测试样本，并进一步投影到特征向量空间

Scholkopf, Smola, Muller, “Nonlinear component analysis as a kernel eigenvalue problem,” Technical report #44, Max Plank Institute, 1996.

其它核特征提取技术

- 核判别分析 (Kernel Fisher Discriminant Analysis)
- 核独立成分分析 (Kernel ICA)
- 核典型相关分析 (Kernel CCA)
-

Schölkopf: “*every (linear) algorithm that only use scalar (inner) products can implicitly be executed in Φ by using kernels, i.e. one can very elegantly construct a nonlinear version of a linear algorithm.*”



END