

模式识别与机器学习 (10)

非监督学习

左旺孟


哈尔滨工业大学计算机学院
机器学习研究中心
综合楼712

cswmzuo@gmail.com


13134506692




模式识别



分类和聚类



给定样本和类别标签，确定
决策函数




给定样本，根据样本的邻近关
系等分析其分布的内在结构

分类



Cat or Dog?

聚类




Class 1 or Class 2



聚类分析

- 聚类准则
- 层次聚类 (简单介绍)
- K均值聚类
- 高斯混合模型
 - EM算法

1. 聚类准则函数



◆ 类别数 如: $c = 2$

◆ 聚类结果

误差平方和准则

- 将样本分成 c 个子集 $D_1, \dots, D_c$, n_i 为第 i 个子集的样本数, $\mathbf{m}_i$ 为样本均值:

$$\mathbf{m}_i = \frac{1}{n_i} \sum_{\mathbf{x} \in D_i} \mathbf{x}$$

- 误差平方和准则:

$$J_e = \sum_{i=1}^c \sum_{\mathbf{x} \in D_i} \|\mathbf{x} - \mathbf{m}_i\|^2$$

散布矩阵

- 类内散布矩阵:

$$\mathbf{S}_w = \sum_{i=1}^c \sum_{\mathbf{x} \in D_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^t$$

- 类间散布矩阵:

$$\mathbf{S}_B = \sum_{i=1}^c n_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^t$$

- 总体散布矩阵:

$$\mathbf{S}_T = \sum_{\mathbf{x} \in D} (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^t = \mathbf{S}_w + \mathbf{S}_B$$

散布准则


- 基于行列式的散布准则：

$$J_d = |\mathbf{S}_w|$$

- 基于不变量的散布准则：

$$J_f = tr[\mathbf{S}_T^{-1} \mathbf{S}_W]$$


大间隔准则



准则函数的优化

- 穷举法优化：聚类准则函数的优化是组合最优问题，是一个NP难题，将 n 个样本分到 c 个类别有 $c^n/c!$ 种分法，穷举计算是不现实的，只能寻找次优方法解决；
- 迭代最优化：随机设置初始聚类，计算将样本 x 从 D_i 聚类移到 D_j 聚类是否能够使准则函数减小，减小则做此修改，否则不修改。


2. 层次聚类



Data:

o ... datapoint

x ... centroid




2. 层次聚类：算法

1. begin initialize $c, c' \leftarrow n, D_i \leftarrow \{x_i\}, i=1, \dots, n;$
2. do $c' \leftarrow c' - 1$
3. 求最接近的聚类, 如 D_i 和 D_j ;
4. 合并 D_i 和 D_j ;
5. until $c' = c$;
6. return c 个聚类;
7. end

最接近的聚类

- 两类最近的样本的距离最小
- 两类的中心的距离最小
 - 如何定义类的中心？（均值）
 - 如何度量类中心间的距离（欧氏距离）

层次聚类的树图



层次聚类的特点

- 层次聚类不用初始化聚类中心，因此聚类结果不受初始聚类中心的影响；
- 需要定义类别之间的相似性度量；
- 当样本数比较多时，算法的计算量比较大（算法第3步）。
- 聚类结果同样是对平方误差准则函数的贪心优化结果。

3. k-均值聚类

- 平方误差准则

$$J_e = \sum_{i=1}^c \sum_{\mathbf{x} \in D_i} \|\mathbf{x} - \mathbf{m}_i\|^2$$


- 迭代贪心搜索算法
 - 给定 $\mathbf{m}_i$, 更新 D_i
 - 给定 D_i , 更新 $\mathbf{m}_i$

3. k-均值聚类

1. begin initialize 样本数 n , 聚类数 c , 初始聚类中心 $m_1, \dots, m_c$;
2. do 按照最近邻 m_i 分类 n 个样本;
3. 重新计算聚类中心 $m_1, \dots, m_c$;
4. until m_i 不再改变;
5. return $m_1, \dots, m_c$;
6. end


K-means

1. Ask user how many clusters they'd like.
(e.g. $k=5$)




K-means

1. Ask user how many clusters they'd like.
(e.g. $k=5$)
2. Randomly guess k cluster Center locations




K-means

1. Ask user how many clusters they'd like.
(e.g. $k=5$)
2. Randomly guess k cluster Center locations
3. Each datapoint finds out which Center it's closest to. (Thus each Center "owns" a set of datapoints)




K-means

1. Ask user how many clusters they'd like.
(e.g. $k=5$)
2. Randomly guess k cluster Center locations
3. Each datapoint finds out which Center it's closest to.
4. Each Center finds the centroid of the points it owns




K-means

1. Ask user how many clusters they'd like.
(e.g. $k=5$)
2. Randomly guess k cluster Center locations
3. Each datapoint finds out which Center it's closest to.
4. Each Center finds the centroid of the points it owns...
5. ...and jumps there
6. ...Repeat until terminated!




K-means continues

...




K-means continues

...




K-means continues

...




K-means continues

...




K-means continues

...



K-means terminates



k-均值聚类的特点

- k-均值算法可以看作是对平方误差准则函数的贪心搜索算法；

$$J_e = \sum_{i=1}^c \sum_{\mathbf{x} \in D_i} \|\mathbf{x} - \mathbf{m}_i\|^2$$

- 聚类结果受初始聚类中心的选择影响很大，不同的初始聚类中心会导致不同的聚类结果。

4. 高斯混合模型


- 一个复杂的概率密度分布函数可以由多个简单的密度函数混合构成：

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{i=1}^M a_i p_i(\mathbf{x}|\boldsymbol{\theta}_i), \quad \sum_{i=1}^M a_i = 1$$




- 最常用的是高斯混合模型(GMM, Gauss Mixture Model):

$$p(\mathbf{x}) = \sum_{i=1}^M a_i N(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \quad \sum_{i=1}^M a_i = 1$$

高斯混合模型



GMM模型产生的2维样本数据



混合密度模型的参数估计

- 混合密度模型的参数可以表示为：

$$\boldsymbol{\theta} = (a_1, a_2, \cdots, a_M, \boldsymbol{\theta}_1, \boldsymbol{\theta}_2, \cdots, \boldsymbol{\theta}_M)$$

- 参数的估计方法：
 1. 利用最优化方法直接对似然函数进行优化，如梯度下降法；
 2. 引入未知隐变量 $\mathbf{Y}$ 对问题进行简化，将 $\mathbf{Y}$ 看作丢失的数据，使用EM算法进行优化。

GMM模型的参数估计

- 首先引入隐含数据集: $Y = \{y_1, y_2, \dots, y_n\}$

其中: $y_i \in \{1, \dots, M\}$ 代表第*i*个训练样本是由第 y_i 个高斯函数产生的, 将Y作为丢失数据集, 采用EM算法进行迭代估计。

期望最大化(E-M)算法

- E-M算法并不是一种独立的参数估计方法，而是一种针对**数据缺失**情形下进行**最大似然估计**时使用的一种经典算法。
- 缺失数据：实际应用中得到的观测数据 X 会不完整，假设完全数据为 $Y=(X,Z)$ ，而我们只能基于观测数据 X 进行参数估计，此时称 Z 为缺失数据。
- 由于其简单性、有效性和收敛性，E-M算法已被广泛应用于各种数据缺失情形下的参数估计问题。

期望最大化算法(EM算法)

- EM算法的应用可以分为两个方面：
 1. 训练样本中某些**特征丢失**情况下，分布参数的最大似然估计；
 2. 对某些复杂分布模型假设，最大似然估计很难得到解析解时的迭代算法。
 1. 引入**隐变量**并利用EM算法求解

基本EM算法

- 令 $\mathbf{X}$ 是观察到的样本数据集合， $\mathbf{Y}$ 为丢失的数据集合，完整的样本集合 $\mathbf{D}=\mathbf{X}\cup\mathbf{Y}$ 。

$$p(\mathbf{D}|\boldsymbol{\theta}) = p(\mathbf{X}, \mathbf{Y}|\boldsymbol{\theta})$$

- 由于 $\mathbf{Y}$ 未知，在给定参数 $\boldsymbol{\theta}$ 时，似然函数可以看作 $\mathbf{Y}$ 的函数：

$$l(\boldsymbol{\theta}) = l(\boldsymbol{\theta}|\mathbf{D}) = l(\boldsymbol{\theta}|\mathbf{X}, \mathbf{Y}) = \ln p(\mathbf{X}, \mathbf{Y}|\boldsymbol{\theta})$$

基本EM算法

- 由于Y未知，因此我们需要根据当前的参数估计结果，寻找到一个在Y的所有可能情况下，平均意义下的似然函数，即似然函数对Y的期望，然后再执行最大化期望进行参数估计：

$$\begin{aligned}\text{E-Step: } Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{i-1}) &= E_{\mathbf{Y}} \left(l(\boldsymbol{\theta}|\mathbf{X}, \mathbf{Y}) \middle| \mathbf{X}, \boldsymbol{\theta}^{i-1} \right) \\ &= E_{\mathbf{Y}} \left(\ln p(\mathbf{X}, \mathbf{Y}|\boldsymbol{\theta}) \middle| \mathbf{X}, \boldsymbol{\theta}^{i-1} \right)\end{aligned}$$

$$\text{M-Step: } \boldsymbol{\theta}^i = \arg \max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{i-1})$$

基本EM算法

1. **begin initialize** $\boldsymbol{\theta}^0$, T , $i \leftarrow 0$;
2. **do** $i \leftarrow i+1$
3. E步: 计算 $Q(\boldsymbol{\theta} | \boldsymbol{\theta}^{i-1})$;
4. M步: $\boldsymbol{\theta}^i = \arg \max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta} | \boldsymbol{\theta}^{i-1})$
5. **until** $Q(\boldsymbol{\theta}^{i+1} | \boldsymbol{\theta}^i) - Q(\boldsymbol{\theta}^i | \boldsymbol{\theta}^{i-1}) \leq T$
6. **return**

$$\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}^{i+1}$$




GMM参数的EM估计算法


1. 设定混合模型数M，初始化模型参数 θ^0 ，阈值T， $i \leftarrow 0$ ；
2. 用下列公式迭代计算模型参数，直到似然函数变化小于T为止：

$$p(m|\mathbf{x}_t, \theta^i) = \frac{a_m^i p_m(\mathbf{x}_t | \theta_m^i)}{\sum_{j=1}^M a_j^i p_j(\mathbf{x}_t | \theta_j^i)} \quad \leftarrow \quad a_m^{i+1} = \frac{1}{n} \sum_{t=1}^n p(m|\mathbf{x}_t, \theta^i)$$

$$\mu_m^{i+1} = \frac{\sum_{t=1}^n \mathbf{x}_t p(m|\mathbf{x}_t, \theta^i)}{\sum_{t=1}^n p(m|\mathbf{x}_t, \theta^i)} \quad \rightarrow \quad \Sigma_m^{i+1} = \frac{\sum_{t=1}^n p(m|\mathbf{x}_t, \theta^i) (\mathbf{x}_t - \mu_m^{i+1}) (\mathbf{x}_t - \mu_m^{i+1})^t}{\sum_{t=1}^n p(m|\mathbf{x}_t, \theta^i)}$$

GMM模型产生的2维样本数据





END