

一、填空题

1. 闭凸集 $X \subset R^n$, 任意一点 $y \in R^n$, 则点 y 在集合 X 上的投影是否是唯一的 是。
2. 给定问题 $\min_{x \in R^2} f(x), f(x) = -12x_2 + 4x_1^2 + 4x_2^2 + 4x_1x_2$, 则 Hessian 矩阵 $H =$ _____。

若初始搜索方向 $d_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, 则该方向的共轭方向具有的特征为 $d_2 =$ _____。假设初始

点为 $x^{(1)} = \left(-\frac{1}{2}, 1\right)^T$, 沿 d_1 最小化目标函数得到迭代点 $x^{(2)} =$ _____。然后从该点

沿 d_2 方向最小化目标函数得 $x^{(3)} =$ _____。

3. 目标函数 $f(x_1, x_2) = 3x_1^2 - 4x_1x_2 + x_2^2$ 在点 $x^{(0)} = (0, 1)^T$ 处的单位最速下降方向为: _____
4. $\min x_1 + x_2, s. t. 2 - x_1^2 - x_2^2 \geq 0$, 其由非线性乘子法构造的拉格朗日函数在最优点 $x^* =$ _____ 处对应的 $\nabla_x^2 L(x^*, \lambda^*) =$ _____, 对应的乘子 $\lambda_1^* =$ _____
5. 在 SVM 中的 Hinge 损失和 L_2 损失分别如下:

$$f_i(z) = \begin{cases} \max\{0, 1 - y_i z\}, & \text{Hinge 损失} \\ \frac{1}{2} \max\{0, 1 - y_i z\}^2, & L_2 \text{ 损失} \end{cases}$$

$$\text{其梯度 } f'_i(z) = \begin{cases} (&), & \text{Hinge 损失} \\ (&), & L_2 \text{ 损失} \end{cases}$$

6. 外点法与内点法中, 只能对不等式约束问题进行求解是 内点 法。

二、计算证明题

7. 给定 $u, v, x \equiv (w_1, w_2, b_1, w_3, w_4, b_2, \omega_1, \omega_2, c)$, 令 $h(u; x) := g(\omega_1 h_1(u; w_1, w_2, b_1) + \omega_2 h_2(u; w_3, w_4, b_2) + c) = g(\omega_1 g(w_1 u_1 + w_2 u_2 + b_1) + \omega_2 g(w_3 u_1 + w_4 u_2 + b_2) + c)$, 这里: $g(z) = \frac{1}{1 + \exp(-z)}$, 并定义 $f(x) = [h(u; x) - v]^2$

- (a) 计算函数 f 的 Hessian 矩阵, 并证明函数 f 不一定是凸函数;
- (b) 计算函数 f 关于变量 x 的梯度 ∇f_x ;
- (c) 讨论如何在计算机上有效计算函数 f 的梯度;
- (d) 推导在什么条件下, 函数的梯度是 Lipschitz 连续的, 即满足: $\|\nabla f(x_1) - \nabla f(x_2)\| \leq L \|x_1 - x_2\|, \forall x_1, x_2 \in R^9$, 常数 $L > 0$ 。

8. 问题 P: $\min f(x); s. t. Ax \leq b; Ex = e; f$ 可微, $A_{m \times n}, E_{l \times n}, x \in R^n, b \in R^m, e \in R^l$, 证明: 设 \bar{x} 是上述问题的一个可行解, 且在点 \bar{x} 处有 $A_1 \bar{x} = b_1, A_2 \bar{x} < b_2$, 其中 $A = [A_1 A_2]^T, b = [b_1 b_2]^T$ 则

(a) 向量 $d (d \in R^n, d \neq 0)$ 是点 \bar{x} 处的可行方向的充要条件为 $A_1 d \leq 0, Ed = 0$;

(b) 若此时 d 又满足: $\nabla f(\bar{x})^T d < 0$, 则 d 是一个可行下降方向。

9. 考虑约束最优化问题 $\min f(x) = 4x_1^2 + 5x_1x_2 + x_2^2, s. t. \begin{cases} x_1^2 - x_2 + 2 \leq 0 \\ x_1 + x_2 - 6 \leq 0 \\ x_1, x_2 \geq 0 \end{cases}$ 分别写出用罚

函数法和内函数法求解的辅助问题。

10. 给定问题 (P) $\begin{cases} \min \left(x_1 - \frac{9}{4}\right)^2 + (x_2 - 2)^2 \\ s. t. \begin{cases} x_2 - x_1^2 \geq 0 \\ x_1 + x_2 \leq 6 \\ x_1, x_2 \geq 0 \end{cases} \end{cases}$, 请验证 $x^* = \left(\frac{3}{2}, \frac{9}{4}\right)^T$ 是 KKT 点, 并证明 x^* 是唯一

的最优解。

三、问答题

11. 请论述在深度学习优化算法中，是如何一步步对梯度下降法进行改进的。

12. 请论述线性规划算法在优化方法中的重要性。

11. 批量梯度下降法 (Batch Gradient Descent, BGD) :

BGD使用整个数据集来计算每个迭代步的梯度。这使得它非常准确，但是在处理大型数据集时速度会很慢，因为每次迭代都需要遍历整个数据集。

随机梯度下降法 (Stochastic Gradient Descent, SGD) :

SGD在每次迭代中只随机选择一个样本来计算梯度，这样计算量大大减少，速度更快。但是，由于梯度的估计是基于单个样本，因此SGD的方差较大，导致更新过程更加波动。

小批量梯度下降法 (Mini-batch Gradient Descent, MBGD) :

MBGD是BGD和SGD的折中方案，它在每次迭代中使用一小批样本（例如32或64个）来计算梯度。这样可以减少方差，同时比BGD更快地更新参数。

动量 (Momentum) :

动量方法借鉴了物理学中的动量概念，它将之前梯度的指数衰减平均值考虑进来，以此来加速学习过程，并减少震荡。动量有助于跨越局部极小值和鞍点。

Nesterov 加速梯度 (Nesterov Accelerated Gradient, NAG) :

NAG是动量方法的一个变种，它在计算梯度时考虑了参数更新后的近似位置，这通常可以提高优化的速度和性能。

自适应学习率算法 :

自适应学习率算法根据参数的历史梯度来调整每个参数的学习率。这些方法包括：

AdaGrad：它为每个参数分配不同的学习率，通过累积梯度平方来更新学习率。

RMSprop：结合了动量和AdaGrad的思想，它使用梯度平方的移动平均来调整学习率。

Adam：结合了RMSprop和动量的特点，同时使用梯度的一阶矩估计（即动量）和二阶矩估计（即未中心化的方差）来调整学习率。