

哈爾濱工業大學

《计算机视觉》
实验报告

专 业	AI 先进技术领军班
学 生	张泽晰
学 号	2024113212
指导教师	刘铭
日 期	2026 年 6 月

1 实验目的

本实验围绕三类视觉任务展开：DnCNN 图像去噪、传统图像分割以及基于 U-Net 的医学图像语义分割。实验目标如下：

1. 理解 DnCNN 在高斯噪声退化模型下的残差学习思想，掌握预训练权重加载、网络推理、结果保存和 PSNR/SSIM 评价流程。
2. 掌握阈值分割、Canny 边缘检测、轮廓检测、K-means 聚类分割和 Watershed 分割的基本假设、关键参数和适用场景。
3. 理解 U-Net 编码器-解码器结构、跳跃连接、像素级二值 mask 输出，以及 IoU、Accuracy 等分割评价指标。
4. 对比传统方法和深度学习方法在可解释性、参数依赖、数据依赖、泛化能力和失败案例上的差异。

2 实验内容

实验代码包包含三个子目录。KAIR 目录用于 DnCNN 去噪实验，输入测试集位于 `testsets/`，预训练模型位于 `model_zoo/`，推理结果保存到 `results/<testset>_<model>/`。Classical-Image-Segmentation-On-Microorganisms 目录用于微生物图像传统分割，对 `test_data/` 中的两张图像进行多算法可视化。Unet 目录用于 X-ray 医学图像分割，测试脚本读取 `dataset/test/xray/` 和 `dataset/test/mask/`，输出原图、预测 mask、真实 mask 的横向拼接图。

3 实验步骤

1. 阅读 `KAIR/main_test_dncnn.py` 和 `models/network_dncnn.py`，确认输入图像、噪声退化、模型权重、输出图像和日志的关系。
2. 使用 `dncnn_15`、`dncnn_25`、`dncnn_50` 等模型在 `set5` 上完成去噪推理，保存噪声图 `_L`、复原图 `_E`、原图 `_H` 和日志。
3. 阅读传统分割主程序和各算法脚本，分别在默认参数和调整参数下运行 `main.py`，生成多算法分割总览图并比较参数变化影响。
4. 阅读 `Unet/network.py` 和 `test_segmentation.py`，加载 `checkpoint/UNET_model.pth`，对 16 张测试 X-ray 图像进行分割并记录 IoU/Accuracy。
5. 汇总三类任务的图像结果、指标结果和代码结构，分析参数、模型假设及失败原因。

4 实验过程

4.1 DnCNN 图像复原

`main_test_dncnn.py` 通过命令行参数指定 `model_name`、`testset_name`、`noise_level_img` 和 `device`。当测试集路径同时作为低质量图像和高质量图像路径时，脚本会在原图上叠加均值为 0、标准差为 $\sigma/255$ 的高斯噪声，得到输入噪声图。网络输出复原图后，脚本逐图计算 PSNR 和 SSIM，并保存三类图像。

DnCNN 类由首层卷积、若干中间卷积块和尾层卷积组成。灰度模型中输入通道数和输出通道数均为 1，中间通道数为 64；普通 `dncnn_15/25/50` 使用 17 个卷积层，`blind` 模型使用 20 个卷积层。前向传播中 `self.model(x)` 学习的是噪声残差 n ，最终 `return x-n` 表示从噪声图中减去估计噪声，得到干净图像。残差学习降低了网络直接拟合干净图像的难度，也使高斯噪声残差的统计分布更稳定。

4.2 传统图像分割

传统分割主程序对两张微生物图像依次执行固定阈值、Canny、轮廓检测、K-means 和 Watershed。参数调整前配置中，固定阈值和轮廓检测使用阈值 127，Canny 双阈值为 100/200，K-means 聚类数 $K = 100$ ，Watershed 使用 3×3 膨胀核、膨胀 3 次，并以 $0.5 \cdot \max(dist)$ 作为距离变换前景阈值。参数调整后，固定阈值和轮廓检测阈值改为 50，Canny 双阈值改为 50/250，K-means 聚类数改为 $K = 50$ ，Watershed 前景阈值系数改为 0.7。K-means 的终止条件保持为 `EPS + MAX_ITER`、最大迭代 10 次、精度 1.0，随机初始化尝试次数为 10。

实验过程中分别保存参数调整前后的分割可视化结果，并将各算法输出统一转换为二值 `mask`，与人工标注进行 IoU/Dice 统计。这样既能观察不同参数下的视觉变化，也能用区域重叠指标判断传统算法与标注结果之间的差异。

4.3 U-Net 医学图像分割

U-Net 使用四级下采样和四级上采样。编码端每一级由两层卷积、BatchNorm 和 ReLU 构成，并通过 MaxPool 扩大感受野；解码端先上采样，再与对应编码层特征拼接，利用跳跃连接恢复边界与局部细节；末端 1×1 卷积把 64 通道映射到单通道概率图，Sigmoid 输出每个像素属于目标区域的概率。

测试脚本将 X-ray 和 `mask` `resize` 到 256×256 ，模型输出后以 0.5 为阈值计算二值预测。IoU 计算 $TP/(TP + FP + FN)$ ，更关注前景区域重叠程度；Accuracy 计算 $(TP + TN)/(TP + TN + FP + FN)$ ，在背景占比很高时可能偏乐观，因此医学分割中不能只看 Accuracy。

5 网络结构与算法原理分析

5.1 传统分割方法的基本假设

传统分割方法通常假设目标与背景在灰度、颜色、边缘连续性或空间连通性上存在可分差异。固定阈值方法假设单个灰度阈值足以区分前景和背景；Canny 假设目标边界对应明显梯度变化；轮廓检测假设二值图中的连通边界能够代表目标形状；K-means 假设像素可在颜色空间中被聚为若干紧凑类别；Watershed 假设距离变换或梯度图中的局部结构可以提供可靠的前景、背景和未知区域。它们的优点是计算简单、参数含义直观、可解释性强；缺点是对光照、噪声、纹理、粘连和阈值非常敏感，参数从一张图迁移到另一张图时往往需要重新调节。

5.2 DnCNN 核心结构




图 1: DnCNN 残差学习结构示意图

DnCNN 的核心不是直接预测干净图像，而是预测噪声残差。代码中 `DnCNN.forward` 先令 `n = self.model(x)`，再返回 `x-n`。这种设计把图像复原转化为噪声估计问题，适合高斯噪声这类统计分布相对稳定的退化。相比直接学习干净图像，残差学习让网络重点拟合噪声分量，目标分布更集中，优化难度更低，也更容易保留输入图像中的主体结构。实验中的普通灰度 DnCNN 使用 17 层卷积、64 个中间通道，输入和输出通道均为 1。预训练权重 `dncnn_15`、`dncnn_25`、`dncnn_50` 分别对应不同噪声等级，因此模型与噪声强度是否匹配会显著影响复原结果。

5.3 U-Net 核心结构




图 2: U-Net 编码器-解码器与跳跃连接结构示意图

U-Net 通过下采样提取上下文语义，通过上采样恢复空间分辨率，并把编码端的浅层细节与解码端的深层语义进行拼接。代码中的 `torch.cat((e4,d5), dim=1)` 等语句就是跳跃连接，它能把边界、纹理和位置信息传回解码阶段，缓解连续下采样造成的细节丢失。没有跳跃连接时，解码器主要依赖低分辨率语义特征恢复 mask，边缘会更粗糙；加入跳跃连接后，浅层特征中的局部梯度和轮廓信息能辅助恢复齿根、牙冠边界和上下牙弓分离关系。最后一层 1×1 卷积把通道数压缩为单通道，Sigmoid 输出每个像素属于目标区域的概率，再通过阈值化得到预测 mask。

6 实验结果分析

6.1 DnCNN 去噪结果




图 3: set5 中 baby 图像在 $\sigma = 25$ 噪声下的不同模型去噪对比


图 4: set5 中 dncnn_25 在 $\sigma = 25$ 噪声下的多图像去噪对比

表 1: DnCNN 不同模型与噪声设置下的平均指标

模型	测试集	噪声强度	平均 PSNR/dB	平均 SSIM
dncnn_15	set5	5	33.80	0.8930
dncnn_25	set5	5	31.15	0.8437
dncnn_50	set5	5	28.08	0.7678
dncnn_15	set5	25	24.10	0.4989
dncnn_25	set5	25	31.27	0.8709
dncnn_50	set5	25	28.33	0.7788

从图 1 和图 2 可以先直观看到 DnCNN 的复原特征：噪声图中的颗粒状高斯噪声被明显压制，人脸、鸟身体和蝴蝶翅膀的大尺度轮廓都恢复得比较稳定；但帽子编织纹理、鸟背景枝叶和蝴蝶翅脉附近的细小纹理会出现一定平滑。图 1 中同样是 $\sigma = 25$ 的输入，dncnn_25 的结果最接近原图，脸部噪声被压下去的同时眼睛、嘴唇和帽子边缘仍保留较好；dncnn_15 去噪不足，脸部和背景仍有可见噪声；dncnn_50 则明显过平滑，脸部和帽子纹理被削弱。表 1 的定量结果与图像观察一致：dncnn_25 在 $\sigma = 25$ 的 set5 上达到 31.27 dB 和 0.8709 SSIM，明显优于 dncnn_15 和 dncnn_50 的错配设置。通常

噪声强度 σ 越大，图像退化越严重，PSNR 和 SSIM 会下降；如果模型训练噪声等级与测试噪声等级匹配，下降可以被有效缓解，但如果低噪声模型处理高噪声图会残留噪声，高噪声模型处理低噪声图又会过度平滑。低噪声 $\sigma = 5$ 下，dncnn_15 的指标最高，说明非 blind DnCNN 强依赖噪声强度假设。实际使用时应优先估计噪声等级，或选择 blind denoising 模型来提升适应性。




图 5: 真实噪声图像 real_faces 的 DnCNN color blind 去噪结果

在 real_faces 实验中，使用 dncnn_color_blind 对真实噪声人脸图像直接推理，运行命令为 `python main_test_dncnn.py --model_name dncnn_color_blind --testset_name real_faces --need_degradation False`。从图中可以看到，去噪后人物面部和背景中的彩色噪声有所减弱，局部块状噪声被平滑，但真实噪声不是由脚本合成的加性高斯噪声，它可能同时包含压缩伪影、传感器噪声、低照度噪声和颜色偏移。日志中虽然仍打印了 PSNR/SSIM，但这是因为代码把输入路径同时作为 H_path，并不代表存在真正的无噪声参考图。PSNR 和 SSIM 都是全参考指标，需要干净真值图像作为比较对象；真实噪声场景下只有退化图，没有对应的干净人脸，因此无法直接计算可信的 PSNR/SSIM。此时更合理的评价方式是主观视觉比较，或使用 NIQE、BRISQUE 等无参考图像质量指标，或构造有配对干净图的真实噪声数据集。

6.2 传统分割结果




图 6: 参数调整前两张微生物图像的传统分割结果




图 7: 参数调整后两张微生物图像的传统分割结果




图 8: 传统分割测试图像对应的人工标注结果

表 2: 传统分割算法参数与效果分析

算法名称	关键参数	主要视觉效果	优点	缺点	平均 IoU/Dice (前 → 后)
固定阈值	前: 阈值 127/255; 后: 阈值 50/255, 均取反	调整前能提取部分目标; 调整后接近全黑, 目标主体丢失。	简单快速。	对阈值和取反逻辑极敏感。	0.0786/0.1454 → 0.0000/0.0000
Canny 边缘	前: 100/200; 后: 50/250	调整后弱边缘和内部纹理更多, 圆形边界更密集。	边界定位清晰。	边缘线不等于完整 mask。	0.1254/0.2227 → 0.1567/0.2710
轮廓检测	前: 阈值 127/255; 后: 阈值 50/255, 线宽 3	调整前有部分轮廓; 调整后接近全黑。	便于形状分析。	强依赖二值化质量。	0.1982/0.3278 → 0.0000/0.0000
K-means	前: $K = 100$; 后: $K = 50$, 迭代 10, 精度 1.0	两组均能给出区域结果; 调整后类别减少, 结果更粗略。	可利用颜色/灰度分布。	K 选择敏感。	0.1927/0.3228 → 0.1959/0.3271
Watershed 相关	前: $0.5 \max(dist)$; 后: $0.7 \max(dist)$, 膨胀 3 次	两组均突出大区域; 调整后前景标记更保守。	适合粘连目标。	marker 和距离阈值敏感。	0.4218/0.5902 → 0.4295/0.5968

从图 5、图 6 和人工标注图对比可以看到, 传统分割结果并不是参数越“宽松”越好。固定阈值和轮廓检测在调整前还能提取第一张图的中心微生物团块和第二张图的环形结构; 调整后阈值结果和轮廓结果出现大面积全黑, 与人工标注几乎没有重叠, 因此平均 IoU/Dice 均降为 0。Canny 调整后保留了更多弱边缘, 平均 IoU 从 0.1254 提升到 0.1567, Dice 从 0.2227 提升到 0.2710, 但边缘线仍不是完整区域 mask。K-means 的平均指标变化很小, 说明从 $K = 100$ 调整到 $K = 50$ 后整体区域重叠基本稳定, 只是视觉上更粗略。Watershed 的平均 IoU/Dice 最高, 调整后达到 0.4295/0.5968, 说明距离变换和前景标记对这两张显微图的目标区域更有效。整体来看, 传统分割方法的可解释性强, 但对灰度分布、阈值方向、取反逻辑和后处理非常敏感, 必须结合可视化和 Dice/IoU 定量指标共同调参。

从算法适用性看, 固定阈值分割更适合目标与背景灰度范围稳定、分界阈值可以人工确定的图像; Otsu 通过最大化类间方差自动选阈值, 更适合前景和背景近似双峰、两类比例不过度失衡的灰度分布。若图像存在明显光照不均、背景纹理复杂或前景占比过小, Otsu 得到的全局阈值就容易偏向背景。Canny 的结果不能直接等价于完整目标区

域，是因为它检测的是梯度突变位置，只给出边界响应，不能保证边缘闭合，也不会自动填充目标内部，因此更适合作为轮廓线索或后续区域构造的输入。K-means 的聚类数 K 过小时会把不同组织、纹理或灰度层次合并，导致欠分割； K 过大时又会把噪声、染色差异和局部纹理拆成多个伪类别，造成碎片化。区域生长对种子点和相似性阈值敏感，是因为生长路径从种子位置开始累积：种子落在目标内部时结果较稳定，落在背景或边界附近则会偏移；相似性阈值过小会欠生长，过大则容易泄漏到背景。Watershed 容易过分割，是因为噪声、细小纹理和局部极值都会形成额外“集水盆地”，可通过高斯或中值滤波、形态学开闭运算、距离变换平滑、连通域筛选，以及构造更可靠的 sure foreground/sure background marker 来减少错误分水岭。


6.3 U-Net 分割结果



(a) 101: X-ray 原图、预测 mask、真实 mask



(b) 111: 高 IoU 样本



(c) 116: 低 IoU 样本

图 9: U-Net 医学图像分割代表结果

表 3: U-Net 测试集代表样本指标

图像编号	IoU	Dice	Accuracy	备注
101	0.8186	0.9002	0.9461	边界较完整，主体区域重叠较好
111	0.8636	0.9268	0.9606	本组最高 IoU/Dice，形状恢复最稳定
116	0.6592	0.7946	0.8861	本组最低 IoU/Dice，边缘误差较明显
全部 16 张平均	0.7988	0.8875	0.9403	整体分割稳定，但低分样本拉低均值

U-Net 的平均 Accuracy 达到 0.9403, 说明绝大多数像素类别判断正确; 平均 IoU 为 0.7988, 平均 Dice 为 0.8875, 二者都反映前景区域与真实 mask 的重合程度, 其中 Dice 对重叠区域的表达更直观, 数值通常高于 IoU。从图像上看, 101 号样本的预测 mask 能覆盖上下牙列主体, 但局部牙根边缘仍比真实 mask 更粗糙; 111 号样本 IoU/Dice 分别为 0.8636/0.9268, 是本组高分样本, 预测区域与真实 mask 的上下牙弓形状较一致, 中间咬合间隙和外轮廓保留较好; 116 号样本 IoU/Dice 降至 0.6592/0.7946, 预测 mask 中上下牙列局部连接、边界扩张和缺口位置都与真实标注差异更大, 说明模型在对比度较低、牙根边界重叠或局部结构复杂时更容易出错。虽然 116 的 Accuracy 仍有 0.8861, 但这是因为背景像素占比较高, 背景判断正确会抬高 Accuracy, 不能完全代表前景分割质量。因此医学图像分割更应优先观察 IoU、Dice 和可视化边界质量, 而不能只看 Accuracy。

U-Net 中跳跃连接有助于恢复边界和细节, 是因为编码器深层特征虽然语义更强, 但经过多次下采样后空间分辨率降低, 牙齿边缘、齿根细节和上下牙弓间隙等局部信息会被压缩甚至丢失。跳跃连接把编码器浅层的高分辨率纹理、梯度和位置信息直接拼接到解码器, 使解码器在恢复 mask 时不仅依赖深层语义判断“哪里是牙列区域”, 还能够利用浅层轮廓线索判断“边界应落在哪里”。从 111 号高分样本看, 预测 mask 与真实 mask 的弓形轮廓和中间间隙较一致, 说明跳跃连接对边界定位有明显帮助; 而 116 号低分样本在局部连接和边界扩张处仍有误差, 说明当原图对比度低、边界重叠或局部结构复杂时, 跳跃连接能缓解细节丢失, 但不能完全消除标注差异和图像质量带来的不确定性。

7 代码修改说明

1. 传统分割参数修改主要位于 `threshold_segmentation.py`、`canny_edge_detection.py`、`contour_detection.py`、`kmeans_segmentation.py` 和 `watershed_segmentation.py`。调整原因是观察不同阈值、边缘阈值、聚类数和距离阈值对微生物目标提取的影响。
2. 固定阈值和轮廓检测的二值阈值由 127 调整为 50, 是为了观察阈值降低对二值化与轮廓连通性的影响。实际结果显示, 在当前取反二值化流程下该调整会使阈值和轮廓结果接近全黑, 说明参数需要结合图像灰度分布验证。
3. Canny 双阈值由 100/200 调整为 50/250, 是为了保留更多弱边缘, 同时让强边缘判定更严格, 观察边缘召回与噪声增加之间的权衡。
4. K-means 聚类数由 $K = 100$ 调整为 $K = 50$, 是为了减少颜色类别过细导致的碎片化现象, 使区域结果更平滑。
5. Watershed 距离变换前景阈值系数由 0.5 调整为 0.7, 是为了使 `sure_fg` 前景标记更保守, 扩大未知边界区域, 观察粘连和边界不确定区域的变化。
6. 传统分割部分额外增加了 Dice/IoU 指标计算代码: 在读取 `test_data/` 图像和

test_gts/ 人工标注后, 将各算法输出统一二值化为 mask, 并按 $IoU = TP/(TP + FP + FN)$ 、 $Dice = 2TP/(2TP + FP + FN)$ 逐图逐算法统计, 再汇总调整前后的平均 IoU/Dice, 用于定量分析传统算法与人工标注之间的差异。

7. U-Net 测试脚本在原有 IoU 和 Accuracy 统计基础上补充了 Dice 系数计算。代码对 Sigmoid 输出阈值化后的预测 mask 与真实 mask 统计 TP 、 FP 、 FN , 再计算 $Dice = 2TP/(2TP + FP + FN)$, 并与 IoU、Accuracy 一起输出单张图像指标和 16 张测试图像的平均指标, 便于同时观察区域重叠质量和背景像素占比造成的 Accuracy 偏差。

8 总结与心得

本次实验展示了三类方法在视觉任务中的不同工作方式。DnCNN 通过学习噪声残差完成图像复原, 指标结果清楚表明模型权重与噪声强度匹配很重要; 当噪声假设错配时, 网络可能欠去噪或过平滑。传统分割方法不需要训练数据, 参数含义直观, 适合快速探索和可解释分析, 但对阈值、边缘阈值、聚类数、marker 等参数高度敏感, 迁移到不同图像时往往需要重新调参。U-Net 依靠编码器-解码器和跳跃连接进行像素级预测, 整体指标明显稳定, 但它依赖标注数据和预训练权重, 且失败样本需要结合前景比例、边界模糊和标签质量分析。

从工程角度看, 传统图像处理方法最大的优势是可解释性强、部署成本低、通常不需要大量标注数据, 在小样本或快速验证场景中很有价值; 局限是参数依赖明显, 可迁移性弱, 换一批光照、噪声或目标形态后往往需要重新调参。深度学习方法的数据依赖更强, 训练和部署成本更高, 也需要 GPU、框架环境和标注数据支撑; 但一旦训练数据覆盖充分, 它对复杂纹理、形变和噪声的适应能力通常更好, 推理流程也更统一。评价指标也必须与任务匹配: 去噪可使用 PSNR/SSIM, 因为有参考原图; 分割任务需要 IoU/Dice 等区域重叠指标, 单独使用 Accuracy 容易在前景较小的医学图像中产生误判。