空域滤波

卷积与边缘提取算子

- 一、空域滤波概述
  - 核心背景：传统点处理存在局限，未考虑像素空间位置信息，仅依赖单个像素灰度或全局处理
  - 核心目的：去除图像中无关变化，保留任务所需关键信息，包括提取边缘/轮廓、抑制噪声、锐化图像细节
  - 关键定位：卷积神经网络（CNN）中的核心特征提取算子，是计算机视觉的基础操作
  - 基础理论支撑：线性时不变系统（LSIS）
    - 线性性：若输入为$af_1 + f_2$，则输出为$ag_1 + g_2$，满足线性组合映射关系
    - 平移不变性：输入图像平移a个单位，输出图像同步平移a个单位，即$f(x-a) \rightarrow g(x-a)$
  - 发展历程：从1D移动平均（MA）逐步演进至2D滤波，后续支撑Cognitron、LeNet-5、AlexNet等CNN模型发展
- 二、核心概念与基础操作
  - 2.1 2D滤波与卷积
    - 核心定义与公式
      - 2D滤波：$h[m,n] = \sum_{k,l} f[k,l] I[m+k, n+l]$，输入图像与滤波器核直接进行加权求和
      - 2D卷积：$h[m,n] = \sum_{k,l} f[k,l] I[m-k, n-l]$，滤波器核翻转后与输入图像加权求和
      - 交叉相关性：$G[i,j] = \sum_{u=-k}^{k} \sum_{v=-k}^{k} H[u,v] F[i+u, j+v]$，无核翻转，与滤波本质等价
    - 关键区别：核心差异在于滤波器核是否翻转，当核为对称时，滤波与卷积效果完全一致
    - 实用工具：Python中可通过scipy.signal.convolve2d实现2D卷积操作
  - 2.2 线性滤波器关键性质
    - 平移不变性：滤波效果与像素在图像中的位置无关，每个滑动窗口均采用相同权重计算
    - 可分离滤波器
      - 定义：2D滤波器可分解为一个行向量与一个列向量的乘积
      - 核心优势：大幅降低计算成本，非分离滤波计算量为$M^2 \times N^2$，分离滤波仅为$M^2 \times 2N$（M为图像尺寸，N为核尺寸）
      - 典型示例：方框滤波、高斯滤波均属于可分离滤波器
  - 2.3 边界处理方法
    - 核心问题：当滤波窗口超出图像边界时，需补充边界外像素以完成计算
    - 常用解决方案
      - 零填充：边界外补充像素值均为0
      - 对称填充：沿图像边界进行镜像翻转补充
      - 循环填充：以图像为周期，环绕补充像素
    - 输出模式分类
      - Full模式：滤波器核与图像有任何重叠即计算，输出尺寸大于输入
      - Same模式：输出图像与输入图像尺寸一致
      - Valid模式：滤波器核完全在图像内部才计算，输出尺寸小于输入
- 三、空域滤波器分类及原理
  - 3.1 平滑滤波器（Smoothing Filters）
    - 核心作用：对图像进行模糊处理，抑制噪声干扰，减少灰度值突变
    - 线性平滑滤波器
      - 方框滤波（Box Filter）
        - 别名：2D矩形滤波器、方形均值滤波器
        - 工作原理：用当前像素邻域内所有像素的平均值替换该像素
        - 特点：实现简单，但易产生“块状”伪影，平滑效果较生硬
      - 高斯滤波器（Gaussian Filter）
        - 数学公式：$n_\sigma[i,j] = \frac{1}{2\pi\sigma^2} e^{-\frac{1}{2}\left(\frac{i^2+j^2}{\sigma^2}\right)}$
        - 核心特性：权重随像素与中心距离的增大呈高斯分布衰减，平滑效果自然柔和
        - 参数选择：核尺寸推荐为$Size = 6\sigma + 1$（经验值），σ越大平滑效果越强
        - 关键优势：具备可分离性，且自卷积后仍为高斯分布（两次σ卷积等价于一次$\sigma\sqrt{2}$卷积）
    - 非线性平滑滤波器
      - 中值滤波器（Median Filter）
        - 计算公式：$R = mid\{z_k | k = 1, 2, ..., n\}$，取邻域内像素灰度值的中值作为输出
        - 核心优势：相比均值滤波器，更适合去除椒盐噪声，且能较好保留图像边缘细节
      - 最大滤波器（Max Filter）
        - 计算公式：$R = max\{z_k | k = 1, 2, ..., n\}$，取邻域内像素灰度最大值
        - 主要用途：寻找图像中的最亮点，突出亮区域
      - 最小滤波器（Min Filter）
        - 计算公式：$R = min\{z_k | k = 1, 2, ..., n\}$，取邻域内像素灰度最小值
        - 主要用途：寻找图像中的最暗点，突出暗区域
      - 双边滤波（Bilateral Filter）
        - 核心原理：结合空间域核（G_s，基于像素空间距离）和范围核（G_b，基于像素灰度差异）的加权滤波
        - 权重公式：$w(i,j,k,l) = exp\left(-\frac{(i-k)^2+(j-l)^2}{2\sigma_d^2} - \frac{\|f(i,j)-f(k,l)\|^2}{2\sigma_r^2}\right)$
        - 输出公式：$\hat{I}(i,j) = \frac{1}{W_{sb}} \sum_{m,n} I(m,n) G_s(i-m, j-n) G_b(I(m,n) - I(i,j))$
        - 优势：在抑制噪声的同时，能有效保留边缘细节，避免边缘模糊
      - 引导滤波（Guided Image Filtering）
        - 核心原理：基于引导图与输入图的局部 affine 变换模型$g = Ah + b$
        - 优化方式：通过岭回归最小化误差$\sum \|Ah + b - f\|^2 + \lambda \|A\|^2$，求解系数$A$和$b$
        - 优势：计算效率高（时间复杂度$O(N)$），边缘保留效果优于联合双边滤波
  - 3.2 锐化滤波器（Sharpening Filters）
    - 核心作用：突出图像细节特征，增强模糊区域的清晰度，提升图像整体对比度
    - 基于一阶导数（梯度算子）
      - 核心原理：梯度幅值反映像素灰度变化率（$E_s = \sqrt{I_x^2 + I_y^2} \approx |I_x| + |I_y|$），梯度方向垂直于边缘方向（$E_\theta = tan^{-1}\frac{I_y}{I_x} + \frac{\pi}{2}$）
      - 常用梯度算子
        - Roberts 交叉梯度算子：采用2×2模板，边缘检测定位精准，但对噪声敏感
        - Prewitt 梯度算子：采用3×3模板，融入邻域平均操作，具备一定噪声抑制能力
        - Sobel 梯度算子：采用3×3模板，对中心像素赋予权重2，增强中心像素重要性
          - 水平边缘检测核：$K_x = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix}$
          - 垂直边缘检测核：$K_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$
          - 优势：近似高斯平滑后的导数，抗噪声能力强，边缘检测效果更稳定
    - 基于二阶导数
      - 拉普拉斯算子（Laplacian）
        - 数学公式：$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y)$
        - 模板设计原则：中心系数与周边系数符号相反，所有系数之和为0，满足旋转不变性（各向同性）
        - 增强公式：$g(x,y) = f(x,y) \pm \nabla^2 f(x,y)$（中心系数为负时取“-”，为正时取“+”）
        - 局限：对噪声极为敏感，需先进行平滑预处理
      - 高斯拉普拉斯（LoG）滤波器
        - 核心原理：先通过高斯滤波器平滑图像，再用拉普拉斯算子进行锐化，公式为$\nabla^2 G(x,y;\sigma) = \left(\frac{x^2+y^2}{\sigma^4} - \frac{2}{\sigma^2}\right) G(x,y;\sigma)$
        - 优势：大幅降低噪声对锐化效果的影响，通过“零交叉”现象可精准定位边缘
    - 非锐化掩模（Unsharp Masking）
      - 核心原理：原始图像减去模糊图像得到细节图像，再将细节图像与原始图像叠加（$sharpened = f + \alpha \times detail$）
      - 传统应用：暗房冲印中的锐化技术，通过失焦负片与原负片叠加实现
- 四、边缘检测算法
  - 4.1 边缘检测基础
    - 边缘定义：图像中亮度、纹理或颜色发生急剧变化的位置，是物体形状和场景结构的核心承载信息
    - 边缘成因：表面法向不连续、深度不连续、表面颜色不连续、光照条件不连续
    - 核心步骤：图像平滑（抑制噪声）→ 梯度计算（获取灰度变化率）→ 边缘定位（筛选有效边缘）
  - 4.2 经典边缘检测算法
    - Sobel 边缘检测
      - 流程：高斯平滑 → 计算I_x（水平梯度）和I_y（垂直梯度）→ 梯度幅值与方向计算 → 阈值筛选边缘
      - 优势：抗噪声能力较强，边缘检测稳定性高，边缘宽度至少为2像素
    - Canny 边缘检测（主流常用算法）
      - 核心流程
        - 高斯平滑：使用高斯滤波器去除图像噪声，为边缘检测做准备
        - 梯度计算：求解梯度幅值和方向，反映灰度变化强度与边缘方向
        - 非极大值抑制（NMS）：沿梯度方向保留局部最大值像素，细化边缘宽度
        - 滞后阈值化：设置双阈值（高阈值T_h、低阈值T_l），强边缘直接保留，弱边缘需连接强边缘才保留
      - 参数影响：σ（高斯核标准差）越大，检测的“大尺度”边缘越多；σ越小，越能检测细边缘
  - 4.3 深度学习边缘检测方法
    - 代表算法：Holistically-Nested Edge Detection（HED）、Richer Convolutional Feature（RCF）、Contour-Aware Semantic Segmentation Network（CASENet）
    - 核心优势：相比传统算法，能更好捕捉复杂场景下的边缘特征，边缘检测精度更高
- 五、关键应用与拓展
  - 5.1 模板匹配（Template Matching）
    - 定义：在输入图像中寻找与给定模板图像相同或相似的目标区域，确定目标位置
    - 分类：单目标模板匹配（仅寻找一个最优匹配位置）、多目标模板匹配（设置相似度阈值，筛选所有符合条件的匹配位置）
    - 相似度度量方法
      - 互相关：$R(i,j) = \sum_{m,n} I(m,n) T(m-i, n-j)$
      - 归一化互相关：$R(i,j) = \frac{\sum_{m,n} I(m,n) T(m-i,n-j)}{\sqrt{\sum_{m,n} I^2(m,n)} \sqrt{\sum_{m,n} T^2(m-i,n-j)}}$，适用于亮度变化场景
  - 5.2 典型应用场景
    - 图像去噪：高斯滤波、双边滤波去除高斯噪声，中值滤波去除椒盐噪声
    - 图像增强：平滑滤波后结合阈值分割实现简单图像分割，非锐化掩模技术增强印刷/扫描图像细节
    - 模糊处理：运动模糊去除（通过匹配自然图像梯度分布实现），多次双边滤波实现图像“卡通化”
    - 混合图像生成：结合低通滤波（保留大尺度特征）和高通滤波（保留细节特征），生成具有双重视觉效果的混合图像
    - 特定领域应用：超声成像低分辨率/边缘模糊改善、武器系统目标识别与定位、医学图像细节增强
  - 5.3 补充拓展
    - 自然图像统计特性：自然图像的梯度直方图呈重尾分布，模糊图像的梯度分布与自然图像存在显著差异
    - 滤波近似：二项式滤波器可近似高斯滤波器，在部分场景下降低计算复杂度

计算机视觉（限选）课内参考资料