

传统图像分割方法

一、总览：传统分割的考试框架

类别	核心依据	代表方法	高频考法
阈值与边界	基于不连续性；寻找子区域或目标的划分阈值/边界。	固定阈值、Otsu 大津法、Canny 边缘检测、轮廓检测。	问原理、优缺点、为什么边缘不等于区域、固定阈值和 Otsu 适用条件。
区域与聚类	基于相似性；直接对像素或区域进行聚类/合并。	区域生长、分水岭、K-means、Mean Shift。	问参数敏感性、过分割/欠分割、粘连目标怎么处理、K 过大过小的影响。
实验分析	比较多种算法输出，修改关键参数，分析与人工标注的差异。	main.py 输出 segmentation_results，至少 4 种算法对比。	问如何写结果表格、如何改参数、如何解释失败案例。

二、概念与分类题

Q1. 什么是图像分割？它和图像分类、目标检测有什么区别？

关键词：像素级预测；区域划分；边界；类别/实例

图像分割是把图像划分为若干有意义的区域，目标是为像素或区域赋予类别/实例标签。图像分类只输出整张图像的类别；目标检测输出目标框和类别；图像分割输出像素级区域边界，因此比分类和检测更关注空间位置、形状和边界。答题时可以补一句：语义分割关注每个像素属于什么类别；实例分割还要区分同一类别中的不同个体。

Q2. 图像分割应满足哪些基本原则？

关键词：完备性；互斥性；区域一致性；相邻区域差异性

可按四点回答：第一，完备性，所有子区域的并集应覆盖整个图像域；第二，互斥性，不同区域之间不应重叠；第三，区域一致性，同一区域内像素满足某种相似性准则，如灰度、颜色、纹理或类别相同；第四，相邻区域差异性，相邻区域应在所采用准则上存在差异。

这道题常用于判断你是否理解“分割”不是简单画边，而是要形成完整、互斥且有意义的区域划分。

Q3. 传统图像分割方法可以怎样分类？

关键词：不连续性 vs 相似性；阈值/边界 vs 区域/聚类

课程中把传统分割分成两大类：一类是“阈值与边界”，基于不连续性寻找阈值或边界，包括固定阈值、Otsu、Canny 等；另一类是“区域与聚类”，基于相似性直接对区域或像素聚类，包括区域生长、分水岭、K-means、Mean Shift 等。简答题中建议先给分类，再各举 2 个例子，最后点出二者思想差异：前者看“哪里断开”，后者看“哪里相似”。

Q4. 传统分割方法的共同缺陷是什么？

关键词：人工设计；无语义；噪声敏感；参数依赖；泛化弱

主要缺陷包括：严重依赖人工设计，缺乏语义理解；对噪声、纹理和光照变化敏感，鲁棒性差；缺少全局理解和上下文建模能力；参数依赖度高，泛化能力弱；相似性度量由人工定义，难以处理复杂模式。

高分答法：不要只说“效果不好”，要说明为什么不好：它只看低层特征，如灰度、颜色、梯度、局部相似性，而不知道图像中“是什么物体”。

三、阈值与边界方法

Q5. 固定阈值分割的原理、优点和缺点是什么？

关键词：像素值；人工阈值；高对比度；无空间信息

原理：根据像素灰度或颜色值是否超过某个阈值，把像素分成前景和背景。例如灰度值大于 127 判为白色，否则判为黑色。

优点：简单直观、计算量低、可解释性强，适合前景和背景灰度差异明显、光照较稳定的高对比度图像。

缺点：阈值通常需要人工设置；忽略空间信息；对噪声和光照变化敏感；不能理解语义；复杂背景或低对比度图像中容易失败。

```
cv2.threshold(img, 127, 255, cv2.THRESH_BINARY)
```

Q6. Otsu 大津法的核心思想是什么？为什么说它是自动阈值法？

关键词：类间方差最大；自动阈值；直方图双峰假设

Otsu 的核心思想是遍历所有可能的灰度阈值 T ，把图像分成前景和背景两类，选择使两类“类间方差”最大的阈值。类间方差越大，说明前景和背景分得越开。

它被称为自动阈值法，是因为阈值不是人工指定，而是根据图像灰度直方图统计自动计算得到。常用表达式可写作：

$T^* = \operatorname{argmax} \sigma_B^2(T) = \omega_0(T) * \omega_1(T) * [\mu_0(T) - \mu_1(T)]^2$ 。

```
cv2.threshold(img, 0, 255, cv2.THRESH_BINARY + cv2.THRESH_OTSU)
```

Q7. 固定阈值和 Otsu 分割分别适合什么样的灰度分布？

关键词：固定阈值靠经验；Otsu 靠直方图双峰；二分类

固定阈值适合先验明确、成像条件稳定的场景，例如前景灰度总是明显高于背景，可以直接设定经验阈值。

Otsu 更适合前景和背景在灰度直方图上近似双峰分布的二分类问题。它不适合灰度分布单峰、多峰混杂、前景比例极小、光照不均匀或噪声较强的图像。

一句话模板：固定阈值依赖人为经验，Otsu 依赖双峰统计假设；两者都缺少空间和语义信息。

Q8. Canny 边缘检测的结果为什么不等价于完整目标区域？

关键词：边界信息；不闭合；纹理边缘；无语义

Canny 输出的是边缘像素，而不是区域 mask。边缘通常只是目标轮廓或纹理变化的位置，可能不闭合，也可能包含大量内部纹理边缘。

因此，Canny 可以作为分割的辅助信息，但要得到完整目标区域，通常还需要闭运算、轮廓填充、连通域筛选、区域生长或其他后处理。

这道题最容易考：边界信息 $\neq$ 区域分割；检测到边缘并不代表已经知道目标是什么。

易错点：不要把 Canny 的白色边缘图直接当成语义分割 mask。

```
edges = cv2.Canny(img, 100, 200)
```

Q9. Canny 的优势和缺陷是什么？

关键词：梯度边缘；噪声敏感；边界不闭合；语义缺失

优势：物理意义直观，计算效率高；基于梯度或灰度不连续性，不要求区域内部完全一致。

缺陷：对噪声非常敏感；阈值设置影响明显；边缘可能断裂，难以形成闭合边界；不能区分物体轮廓和纹理边缘，缺少语义理解。

实验分析时，如果看到 Canny 输出很多碎边，可以从噪声、纹理、阈值过低、未平滑等角度解释。

Q10. 轮廓检测在传统分割实验中通常起什么作用？

关键词：二值图；边界连通；候选区域；依赖预处理

轮廓检测通常基于二值图或边缘图，寻找连通边界并提取目标外轮廓或内轮廓。它常用于把边缘信息转化成候选目标区域，例如配合阈值分割、形态学闭运算、连通域筛选。

局限是它非常依赖前面的二值化或边缘检测结果：如果边缘断裂、噪声多、目标粘连，轮廓也会不稳定。

四、区域与聚类方法

Q11. 区域生长法的原理、优点和缺点是什么？

关键词：种子点；相似性阈值；连通性；泄漏

原理：从一个或多个预设种子点出发，按照相似性准则，如灰度差小于阈值，把邻域中满足条件的像素不断并入当前区域，直到没有新像素可加入。

优点：思想直观，能得到连续区域，对边界清晰、区域内部一致、形状较规则的目标效果较好。

缺点：严重依赖种子点位置和相似性阈值；对噪声、模糊边界敏感；不同遍历顺序可能导致不同结果；遇到弱边界时容易泄漏到背景。

易错点：种子点选错或阈值过大，区域会扩散到背景；阈值过小，目标会分割不完整。

`regiongrowth_segmentation(img, num_seeds=1, threshold=20, connectivity=8)`

Q12. 分水岭算法的原理是什么？为什么容易过分割？

关键词：地形；盆地；局部极小值；marker；过分割

分水岭把图像或梯度图看作地形，像素值看作海拔。水从低洼处逐渐上涨，不同盆地的水相遇处筑堤，堤的位置就是分割边界。

它容易过分割，是因为噪声、纹理和局部极小值会产生大量“小盆地”，每个小盆地都可能被当成一个区域。

缓解方法包括：平滑去噪、形态学开闭运算、距离变换、使用 marker 控制初始盆地、合并小区域或连通域筛选。

Q13. K-means 聚类分割的基本步骤是什么？

关键词：预设 K；迭代聚类；颜色特征；初值敏感

步骤：随机初始化 K 个聚类中心；把每个像素按特征距离分配给最近中心；重新计算每类均值作为新中心；迭代直到中心基本不变。用于图像分割时，特征可以是灰度、RGB 颜色，也可以加入坐标特征。

优点：简单高效，不需要人工指定边界或种子点。缺点：必须预设 K；对初始中心敏感；常只依赖颜色而忽略空间关系，因此容易把空间上分离但颜色相似的区域分为同一类。

易错点：K 不是“越大越好”。K 过大容易过分割，K 过小容易把不同区域合并。

`cv2.kmeans(img, K, None, criteria, 10, cv2.KMEANS_RANDOM_CENTERS)`

Q14. Mean Shift 均值偏移法的原理和特点是什么？

关键词：密度峰值；无需 K；带宽参数；复杂度高

原理：每个像素点在特征空间中沿局部数据密度梯度方向不断移动，直到收敛到某个密度峰值；收敛到同一密度中心的像素归为一类。

优势：不需要预设 K，对非球形或不规则分布有一定鲁棒性。缺点：计算复杂度较高，对空间半径、颜色半径等带宽参数敏感，高维特征下效果和效率都会变差。

`cv2.pyrMeanShiftFiltering(img, spatial_radius, color_radius, max_level)`

Q15. K-means 和 Mean Shift 有什么区别？

关键词：K vs 带宽；中心迭代 vs 密度爬坡；效率 vs 灵活性

K-means 需要预先给定聚类数 K，优化目标是让像素到所属类中心的距离尽可能小；它简单高效，但对 K 和初始中心敏感。

Mean Shift 不需要预设 K，而是通过寻找密度峰值自动形成类别；它对某些不规则分布更灵活，但计算开销较大，且依赖空间/颜色带宽参数。

考试答法：K-means 的关键参数是 K，Mean Shift 的关键参数是带宽；前者快但假设强，后者自动聚类但成本高。

五、参数分析与实验题

Q16. 传统分割实验 main.py 运行后应关注哪些输出？

关键词：main.py；segmentation_results；多算法对比；参数分析

实验中应进入 Classical-Image-Segmentation 目录运行 main.py，关注 segmentation_results 目录中的多算法输出图。

常见结果包括 Threshold Segmentation、Otsu Segmentation、Canny Edge Detection、Contour Detection、K-means Segmentation、Region Growth、Watershed Segmentation 以及汇总图。

报告中不能只贴图，应说明每种算法的输入、关键参数、主要视觉效果、优缺点，并分析与测试标签或人工标注之间的差异。

Q17. 实验报告中如何比较至少 4 种传统分割算法？

关键词：4 种算法；覆盖阈值/边界/区域/聚类；表格比较

推荐表格列：算法名称、关键参数、主要视觉效果、优点、缺点、与人工标注的差异。

推荐选择组合：固定阈值或 Otsu（阈值类）+ Canny 或轮廓检测（边界类）+ K-means 或 Mean Shift（聚类类）+ 区域生长或 Watershed（区域类）。这样覆盖课程两大分类，答案更完整。

算法	关键参数	参数变化的典型影响
固定阈值	threshold	阈值升高：前景变少，可能漏检；阈值降低：前景变多，可能把背景误分为目标。
Otsu	是否预平滑；二值化方向	预平滑可减弱噪声导致的局部干扰；若前景/背景灰度关系相反，需要反向二值化。
Canny	low_threshold、high_threshold、平滑核	阈值低：边缘多且噪声多；阈值高：边缘少且可能断裂；先平滑可减少伪边缘。
区域生长	种子点、threshold、connectivity	种子点偏离目标会失败；阈值大易泄漏，阈值小易欠分割；8 邻域比 4 邻域更容易扩张。
Watershed	marker、距离变换阈值、平滑/形态学	marker 太多会过分割，marker 太少会欠分割；预处理能减少噪声盆地。
K-means	K、初始中心、迭代次数	K 小会合并不同区域，K 大会产生碎片；随机初值可能导致结果不稳定。
Mean Shift	spatial_radius、color_radius、max_level	半径大分割更粗、平滑更强；半径小保留细节但碎片可能更多，计算更耗时。

Q18. K-means 聚类数 K 过大或过小会怎样影响分割结果？

关键词：K 过小欠分割；K 过大过分割；颜色相似会失败

K 过小：多个不同目标或背景区域被合并，出现欠分割，细节丢失。

K 过大：同一目标内部被切成多个颜色簇，出现过分割，结果碎片化。

分析时要结合图像颜色分布：如果目标和背景颜色接近，仅调 K 也未必能得到好结果，因为 K-means 缺少空间和语义约束。

Q19. 区域生长为什么对种子点位置和相似性阈值敏感？

关键词：初始条件敏感；阈值控制扩张；弱边界泄漏

区域生长是从种子点开始逐步扩张的，初始种子决定了算法从哪个区域开始理解“相似”。如果种子落在背景或噪声点，后续区域就会偏离目标。

相似性阈值决定能否并入邻域像素：阈值过小会使区域停止过早，目标不完整；阈值过大则会跨过弱边界，把背景吞进去。

Q20. Watershed 为什么容易过分割？可以用哪些预处理或 marker 策略缓解？

关键词：局部极小值；平滑；形态学；距离变换；marker

过分割的根本原因是噪声、纹理和细小灰度变化会产生大量局部极小值，每个极小值都可能形成一个盆地。

缓解策略：先用高斯滤波或中值滤波平滑图像；用形态学开运算去小噪点、闭运算填小孔；用距离变换寻找稳定的前景 marker；用背景 marker 限制范围；最后对小区域做合并或连通域筛选。

Q21. 传统分割实验中如何写“参数变化分析”？

关键词：参数含义；结果变化；原因解释；至少两类算法

写法模板：先说明改了哪个参数及其物理意义，再描述结果变化，最后解释原因。例如：“将 Canny 高阈值从 200 提高到 300 后，弱边缘被抑制，目标轮廓变得更稀疏，部分边界断裂；说明该图像边界梯度较弱，阈值过高会导致漏检。”

至少选两类算法改参数，例如 Canny 阈值 + K-means 的 K，或区域生长阈值 + Watershed 的 marker。

六、分析设计题模板

Q22. 设计一个传统方法完成微生物图像分割的流程。

关键词：预处理；Otsu/Watershed/K-means；形态学；IoU/Dice

可按“预处理—候选分割—后处理—评价”的框架回答。

预处理：灰度化、去噪、对比度增强或光照校正，降低噪声和背景不均匀影响。

候选分割：若前景背景灰度差异明显，使用 Otsu 或固定阈值；若目标粘连，结合距离变换和 Watershed；若颜色差异明显，可使用 K-means 或 Mean Shift；若只需轮廓，可用 Canny + 轮廓检测。

后处理：形态学开运算去噪、闭运算补洞，连通域筛选去除小区域，必要时填充轮廓得到完整 mask。

评价：若有标签，计算 IoU/Dice/Accuracy；若无标签，结合边界是否完整、目标是否粘连、是否漏检和误检进行定性分析。

Q23. 如果目标边界模糊、背景噪声多，传统方法容易出现什么问题？如何改进？

关键词：低对比度；噪声；弱边界；预处理；marker；深度学习

可能出现的问题：阈值法会把噪声当成前景或漏掉低对比度目标；Canny 会产生大量伪边缘或断裂边缘；区域生长会在弱边界处泄漏；Watershed 会过分割；K-means 会受噪声颜色干扰产生碎片。

改进方向：先平滑去噪或增强对比度；使用自适应阈值或 Otsu 代替固定阈值；结合形态学操作修补 mask；对粘连目标使用距离变换 + marker-controlled Watershed；若传统方法仍不稳定，应考虑 U-Net 等深度学习方法。

Q24. 传统方法和深度学习方法在分割任务中的差异是什么？

关键词：可解释性；参数依赖；数据依赖；语义理解；泛化

传统方法依赖人工设计的灰度、颜色、梯度或相似性准则，优点是简单、可解释、计算成本低、小数据场景也能使用；缺点是参数敏感、鲁棒性和泛化能力弱、缺少语义理解。

深度学习方法能从数据中学习多层特征和语义上下文，通常对复杂场景更强；缺点是需要标注数据、训练成本高、可解释性弱，部署可能需要较高算力。

考试中可用一句话收束：传统方法适合规则、低成本、可解释的简单场景；深度学习适合复杂、多变、需要语义理解的场景。

Q25. 如果考试给一张粘连细胞/微生物图，问用哪种传统方法更合适，怎么答？

关键词：粘连目标；距离变换；marker；Watershed

优先考虑 marker-controlled Watershed。原因是粘连物体的边界可能互相接触，单纯阈值只能得到一大块连通区域，而分水岭可以利用距离变换或局部极值把粘连目标分开。

答题流程：先阈值化得到前景；用形态学开运算去小噪点、闭运算补孔；计算距离变换找确定前景 marker；确定背景；最后用 Watershed 分割粘连区域，并用面积/圆度等规则筛除异常区域。

七、评价指标与实验报告写法

Q26. 传统分割有人工标签时，可以如何计算 IoU 和 Dice？

关键词：交并比；Dice；小前景；Accuracy 可能误导

$\text{IoU} = \text{预测前景与真实前景的交集} / \text{预测前景与真实前景的并集}$ 。 $\text{Dice} = 2 * \text{交集} / (\text{预测前景像素数} + \text{真实前景像素数})$ 。
IoU 更严格，Dice 对重叠程度也很敏感。若前景区域很小，只看 Accuracy 可能被大量背景像素“稀释”，因此实验分析中可补充 IoU/Dice。

Q27. 传统分割结果表格应该怎么写？

关键词：算法；参数；视觉效果；优缺点；差异；改进

建议包含：算法名称、输入图像编号、关键参数、结果现象、优点、缺点、与标签差异、可能改进。

示例句：“Otsu 能自动确定阈值，目标主体基本被提取，但由于背景亮度不均，部分背景被误判为前景。改进可加入光照校正、形态学开运算或连通域面积筛选。”

分析对象	可写现象	原因解释	改进思路
阈值/Otsu	前景缺失、背景误检、孔洞	灰度重叠、光照不均、噪声干扰	自适应阈值、预平滑、光照校正、形态学闭运算
Canny/轮廓	边缘断裂、内部纹理多、无法填成区域	梯度弱、噪声强、阈值不合适	高斯平滑、调阈值、闭运算、轮廓填充
K-means	同一目标被拆开或不同目标合并	K 设置不当，颜色特征不足	调 K，加入空间坐标，后处理连通域
区域生长	泄漏或欠分割	种子点偏差、阈值不合适、弱边界	手动/自动优化种子点，调阈值，先增强边界
Watershed	过分割、小碎片多	局部极小值过多，marker 过密	平滑、形态学、距离变换、marker 控制

八、选择题/判断题易错点

题干/说法	答案	理由
Otsu 不需要人工指定阈值，所以不受图像灰度分布影响。	错	Otsu 自动算阈值，但严重依赖直方图双峰假设。
Canny 边缘检测结果可以直接等价于完整目标 mask。	错	它输出边界，不保证闭合，也没有区域语义。
K-means 的 K 越大，分割结果一定越好。	错	K 过大会过分割，结果碎片化。
区域生长法对种子点和相似性阈值敏感。	对	种子决定起点，阈值决定扩张范围。
Watershed 适合粘连目标分离，但容易过分割。	对	它边界定位好，但噪声会产生大量盆地。
传统分割方法通常具备强语义理解能力。	错	传统方法主要依赖灰度、颜色、边缘、相似性等低层特征。
Mean Shift 不需要预设 K。	对	它通过密度峰值自动形成聚类，但需要带宽参数。
固定阈值适合光照稳定、前景背景对比明显的场景。	对	若低对比度或光照不均，固定阈值效果会明显下降。
形态学开运算可用于去除小噪声，闭运算可用于填补小孔或连接断裂。	对	这是传统分割常用后处理。
只要有人工标签，传统分割结果也可以计算 IoU/Dice。	对	指标和模型无关，只要求预测 mask 与真实 mask。