

DnCNN 大全

一、DnCNN 必背主线

考点	一句话答案
图像复原总模型	$y = Hx + n$ ；去噪时 $H \approx I$ ，所以 $y = x + n$ 。
DnCNN 的核心思想	不直接学干净图像，而是学习噪声残差 n ，再用输入 y 减去预测噪声得到 $\hat{x}$ 。
代码中的 <code>return x-n</code>	x 是输入噪声图， n 是网络预测的噪声残差， $x-n$ 是复原图。
为什么残差学习	噪声残差比干净图像结构更简单，均值更接近 0，更容易拟合；也能让网络专注于去掉退化成分。
为什么 BN 有用	BN 稳定特征分布、加速收敛；高斯去噪残差分布较简单，BN 与残差学习相互促进。
评价指标	PSNR/SSIM 是全参考指标，需要干净参考图；真实噪声没有 ground truth 时不能直接算。
噪声强度 σ	σ 越大，噪声越强，去噪难度越高；通常 PSNR/SSIM 越低。
DnCNN_15/25/50	通常对应训练噪声水平 $\sigma=15/25/50$ ；模型与噪声水平不匹配会欠去噪或过平滑。
传统方法对比	均值/高斯滤波简单但模糊边缘；NLM/BM3D 利用非局部相似性；DnCNN 用数据学习图像先验。
实验报告重点	展示噪声图、复原图、原图；记录 model_name、testset_name、noise_level_img、PSNR、SSIM，并分析。

二、核心概念与模型原理：简答题高频问法

【简答】问题 1：图像复原的统一观测模型是什么？DnCNN 所在的去噪任务对应哪一种特例？

答案：图像复原通常写成 $y = Hx + n$ ，其中 x 是潜在清晰图像， y 是观测到的退化图像， H 是退化算子或退化矩阵， n 是噪声。若 H 是恒等映射 I ，则退化主要来自加性噪声，模型变为 $y = x + n$ ，这就是图像去噪任务。DnCNN 主要解决的就是从噪声图 y 中恢复清晰图 x 。

记忆点：复原大公式 $y=Hx+n$ ；去噪特例 $y=x+n$ 。

【简答】问题 2：什么是图像去噪？它和图像增强有什么区别？

答案：图像去噪是减少数字图像中噪声的过程，目标是恢复更接近真实场景或干净参考图的图像。图像增强更偏向改善视觉效果，例如调亮、增强对比度、HDR 或色调映射，不一定严格恢复原始真实图像。图像复原强调退化模型和参考图像，去噪属于图像复原中的典型任务。

【简答】问题 3：合成噪声和真实噪声有什么区别？

答案：合成噪声是人为加入、模型明确的噪声，如高斯白噪声、泊松噪声、椒盐噪声、空间变化高斯噪声等。真实噪声来自相机传感器、ISO 增益、ISP 流程、压缩和外部环境，常常是异方差、非均匀、与设备相关的复杂噪声。合成噪声适合做可控实验，真实噪声更贴近实际但更难建模和评价。

【简答】问题 4：什么是非盲去噪和盲去噪？DnCNN_15、DnCNN_25、DnCNN_50 属于哪类实验设置？

答案：非盲去噪指噪声模型和参数已知，例如已知是高斯白噪声且噪声水平 $\sigma=25$ 。盲去噪指噪声参数未知，或需要模型自动估计噪声水平。实验中的 dncnn_15、dncnn_25、dncnn_50 通常对应已知噪声水平 $\sigma=15、25、$

50 的预训练模型，因此更接近非盲去噪实验设置。若用一个模型处理多种未知噪声，则更接近盲去噪或通用去噪。

记忆点：非盲=知道 σ ；盲=不知道 σ 。

【简答】问题 5：DnCNN 为什么采用残差学习，而不是直接预测干净图像？

答案：因为干净图像 x 包含复杂结构、纹理和语义，分布复杂；而噪声残差 $n = y - x$ 通常更简单，特别是高斯噪声接近零均值、统计分布更稳定。让网络学习噪声残差，等价于让模型专注于“要去掉什么”，最后用 $y - n_{\text{hat}}$ 得到复原图 x_{hat} 。这样更容易优化、收敛更快，也更符合去噪任务的物理含义。

记忆点：学噪声比学整张干净图更简单；输出残差，再相减。

【简答】问题 6：DnCNN 中的 $\text{return } x - n$ 表示什么？

答案：在代码阅读题中， x 通常表示输入的噪声图像， n 表示网络预测出的噪声残差。 $\text{return } x - n$ 的含义是：用输入噪声图减去估计噪声，得到复原后的干净图像。也可以写作 $x_{\text{hat}} = y - R(y)$ ，其中 $R(y)$ 是 DnCNN 预测的噪声残差。

记忆点：这是实验指导书最可能直接问的代码题。

【简答】问题 7：DnCNN 的基本网络结构是什么？

答案：DnCNN 是卷积神经网络去噪模型。典型结构为：第一层 Conv + ReLU，中间多层 Conv + BatchNorm + ReLU，最后一层 Conv 输出残差图。输入是噪声图像，网络输出通常是噪声残差，最终复原图由输入图像减去残差得到。它没有全连接层，适合处理任意尺寸的图像块或整图。

【简答】问题 8：DnCNN 中 Batch Normalization 的作用是什么？为什么它和残差学习相互促进？

答案：Batch Normalization 可以稳定中间特征分布，缓解训练不稳定，加快收敛。DnCNN 学习的是噪声残差，特别是高斯噪声残差分布相对简单、接近零均值，这使得 BN 更容易发挥作用；反过来 BN 又让残差学习的优化过程更稳定。因此课程资料强调 BN 和残差学习对高斯去噪特别有益。

记忆点：BN 稳定训练；残差分布简单；二者配合。

【简答】问题 9：DnCNN 的“残差学习”和 ResNet 的“shortcut connection”是不是一回事？

答案：不是完全一回事。ResNet 的残差学习主要体现在网络内部的跨层加和，即 $x_{l+1} = x_l + F(x_l)$ ，目的是缓解退化现象和梯度消失。DnCNN 的残差学习主要体现在学习目标上：网络不直接输出干净图像，而是输出噪声残差，再用输入减去残差得到复原图。二者都体现“学残差比学完整映射更容易”的思想，但作用位置不同。

记忆点：ResNet 是内部跨层加和；DnCNN 是输出层面的噪声残差目标。

【简答】问题 10：什么是训练阶段的退化（degradation）现象？残差思想如何缓解它？

答案：退化现象指网络加深后，训练误差反而升高，并不是简单的过拟合，而是深层网络更难优化。残差学习通过让网络学习 $F(x) = H(x) - x$ ，而不是直接学习 $H(x)$ ，如果新增层没有必要，理论上可以退化为近似恒等映射，使深层网络更容易训练。DnCNN 借鉴残差思想，把去噪目标改成学习噪声残差，从而降低学习难度。

【简答】问题 11：为什么说 DnCNN “beyond Gaussian denoising”？

答案：因为 DnCNN 不只可以用于高斯去噪。课程资料中展示了单个模型可以用于高斯去噪、单幅图像超分辨率和 JPEG 去块效应等任务。核心原因是这些任务都可以理解为从退化图像中估计某种残差或退化成分，再恢复潜在清晰图像。

【简答】问题 12：DnCNN 能处理混合退化吗？例如噪声、低分辨率、JPEG 压缩同时存在。

答案：可以作为思路上处理混合退化的模型。课程资料中给出“DnCNN for hybrid noises”的例子，包含 noise level、SR factor、JPEG factor 等退化因素。答题时应说明：只要训练数据中包含相应退化类型，网络就可能学习从混合退化输入到残差/复原图的映射；但若测试退化和训练退化分布差异很大，效果会下降。

【简答】问题 13：为什么传统均值滤波或高斯滤波容易使图像变模糊？

答案：均值滤波和高斯低通滤波通过局部平滑来抑制噪声，但图像边缘本身也是高频信息，和噪声在频域上可能混在一起。局部平均会同时削弱噪声和边缘细节，因此去噪后常出现边界模糊、纹理丢失。

【简答】问题 14：NLM 和 BM3D 的基本思想是什么？它们与 DnCNN 有何区别？

答案：NLM 利用图像内部的非局部自相似性，用相似图像块加权平均来去噪。BM3D 对相似块进行分组，堆叠成三维数组，在变换域做协同滤波和阈值收缩，再聚合回图像。它们是手工设计的传统方法，依赖自相似和稀疏性先验；DnCNN 则通过数据学习图像先验和退化到残差的映射，通常速度和效果更好，但更依赖训练数据。

记忆点：BM3D=块匹配+3D 协同滤波；DnCNN=数据驱动学习残差。

【简答】问题 15：DnCNN 相比 BM3D 的优势和局限分别是什么？

答案：优势：DnCNN 端到端学习，可利用大量 degraded-clean 样本学习复杂图像先验；推理阶段只需一次前向传播，GPU 上速度快；在高斯去噪基准上通常优于 BM3D。局限：依赖训练数据和退化模型，若真实噪声与训练噪声差异大，可能欠去噪、过平滑或产生伪影；可解释性也弱于完全手工设计方法。

【简答】问题 16：为什么深度学习适合图像去噪？

答案：深度学习可以端到端学习从退化图到清晰图或残差图的映射；深层结构具有较强表达能力，能学习复杂图像先验；卷积结构适合局部空间模式建模；配合 GPU 可以较快推理。课程资料还提到训练流程包括准备退化-干净样本对、设计网络结构和损失函数、训练模型，测试时输入退化图即可得到复原图。

【简答】问题 17：DnCNN 的损失函数一般怎么设计？

答案：常见做法是使用 MSE/L2 损失。如果网络预测噪声残差，则可以让预测残差 $\hat{n}$ 接近真实噪声 $n = y - x$ ；如果网络直接返回 $x - n$ ，也可以让复原图 $\hat{x}$ 接近干净图 x 。核心目标都是让输出与对应的监督信号误差尽可能小。

【简答】问题 18：DnCNN 为什么不一定需要全连接层？

答案：图像去噪是像素级或局部到全局的密集预测任务，需要保持空间结构。卷积层具有局部连接和参数共享特性，能够在不同位置复用同一组滤波器，适合任意尺寸输入和整图推理。全连接层会破坏空间对应关系，并固定输入尺寸，通常不适合此类图像复原任务。

【简答】问题 19：卷积层数、通道数和感受野对 DnCNN 有什么影响？

答案：卷积层数越多，感受野越大，模型可以利用更大范围上下文判断噪声和结构；通道数越多，特征表达能力越强。但过深或过宽会增加计算量和过拟合风险，也可能导致训练困难。因此 DnCNN 借助残差学习和 BN 来稳定较深网络的训练。

【简答】问题 20：DnCNN 的输入和输出尺寸通常是否相同？为什么？

答案：通常相同。去噪任务要求对输入图像中每个像素给出对应的复原结果，所以输出应与输入在空间尺寸上一致。使用合适 padding 的卷积可以保持特征图尺寸不变，最后输出残差图或复原图。

三、评价指标与结果分析：考试常问

【指标】问题 21: MSE、PSNR、SSIM 分别衡量什么？

答案：MSE 是预测图与参考图的平均平方误差，越小越好。PSNR 是由 MSE 推出的峰值信噪比，常写作 $PSNR = 10 \log_{10}(MAX^2/MSE)$ ，越大表示像素误差越小。SSIM 从亮度、对比度、结构相似性角度衡量图像质量，通常比 PSNR 更接近结构感知。实验中常同时记录平均 PSNR 和平均 SSIM。

记忆点：PSNR 越高越好，SSIM 越接近 1 越好。

【指标】问题 22: 为什么真实噪声图像不能直接计算 PSNR/SSIM？

答案：PSNR 和 SSIM 属于全参考指标，需要干净参考图像作为 ground truth。真实噪声图像通常没有对应的无噪声真值，因此不能直接计算 PSNR/SSIM，只能使用无参考指标、主观评价、视觉对比，或构造近似参考。实验指导书也提示 real_faces 等真实噪声图像没有参考图时无法直接算这些指标。

【指标】问题 23: 噪声强度 σ 与 PSNR/SSIM 通常有什么关系？

答案：噪声强度 σ 越大，图像退化越严重，去噪难度越高。若模型能力和训练条件不变， σ 增大通常会导致复原结果的 PSNR 和 SSIM 下降。课程资料中 BSD68 的结果也呈现出 $\sigma=15$ 的 PSNR 高于 $\sigma=25$ ， $\sigma=25$ 又高于 $\sigma=50$ 的趋势。

【指标】问题 24: PSNR 高是否一定代表视觉效果最好？

答案：不一定。PSNR 基于像素级误差，偏向平均意义上的接近参考图，但可能无法准确反映纹理、结构和主观感知质量。有些结果 PSNR 高但过于平滑；有些结果细节更自然但像素误差略大。应结合 SSIM、视觉对比和具体任务需求分析。

【指标】问题 25: 如何分析一张 DnCNN 去噪结果是欠去噪还是过平滑？

答案：欠去噪表现为噪声颗粒仍明显，平坦区域残留噪声多；过平滑表现为边缘变软、纹理消失、细节被当作噪声去掉。可以放大局部区域，比较噪声图、复原图和原图，同时结合 PSNR/SSIM 判断。

【指标】问题 26: 为什么 model_name 和 noise_level_img 不匹配会影响结果？

答案：dncnn_15、dncnn_25、dncnn_50 通常针对特定噪声水平训练。若噪声很强却用低噪声模型，模型可能欠去噪；若噪声较弱却用高噪声模型，模型可能把细节误当噪声删除，导致过平滑。因此实验报告要记录 model_name 和 noise_level_img，并分析匹配与不匹配的影响。

【指标】问题 27: Average PSNR/SSIM 和单张图 PSNR/SSIM 有什么区别？

答案：单张图指标反映某一图像的复原效果，平均指标反映模型在测试集上的总体表现。考试或报告中应避免只用一张图下结论，最好在 set5、set12 或 bsd68 等测试集上统计平均 PSNR/SSIM，并选取典型高分、低分样本做定性分析。

四、实验与代码理解题：按实验指导书整理

【实验】问题 28: DnCNN 实验中 KAIR/、main_test_dncnn.py、models/network_dncnn.py、model_zoo/、testsets/ 分别有什么作用？

答案：KAIR/ 是图像复原实验代码目录；main_test_dncnn.py 是测试入口脚本，负责读取参数、加载模型和测试集、添加或读取噪声、推理并保存结果；models/network_dncnn.py 定义 DnCNN 网络结构；model_zoo/ 存放预训练权重；testsets/ 存放 set5、set12、bsd68 等测试图像。

【实验】问题 29：实验中常用的运行命令和参数有哪些？

答案：常用命令示例：

```
python main_test_dncnn.py --model_name dncnn_25 --testset_name set5 --noise_level_img 25 --device
cpu
python main_test_dncnn.py --model_name dncnn_50 --testset_name set12 --noise_level_img 50 --device
cpu
```

其中 model_name 指定预训练模型，testset_name 指定测试集，noise_level_img 指定添加噪声强度，device 指定 cpu 或 cuda。

【实验】问题 30：DnCNN 输出目录中的 *_L、*_E、*_H 和 *.log 通常表示什么？

答案：*_L 通常表示低质量/噪声图像，*_E 表示模型估计结果或复原图像，*_H 表示高质量原图或参考图像，*.log 记录 PSNR、SSIM 等日志信息。答题时可以说：实验报告需要展示噪声图、复原图、原图，并把日志中的平均 PSNR/SSIM 整理成表格。

【实验】问题 31：实验报告中 DnCNN 结果表应该记录哪些字段？

答案：至少记录 model_name、testset_name、noise_level_img、平均 PSNR、平均 SSIM。更完整的表格还可以加入 device、运行时间、是否匹配噪声水平、视觉效果说明、失败案例说明。

【实验】问题 32：阅读 network_dncnn.py 时应该重点说明什么？

答案：重点说明网络输入、输出、卷积层数、通道数、是否使用 BN 和 ReLU、最后一层输出什么，以及 return x-n 的含义。可以按“输入噪声图 → 多层卷积提取特征 → 输出噪声残差 → 输入减残差得到复原图”的流程回答。

【实验】问题 33：为什么实验不要求重新训练模型，而使用预训练权重？

答案：重新训练 DnCNN 需要大量 degraded-clean 图像对、较长训练时间和 GPU 资源。实验目标是理解网络结构、推理流程、参数影响和评价指标，因此使用预训练权重即可完成基本推理和分析。

【实验】问题 34：如果把 device 从 cpu 改成 cuda，会改变去噪结果吗？

答案：理论上不会改变算法目标和模型参数，只是使用 GPU 加速推理。但由于不同硬件和数值计算可能存在微小浮点差异，结果指标可能有极小差别。实验报告中可以说明 device 主要影响速度。

【实验】问题 35：如何设计 dncnn_15、dncnn_25、dncnn_50 的对比实验？

答案：固定测试集，例如 set12；分别使用不同 model_name 和对应 noise_level_img 运行；记录每组平均 PSNR/SSIM；再选取相同图像的局部放大图比较噪声残留和细节损失。可以进一步做不匹配实验，例如噪声水平 50 却用 dncnn_15，观察欠去噪现象。

【实验】问题 36：如何解释“至少选择两组不同噪声强度或不同模型权重进行对比”的目的？

答案：目的是观察噪声强度和模型权重对去噪效果的影响。不同 σ 会改变任务难度，不同模型权重代表网络针对不同噪声水平学到的去噪能力。通过对比可以理解参数设置、模型假设和实际效果之间的关系。

【实验】问题 37：为什么实验输出需要同时展示噪声图、复原图和原图？

答案：只看复原图无法判断哪些细节被保留或误删。噪声图展示退化程度，复原图展示模型输出，原图提供参考。三者并排能分析去噪是否充分、是否过平滑、边缘和纹理是否恢复。

【实验】问题 38：如果遇到真实噪声测试图 real_faces，实验报告应该怎么写？

答案：应说明该图没有对应干净参考图，因此不能直接计算 PSNR/SSIM。可以做视觉分析，例如观察肤色区域、背景平坦区域、边缘和纹理是否自然，也可以使用无参考指标或主观评分作为补充。

【实验】问题 39: DnCNN 实验和 U-Net 实验在输入输出、指标和任务目标上有什么不同?

答案: DnCNN 是图像复原/去噪任务, 输入是噪声图, 输出是复原图, 常用 PSNR/SSIM 评价; U-Net 是医学图像语义分割任务, 输入是 X-ray 图像, 输出是预测 mask, 常用 IoU/Accuracy 等分割指标评价。二者都属于深度学习视觉任务, 但任务定义、输出类型和评价指标不同。

五、分析设计题: 可直接套用的答案模板

【分析】问题 40: 设计一个 DnCNN 图像去噪实验, 你会如何安排?

答案: 可以按以下步骤回答: 第一, 选择测试集, 如 set5、set12 或 bsd68; 第二, 选择噪声模型和噪声水平, 例如高斯噪声 $\sigma=15、25、50$; 第三, 选择对应预训练模型 dncnn_15、dncnn_25、dncnn_50; 第四, 运行测试脚本并保存噪声图、复原图、原图和日志; 第五, 统计平均 PSNR/SSIM; 第六, 选取典型样本做视觉分析, 说明噪声残留、边缘保持、纹理损失和失败案例。

【分析】问题 41: 如果老师问“为什么 DnCNN 可以用于图像复原而不仅是去噪”, 怎么答?

答案: 图像复原都可以看作从退化观测 y 中恢复潜在清晰图 x 。去噪、超分辨率、JPEG 去块效应虽然退化形式不同, 但都可以转化为学习退化残差或恢复映射的问题。DnCNN 的残差学习框架可以在合适训练数据下学习不同任务的残差, 因此课程资料中展示了单个模型用于高斯去噪、超分辨率和 JPEG deblocking。

【分析】问题 42: 如果去噪结果 PSNR 提高但视觉上变得很平滑, 如何分析?

答案: 这说明模型降低了像素误差, 但可能把细节纹理也当作噪声删除。PSNR 更关注逐像素误差, 不完全等价于感知质量。应结合 SSIM、局部放大图、纹理区域和边缘区域分析, 并指出去噪任务存在噪声抑制与细节保持之间的权衡。

【分析】问题 43: 如果 DnCNN 在某些真实低光图像上效果不好, 可能原因是什么?

答案: 可能原因包括: 训练时主要使用合成高斯噪声, 而真实低光噪声包含传感器噪声、ISO 增益、颜色通道相关性、压缩伪影和 ISP 影响; 测试分布与训练分布不一致; 噪声强度空间变化; 没有真实 clean ground truth; 图像细节和噪声难以区分。改进方向包括使用真实 noisy-clean 数据、建模 ISP 噪声、使用盲去噪或自监督去噪方法。

【分析】问题 44: 如何比较传统去噪方法和 DnCNN?

答案: 可以从五个角度比较: 1) 先验来源: 传统方法依赖手工先验, 如平滑、自相似、稀疏性; DnCNN 通过数据学习先验。2) 参数依赖: 传统方法需要滤波核大小、搜索窗口、阈值等; DnCNN 推理参数少但依赖训练权重。3) 效果: 传统方法容易模糊或受参数影响, DnCNN 在匹配退化上通常更好。4) 可解释性: 传统方法更直观, DnCNN 较弱。5) 泛化性: DnCNN 若遇到训练外噪声可能失效。

【分析】问题 45: 如果让你改进 DnCNN, 你会从哪些方面入手?

答案: 可以考虑: 加入噪声水平图使模型更灵活; 使用真实噪声数据训练; 引入注意力或多尺度结构; 使用残差块或 U-Net 式结构扩大感受野; 结合感知损失或 SSIM 损失改善视觉效果; 对真实噪声使用自监督方法, 如 Noise2Void、Noise2Noise、Neighbor2Neighbor 等。

【分析】问题 46: 如何做 BN 和残差学习的消融实验?

答案: 设计四组模型: 有 BN + 有残差学习; 有 BN + 无残差学习; 无 BN + 有残差学习; 无 BN + 无残差学习。固定训练数据、噪声水平、优化器和训练轮数, 比较训练曲线、收敛速度、最终 PSNR/SSIM。若符合课程结论, BN 与残差学习同时使用时通常收敛更稳、结果更好。

【分析】问题 47：如果老师让你解释 DnCNN 的失败案例，应从哪里入手？

答案：先判断是否噪声水平与模型不匹配；再看图像是否包含大量细纹理、重复纹理或低对比度结构；观察是否出现欠去噪、过平滑、颜色偏移或伪影；最后联系训练数据分布，说明合成高斯噪声模型与真实噪声可能存在差异。

六、选择题/判断题高频陷阱（含答案）

题目	答案	解析
1. DnCNN 在典型去噪设置中主要学习的是： A. 图像类别 B. 噪声残差 C. 分割 mask D. 光流	B	DnCNN 通常预测噪声残差，再用输入减残差。
2. 图像去噪的简单退化模型可写为： A. $y=x+n$ B. $y=k*x \downarrow s$ C. $y=\text{softmax}(x)$ D. $y=Hx-n$	A	去噪是 $H \approx I$ 的特例。
3. PSNR 越高通常表示： A. MSE 越大 B. 像素误差越小 C. 图像越暗 D. 不能说明任何问题	B	PSNR 与 MSE 负相关。
4. 真实噪声图像没有 clean ground truth 时，能否直接计算 PSNR/SSIM？ A. 能 B. 不能 C. 只要有噪声图就能 D. 只要图像是 RGB 就能	B	PSNR/SSIM 是全参考指标。
5. dncnn_25 通常对应的噪声水平是： A. $\sigma=5$ B. $\sigma=15$ C. $\sigma=25$ D. $\sigma=50$	C	模型名中的数字通常表示训练噪声水平。
6. 高斯滤波去噪的常见问题是： A. 会模糊边缘 B. 不能处理任何噪声 C. 只能用于彩色图 D. 需要深度学习框架	A	低通滤波会削弱高频边缘。
7. BM3D 的核心思想更接近：A. 目标检测 B. 块匹配与三维协同滤波 C. 语义分割 D. 直方图均衡	B	BM3D = Block Matching and 3D filtering。
8. DnCNN 中 Batch Normalization 的主要作用包括：A. 稳定训练 B. 固定输出类别数 C. 代替损失函数 D. 生成标签	A	BN 稳定中间分布并加速收敛。
9. 如果噪声很强却使用低噪声模型，常见结果是： A. 欠去噪 B. 输出 mask C. 图像变成 HDR D. 自动训练新模型	A	模型能力与噪声强度不匹配。
10. 判断：DnCNN 的 $\text{return } x-n$ 中， n 可以理解为预测噪声残差。	对	$x-n$ 即输入减去估计噪声。
11. 判断：DnCNN 和 U-Net 的评价指标完全相同。	错	DnCNN 常用 PSNR/SSIM；U-Net 分割常用 IoU/Accuracy。

12. 判断：只要 PSNR 高，视觉效果一定最好。	错	PSNR 不完全等价于感知质量。
13. 判断：真实噪声通常比合成高斯噪声更复杂。	对	真实噪声受传感器、ISO、ISP、压缩等影响。
14. 判断：DnCNN 只适用于高斯去噪，完全不能用于其他图像复原任务。	错	课程资料提到单模型多任务和混合退化示例。
15. 判断：传统去噪方法一定比 DnCNN 更不可解释。	错	通常传统方法更直观，DnCNN 更依赖数据和网络。